

THEME DU MEMOIRE

INTELLIGENCE ARTIFICIELLE ET DETECTION PRECOCE DES TUMEURS CEREBRALES A PARTIR D'IMAGES RADIOLOGIQUES

*Mémoire en vue de l'obtention du diplôme de Master en management des
projets **Option Intelligence Artificielle et Big Data***

Présenté par :

TCHAKOUNTE Junior

Etudiant en Master 2

Encadrant Académique :

**Dr. DJIONOU SADJANG
Patrick**

Co-Encadrant Académique :

KOMBEUL Ulrich Hatmann

*Doctorant et Spécialiste en Intelligence
Artificielle et system embarqué*

Yaoundé, CAMEROUN

Année Académique : 2022 - 2023

DEDICACE

A MA FAMILLE

REMERCIEMENTS

Toute œuvre humaine ne pouvant être le fruit d'efforts uniquement personnels, nous souhaitons donc remercier tous ceux qui nous ont aidés, de près ou de loin, quel que soit le plan.

Ces personnes étant nombreuses, nous pensons spécialement à :

- L'Ingénieur **KOMBEUL Ulrich Hatmann**, enseignant de KEYCE Informatique et d'Intelligence Artificielle et notre encadreur académique pour son aide et ses précieux conseils pour la bonne élaboration de notre projet ;
- A tout le Corps Administratif et Direction de KEYCE Informatique et d'Intelligence Artificielle, Pour la qualité de la formation dont nous avons pu en bénéficier ;
- A tous les enseignants de KEYCE Informatique et d'Intelligence Artificielle pour la qualité majestueuse de leur savoir dont ils ont pu nous transmettre ;
- A Monsieur **ASSOU Frank**, Directeur de Keyce et intelligence artificielle pour la disposition des meilleures conditions académique ;
- A Monsieur **YOUTOU Jean**, Vice-président du collège de paris pour la création, et le succès de Keyce informatique au Cameroun
- À nos parents Monsieur **SILENOU Pierre** et Madame **MEGANG Gisele** qui ont œuvré de leur mieux depuis notre naissance pour notre croissance physique et intellectuelle ;
- Nos frères et sœurs pour leurs encouragements, critiques, réprimandes et surtout leur soutien inconditionnel qui ont beaucoup contribué à notre évolution ;
- A tous nos amis et camarades de promotion pour toute leur contribution technique ;

Au terme de ce travail, je rends grâce à DIEU tout puissant de m'avoir accordé la volonté, le courage et l'intelligence pour réaliser ce mémoire.

RESUME

Dans le monde, l'une des premières causes de mortalité des maladies liées au cerveau sont des tumeurs. Selon l'institut national de recherche contre le cancer (INCA), on estime environ 41,000 le nombre de décès dans le monde lié celle-ci. L'une des raisons liées à ce phénomène est que traditionnellement, la détection des tumeurs cérébrales à partir d'images radiologiques, telles que les scanners et les Imageries par Résonance Magnétique (IRM), sont réalisées par des radiologues humains, mais cela peut être un processus laborieux et sujet à des erreurs.

Notre travail a donc pour but d'explorer les possibilités offertes par l'IA et l'apprentissage profond pour améliorer la détection précoce des tumeurs cérébrales à partir d'images radiologiques et de l'appliquer dans un contexte spécifique du Cameroun en mettant l'enjeu sur un vaste ensemble de données d'images radiologiques préalablement annotées. Ces modèles peuvent être formés pour reconnaître les motifs associés aux tumeurs cérébrales ainsi facilitant la détection précoce de ces tumeurs et réduisant les risques des erreurs.

La méthodologie appliquée à ce travail passe dans un premier temps, un contexte d'étude faisant ressortir l'importance de ce travail. Puis une revue littéraire ou les différents concepts liés à la théorie et notion de l'IA et l'apprentissage profond sont présentés, ainsi que les notions de tumeurs cérébrales et leurs différents types. Pour la suite de notre travail, les sources de données sélectionnées sont présentées et son pré traitement, et enfin nous allons appliquer un algorithme d'apprentissage profond combiné a de l'apprentissage par transfert et l'appliquer sur les données contenant des images scannées par l'IRM dans le but de produire des classes appartenant à chaque type de tumeur cérébrale. Après l'obtention des résultats, ce modèle algorithmique sera ensuite déployé sur un serveur et sera exploité par une application web développé avec un Framework web (nous utiliserons **React JS**). Le résultat obtenu à partir de notre modèle est un tableau comparatif basé sur la précision des différents types de tumeur cérébrale existant dans notre base de données.

Mots clé : Intelligence artificielle ; Apprentissage profond ; Tumeur cérébrale ; Algorithme ; Réseau Neuronal Convolutif

ABSTRACT

Worldwide, one of the leading causes of death from brain-related diseases are tumors. It is estimated that about 41,000 is the number of deaths linked to it worldwide. One of the reasons for this is that traditionally, the detection of brain tumors from X-ray images, such as CT scans and magnetic resonance imaging (MRI), has been performed by human radiologists, but this can be a laborious and error-prone process.

Our work therefore aims to explore the possibilities offered by AI and deep learning to improve the early detection of brain tumors from radiological images and to apply it in a specific context of Cameroon by putting the challenge on a large set of previously annotated radiological image data. These models can be trained to recognize patterns associated with brain tumors, thus facilitating early detection of these tumors and reducing the risk of errors.

The methodology applied to this work begins with a study context highlighting the importance of this work. This is followed by a literature review in which the various concepts related to the theory and notion of AI and deep learning are presented, as well as the notions of brain tumors and their various types. For the rest of our work, the selected data sources and their pre-processing are presented, and finally we will apply a deep learning algorithm combined with transfer learning and apply it to data containing MRI scanned images with the aim of producing classes belonging to each type of brain tumor. Once the results have been obtained, this algorithmic model will then be deployed on a server and used by a web application developed using a web framework (we will be using React JS). The result obtained from our model is a comparative table based on the accuracy of the different types of brain tumor in our database.

Keywords: Artificial intelligence; Deep learning; Brain tumor; Algorithm; Convolutional neural network

SOMMAIRE

DEDICACE	I
REMERCIEMENTS	II
RESUME	III
ABSTRACT	IV
LISTE DES FIGURES	VI
LISTE DES TABLEAUX.....	IX
LISTE DES ABREVIATIONS	X
INTRODUCTION GENERALE	1
CHAPITRE I : CADRE THEORIQUE ET CONCEPTUEL	11
CHAPITRE II : METHODOLOGIE DE RECHERCHE	51
CHAPITRE III : PRESENTATION DE LA SITUATION.....	58
CHAPITRE IV : ANALYSE DE LA SITUATION ET PROPOSITION D'INTERVENTION.....	68
CONCLUSION GENERALE	103
WEBOGRAPHIE ET BIBLIOGRAPHIE	XI
ANNEXES	XIV
TABLE DES MATIERES	XVI

LISTE DES FIGURES

Figure I. 1. Premier calculateur (wikipédia.org s.d.).....	13
Figure I. 2. Évolution de l'IA (wikipedia.org s.d.)	19
Figure I. 3. Apprentissage automatique (Azencot s.d.)	21
Figure I. 4. Illustration Machine a vecteur de support (medium.com s.d.).....	26
Figure I. 5. Illustration K-plus proche voisin (medium.com s.d.)	27
Figure I. 6. Illustration Foret aléatoire (medium.com s.d.).....	28
Figure I. 7. Relation entre Deep Learning avec le ML et IA (Mathew et al. 2021)	29
Figure I. 8 Illustration d'un CNN (medium.com s.d.)	32
Figure I. 9. Couche de neurone (openclassroom.com s. d.).....	33
Figure I. 10. Représentation d'un neurone artificielle.....	34
figure I. 11. pooling (researchgate.net s,d,)	36
Figure I. 12. Fully connected Network (Jul s. d.).....	37
figure I. 13. Cross validation (medium.com s.d.).....	38
Figure I. 14. Random search (quora.com s. d.)	39
Figure I. 15. Grid Search (quora.com s. d.)	39
Figure I. 16. Présentation du cerveau humain (google.com s.d.)	41
Figure I. 17. Formation des cellules cancéreuses (Ali-Osman 2002)	42
Figure I. 18. Schéma d'un supraconducteur cylindrique à résonance magnétique (wikipedia.org s.d.)	45
Figure I. 19. Scan par IRM d'un cerveau saint (google.com s.d.)	45
Figure I. 20. Scan par IRM d'un cerveau avec présence de tumeur (google.com s.d.)	45
Figure III. 1. Organigramme du cabinet Fadjou	61
Figure III. 2. Situation Géographique (google.com/maps s.d.).....	62
Figure III. 3. Résultat 1	64
Figure III. 4. Résultat 2	65
Figure III. 5. Résultat 3	66
Figure III. 6. Résultat 4	66

Figure IV. 1. Présentation de l'outil Anaconda (anaconda.com s.d.)	73
Figure IV. 2. Présentation de l'outil Jupyter (anaconda.com s.d.)	75
Figure IV. 3. Présentation de l'interface hugging face (huggingface.co s.d.)	76
Figure IV. 4. Interface de ReactJS (react.dev s.d.)	77
Figure IV. 5. Visual Studio Code (code.visualstudio.com s.d.)	78
Figure IV. 6. Python (python.developpez.com s.d.)	78
Figure IV. 7. JavaScript (bing.com s.d.)	79
Figure IV. 8. TensorFlow (tensorflow.org s.d.)	80
Figure IV. 9 Architecture de la solution	81
Figure IV. 10. Présentation du fichier des données	82
Figure IV. 11. Répartition des données	83
Figure IV. 12. Création des étiquettes pour les classes	84
Figure IV. 13. Chargement du dataset et splitting	84
Figure IV. 14. Normalisation des données	85
Figure IV. 15. Importation des librairies CNN normale	86
Figure IV. 16. Construction du modèle CNN normale	86
Figure IV. 17. Compilation et entraînement du modèle CNN normale	87
Figure IV. 18 Courbe ROC du CNN normale	87
Figure IV. 19. Matrice de confusion CNN normale	88
Figure IV. 20. Rapport de classification CNN normale	89
Figure IV. 21. Importation des librairies	89
Figure IV. 22. Construction du modèle avec EfficientNet	90
Figure IV. 23. Description avec le modèle EfficientNet	90
Figure IV. 24. Compilation du modèle avec EfficientNet	91
Figure IV. 25. Entraînement du modèle avec EfficientNet	91
Figure IV. 26. Prédiction avec EfficientNet	91
Figure IV. 27. Courbe ROC avec EfficientNet	92
Figure IV. 28. Matrice de confusion avec EfficientNet	92
Figure IV. 29. Rapport de classification avec EfficientNet	93
Figure IV. 30. Importation des librairies	94
Figure IV. 31. Importation du modèle choisi	94
Figure IV. 32. Configuration des paramètres pour exécuter sur hugging face	95

Figure IV. 33. Entrainement sur hugging face	95
Figure IV. 34. Node Js (nodejs.org s.d.)	96
Figure IV. 35. Installation de reactJS	96
Figure IV. 36. Création d'un projet reactJS	97
Figure IV. 37. Présentation de la structure du projet avec React	97
Figure IV. 38. Interface client	97

LISTE DES TABLEAUX

Tableau I. 1. Exemples de données non étiquetées et problèmes d'étiquetage (Azencot s. d.)	23
Tableau I. 2. Avantage et inconvénient d'une machine à vecteur de support (Azencot s. d.).....	26
Tableau I. 3. Avantage et inconvénient de K-plus proche voisin (Azencot s. d.)	27
Tableau I. 4. Avantage et inconvénient d'une forêt aléatoire (Azencot s. d.).....	29
Tableau I. 5. Avantage et inconvénient d'un CNN (Azencot s. d.).....	32
Tableau I. 6. Types courants de tumeurs cérébrales primaires (Ali-Osman 2002)....	43
Tableau III. 1. Ressource matérielle micro-ordinateur	63
Tableau III. 2. Ressource matérielle (équipement réseau).....	63
Tableau IV. 1 Faisabilité économiques.....	98
Tableau IV. 2. Faisabilité technique	99

LISTE DES ABREVIATIONS

ANN : Artificial Neural Network

CNN : Convolutional Neural Network

DL : Deep Learning

FP : false positive

FN : False Negative

IA : Intelligence Artificielle

IRM : Imagerie par Résonnance Magnétique

ML : Machine Learning

RNN : Recurrent Neural Network

TDM : Tomodensitométrie

TN : True Negative

TP : True Positive

TC : Tumeur Cérébrale

INTRODUCTION GENERALE

1.1. Contexte générale de la recherche

La recherche sur l'intelligence artificielle et la détection précoce des tumeurs cérébrales à partir d'images radiologiques par l'apprentissage profond est un domaine très prometteur de la médecine et de l'informatique. Cette approche utilise des techniques avancées d'apprentissage automatique pour analyser et interpréter les images radiologiques du cerveau, ce qui peut aider les spécialistes à fournir une prise en charge rapide pour des tumeurs détectées précocement.

Au Cameroun, comme dans de nombreux autres pays, la détection précoce des tumeurs cérébrales est un défi majeur en raison du manque d'experts médicaux spécialisés, ressources limitées et le processus de détection traditionnel est un processus très complexe qui implique la prise en compte de plusieurs paramètres afin de poser un diagnostic précis. Toutefois, ce processus peut de plusieurs manières être sujet de nombreuses erreurs et altérer le résultat d'un diagnostic précis de façons considérable. Pour réduire donc ces erreurs.

L'utilisation des algorithmes d'intelligence artificielle dans ce domaine permet d'exploiter des motifs et caractéristique contenu dans les images cérébrales afin d'évaluer les risques et prédire la présence de tumeur. Cette approche permet de détecter précocement la présence de tumeur et peut contribuer à combler des lacunes tout en offrant une méthode de dépistage plus précise, efficiente et optimiser la prise en charge des patients. Et cela va permettre également aux professionnels de la santé des informations précieuses et des outils d'aide à la décision

1.2. Problématique de la recherche

1.2.1. Présentation du problème

Le diagnostic précoce des tumeurs cérébrales est un processus relativement difficile car plusieurs processus diagnostiques sont appliqués pour détecter la maladie. Ceci rend le processus d'interprétation des résultats long. il existe également des similitudes entre les images radiologiques des tumeurs et d'autres maladies du cerveau, ce qui peut conduire à des erreurs de diagnostic. Le problème qui se pose est de déterminer comment établir un diagnostic rapide, efficient et précoce.

L'application des techniques d'intelligence artificielle dans le domaine de l'imagerie médicale a permis le développement de logiciels de détection par la segmentation d'image, l'extraction de texture et de forme, et les procédures de classification pour diagnostiquer les tumeurs cérébrales à partir des images radiographie cérébrales.

1.2.2. Formulation du problème

La détection précoce des tumeurs cérébrales est d'une importance cruciale pour améliorer les résultats cliniques et la survie des patients. Cependant, au Cameroun, comme dans de nombreux pays, ce processus peut être entravé par divers facteurs, tels que le manque d'experts médicaux spécialisés et des ressources limitées. Pour ce faire, nous vous conseillons de répondre à la question suivante :

Comment améliorer la détection précoce des tumeurs cérébrales grâce à l'intelligence artificielle, plus précisément l'apprentissage profond appliqué à l'imagerie cérébrale ?

Cette question va nous permettre dans notre étude de répondre plus spécifiquement aux questions suivantes ;

- Quels sont les algorithmes de classification utilisé en apprentissage profond ?
- Quel sera le modèle algorithmique choisi le plus performant en termes de précision parmi les modèles du pour la détection des tumeur cérébrales ?

- Comment rendre le modèle choisi accessible afin de faciliter son adoption par les professionnels de la santé ?

1.3. Hypothèse de la recherche

1.3.1. Hypothèse générale

En utilisant des techniques d'intelligence artificielle basées sur l'apprentissage profond et en adaptant les modèles choisis de notre algorithme aux spécificités du contexte camerounais, il est possible d'améliorer de manière significative la détection précoce des tumeurs cérébrales à partir d'images radiologiques au Cameroun.

1.3.2. Hypothèses spécifiques

Partant de notre hypothèse générale, nous dirons plus spécifiquement que :

- **Hypothèse 1** : Il existe des algorithmes de classification en apprentissage profond pour le diagnostic des tumeurs cérébrales à partir d'image radiologique du cerveau. En adaptant les algorithmes d'apprentissage profond aux caractéristiques spécifiques des images radiologiques, il est possible d'améliorer la sensibilité et la spécificité de la détection des tumeurs cérébrales, conduisant à un taux de détection précoce plus élevé.
- **Hypothèse 2** : Le meilleur modèle de classification en apprentissage profond pour la détection des tumeurs cérébrales est identifié, démontrant une meilleure capacité à détecter les premiers signes de la tumeur.
- **Hypothèse 3** : Grâce à l'existence et la performance du nuage informatique, cela facilite l'accessibilité rapide de notre modèle ainsi que son adoption par les personnels de sante à travers des plateformes tel que par ordinateur et téléphone mobile

1.4. Objectif de la recherche

1.4.1. Objectif générale de la recherche

L'objectif de notre travail est d'explorer les possibilités offertes par l'intelligence artificielle et l'apprentissage profond pour améliorer la détection précoce des tumeurs cérébrales à partir d'images radiologiques. Il sera donc question pour nous de développer des méthodes et des modèles d'intelligence artificielle adaptés aux caractéristiques souhaitées, en tenant compte des contraintes de ressources limitées et du manque de données annotées, afin de fournir un outil de diagnostic précis, rapide et accessible par des spécialistes du domaine pour les patients atteints de tumeurs cérébrales au Cameroun. Et cela permettra ainsi d'améliorer les résultats cliniques, d'optimiser les chances de traitement réussi et de contribuer à une réduction de la morbidité et de la mortalité associées aux tumeurs cérébrales dans le pays.

1.4.2. Objectifs spécifiques de la recherche

Nous dirons plus spécifiquement que nos objectifs de recherches sont :

- Étudier les algorithmes de classification en apprentissage profond plus particulièrement parmi les réseaux neuronaux convolutif (CNN) pour diagnostiquer la tuberculose pulmonaire à l'aide d'images radiologiques.
- Déterminer le modèle le plus performant pour la détection précoce des tumeurs cérébrales combiné à de l'apprentissage par transfert en montrant. Cette étape se concentrera sur leur précision, leur sensibilité et leur spécificité relatives.
- Examiner le meilleur moyen de déploiement du modèle choisi afin qu'il puisse être disponible et accessible. Ceci facilitera son adoption par les personnels de santé

Ces objectifs spécifiques permettront d'orienter la recherche et de concentrer les efforts sur des aspects clés de l'utilisation de l'intelligence artificielle et de l'apprentissage profond pour la détection précoce des tumeurs cérébrales à partir d'images radiologiques.

1.5. Justification de la recherche

1.5.1. Sur le plan scientifique

L'IA et l'application de l'apprentissage profond sur des d'images radiologiques du Cameroun présente plusieurs justifications sur le plan scientifique tel que :

- Avancement de la technologie : L'intelligence artificielle et l'apprentissage profond offrent des possibilités innovantes pour améliorer la détection précoce des tumeurs cérébrales. Cette recherche contribuera à l'avancement des connaissances et des techniques dans ce domaine en développant des modèles spécifiquement adaptés au contexte camerounais.
- Amélioration des résultats cliniques : La détection précoce des tumeurs cérébrales est cruciale pour améliorer les résultats cliniques et les chances de survie des patients. En développant des méthodes plus précises et rapides basées sur l'intelligence artificielle, cette recherche vise à améliorer les taux de détection précoce, facilitant ainsi un traitement plus rapide et plus efficace.
- Réduction des erreurs de diagnostic : L'interprétation des images radiologiques pour détecter les tumeurs cérébrales peut être sujette à des erreurs humaines et à des variations d'expertise. L'utilisation de l'intelligence artificielle peut aider à réduire les erreurs de diagnostic en fournissant une assistance et une précision supplémentaires aux radiologues et aux neurologues.
- Adaptation aux spécificités régionales : Le développement de modèles d'apprentissage profond adaptés au contexte camerounais prendra en compte les caractéristiques régionales des tumeurs cérébrales et des images radiologiques, permettant une détection plus précise et spécifique aux besoins de la population camerounaise.

1.5.2. Sur le plan pratique

Sur le plan pratique, notre travail présente plusieurs avantages tel que :

- Amélioration de la détection précoce : La détection précoce des tumeurs cérébrales est essentielle pour un traitement efficace et des résultats cliniques favorables. En développant des méthodes basées sur l'intelligence artificielle et l'apprentissage profond, cette recherche vise à améliorer la sensibilité et la spécificité des techniques de détection, ce qui permettra d'identifier les tumeurs cérébrales à un stade plus précoce et d'initier un traitement approprié plus tôt.
- Réduction des délais de diagnostic : Les systèmes d'intelligence artificielle entraînés à détecter les tumeurs cérébrales peuvent analyser les images radiologiques de manière plus rapide et efficace que les méthodes traditionnelles d'interprétation humaine. Cela permettra de réduire les délais de diagnostic, permettant aux patients d'obtenir rapidement les soins nécessaires et de commencer leur traitement plus tôt.
- Assistance aux professionnels de la santé : L'utilisation de l'intelligence artificielle pour la détection précoce des tumeurs cérébrales peut servir d'outil d'aide à la décision pour les radiologues et les neurologues au Cameroun. Les modèles d'apprentissage profond peuvent fournir des analyses et des suggestions précieuses, permettant aux professionnels de la santé de prendre des décisions plus éclairées et de fournir des soins plus efficaces.
- Accessibilité aux régions éloignées : Le Cameroun, comme de nombreux autres pays, fait face à des disparités d'accès aux soins de santé, en particulier dans les régions éloignées. L'utilisation de systèmes d'intelligence artificielle embarqués et adaptés aux ressources limitées peut contribuer à améliorer l'accessibilité aux services de détection précoce des tumeurs cérébrales, en permettant des diagnostics sur place dans des zones qui autrement auraient peu ou pas accès à des installations médicales spécialisées.
- Réduction des coûts de santé : Une détection précoce des tumeurs cérébrales permet non seulement d'améliorer les résultats cliniques, mais aussi de réduire les coûts associés aux traitements avancés et aux interventions chirurgicales plus invasives. En identifiant les tumeurs cérébrales à un stade précoce, les

ressources peuvent être utilisées de manière plus efficace, évitant des traitements plus coûteux et améliorant la gestion globale des ressources de santé.

- Formation et soutien aux professionnels de la santé : Cette recherche offre également la possibilité de former les professionnels de la santé camerounais à l'utilisation des techniques d'intelligence artificielle et d'apprentissage profond pour la détection des tumeurs cérébrales. Cela renforce les compétences des professionnels de la santé locaux et leur capacité à utiliser les technologies émergentes pour améliorer la prise en charge des patients.

1.6. Délimitation de la recherche

1.6.1. Sur le plan géographique

La recherche sur notre travail se concentre spécifiquement sur le contexte géographique du Cameroun. La délimitation géographique de cette recherche est donc le territoire du Cameroun. Cela implique de prendre en compte les spécificités des images radiologiques camerounaises, les caractéristiques des tumeurs cérébrales dans cette population, les contraintes et les ressources disponibles dans le système de santé camerounais.

Les données utilisées pour entraîner et tester les modèles d'apprentissage profond seront principalement des données radiologiques provenant du site de kaggle, afin de garantir la pertinence et la validité des résultats. Il convient de noter que cette délimitation géographique n'exclut pas la possibilité d'échanges et de références à des travaux de recherche, des méthodologies et des résultats provenant d'autres pays ou régions, qui peuvent enrichir l'étude et fournir un contexte plus large pour l'analyse comparative. Cependant, l'accent principal sera mis sur les spécificités et les défis liés à la détection précoce des tumeurs cérébrales dans le contexte spécifique du Cameroun.

1.6.2. Sur le plan théorique

Sur le plan théorique, notre recherche se concentre sur l'utilisation de techniques avancées d'apprentissage automatique pour améliorer la détection précoce et la précision du diagnostic des tumeurs cérébrales. Cette recherche se base sur des théories et concepts tels que :

- Apprentissage profond : La recherche se concentrera sur l'utilisation de techniques d'apprentissage profond, telles que les réseaux de neurones convolutifs (CNN), pour analyser les images radiologiques et détecter les tumeurs cérébrales. L'étude se basera sur les fondements théoriques de l'apprentissage profond, y compris l'architecture des réseaux de neurones, les méthodes d'entraînement et de validation des modèles, et les principes de transfert d'apprentissage.
- Imagerie médicale : La recherche se concentre spécifiquement sur l'utilisation d'images radiologiques pour la détection précoce des tumeurs cérébrales. Les concepts théoriques liés à l'imagerie médicale, tels que les différentes modalités d'imagerie (IRM, TDM, etc.), les techniques d'acquisition d'images, la segmentation des structures anatomiques et les caractéristiques radiologiques des tumeurs cérébrales, seront pris en compte.
- Détection précoce des tumeurs cérébrales : La recherche mettra l'accent sur la détection précoce des tumeurs cérébrales à partir des images radiologiques. Cela implique de comprendre les signes précoces et les caractéristiques radiologiques spécifiques des tumeurs cérébrales, ainsi que les défis et les limitations associés à la détection précoce dans le contexte camerounais.
- Intelligence artificielle : La recherche se fonde sur les principes théoriques de l'intelligence artificielle, en particulier dans le domaine de la vision par ordinateur et de l'analyse d'images. Cela comprend la compréhension des concepts fondamentaux tels que l'apprentissage automatique, la classification, la régression et l'utilisation de réseaux de neurones profonds pour résoudre des problèmes spécifiques de détection de tumeurs cérébrales.
- Contexte camerounais : La recherche prendra en compte les spécificités du contexte camerounais, y compris les caractéristiques démographiques, les ressources médicales limitées, les contraintes économiques et les facteurs

socio-culturels. La compréhension du contexte théorique permettra d'adapter les méthodes d'intelligence artificielle aux besoins et aux contraintes spécifiques du Cameroun.

1.6.3. Sur le plan thématique

Sur le plan thématique notre travail comprend les aspects suivants :

- Détection précoce des tumeurs cérébrales : La recherche se concentre spécifiquement sur la détection précoce des tumeurs cérébrales, c'est-à-dire la capacité à identifier et à diagnostiquer les tumeurs cérébrales à un stade précoce à partir d'images radiologiques. Cela inclut la détection de différents types de tumeurs cérébrales telles que les gliomes, les méningiomes, les astrocytomes, etc.
- Intelligence Artificielle et apprentissage profond : La recherche explore l'utilisation de l'intelligence artificielle et de l'apprentissage profond, en particulier des réseaux de neurones convolutifs (CNN), pour analyser les images radiologiques et automatiser le processus de détection des tumeurs cérébrales. Les techniques d'apprentissage profond sont utilisées pour extraire des caractéristiques pertinentes à partir des images et pour entraîner des modèles capables de classer les tumeurs cérébrales.
- Images radiologiques : La recherche se base sur l'utilisation d'images radiologiques, telles que les images d'IRM (Imagerie par Résonance Magnétique) et de TDM (Tomodensitométrie), pour la détection des tumeurs cérébrales. Les caractéristiques spécifiques de ces images, telles que la résolution, les séquences d'acquisition et les propriétés anatomiques, seront prises en compte dans l'analyse et le développement des méthodes d'apprentissage automatique.
- Contexte du Cameroun : La recherche se concentre sur le cas spécifique du Cameroun, prenant en considération les spécificités du contexte camerounais, telles que les ressources médicales limitées, les caractéristiques épidémiologiques des tumeurs cérébrales dans la population camerounaise, les contraintes financières et les disparités régionales en matière d'accès aux soins de santé.

- Évaluation des performances : La recherche inclut une évaluation rigoureuse des performances des modèles d'apprentissage profond développés. Cela peut inclure l'utilisation de métriques telles que la sensibilité, matrice de confusion, la spécificité, la précision et la courbe **ROC (Receiver Operating Characteristic)** pour évaluer l'efficacité et la précision de la détection des tumeurs cérébrales.

CHAPITRE I : CADRE THEORIQUE ET CONCEPTUEL

Introduction

Dans la médecine, l'IA offre des nouvelles possibilités d'améliorer le diagnostic et les soins aux patients. Ce chapitre se penche sur l'histoire de l'IA et une compréhension détaillée de l'état de l'art, du cadre théorique sous-jacent et des recherches antérieures qui ont jeté les bases de cette avancée cruciale. Nous examinerons en profondeur dans un premier temps, les recherches antérieures dans le domaine de l'IA, les sous domaines de l'IA c'est-à-dire apprentissage automatique et profond ainsi que leur évolution au cours du temps, couvrant à la fois les approches traditionnelles et les premières tentatives d'utilisation de l'intelligence artificielle. Ensuite nous examinerons les généralités sur les tumeurs cérébrales ainsi que leurs différents types et comment ils se forment. Cet examen de la littérature nous permettra de présenter une vue d'ensemble des avancées ce qui a conduit au contexte du fondements de notre étude.

Le cadre théorique est une étape importante de notre recherche car il nous permet d'examiner les principes de l'apprentissage profond, en mettant l'accent sur les réseaux neuronaux convolutifs, la pierre angulaire de notre solution

I.1. Histoire de l'IA

Dans cette partie de notre travail nous allons définir et donner des généralités qui vont englober tous les aspects compris dans notre travail.

I.1.1. Histoire de l'Intelligence Artificielle

L'intelligence artificielle (IA) est une discipline jeune de soixante ans qui combine des sciences, des théories et des techniques (comme la logique mathématique, les statistiques, les probabilités, la neurobiologie computationnelle et l'informatique) dans le but d'imiter les capacités cognitives d'un être humain. Ses progrès ont été liés à ceux de l'informatique et ont conduit les ordinateurs à réaliser des tâches de plus en plus complexes, qui ne pouvaient être auparavant que confiées à un humain.

Cependant, cette automatisation n'est pas considérée comme une intelligence humaine au sens strict, ce qui peut être critique pour certains spécialistes. Les réalisations actuelles (des IA « faibles » ou « modérées », extrêmement performantes dans leur domaine d'entraînement) ne sont absolument pas comparables au stade ultime de leurs recherches (une IA « forte », c'est-à-dire en capacité de contextualiser de manière totalement autonome des problèmes spécialisés très différents). Pour être en mesure de modéliser le monde dans son ensemble, l'IA « forte », qui ne s'est encore matérialisée qu'en science-fiction, nécessiterait des progrès en recherche fondamentale (et non de simples améliorations de performance).




Figure I. 1. Premier calculateur (wikipedia.org s.d.)^a

a. https://fr.wikipedia.org/wiki/premier_calculateur

- **1940-1960 : Naissance de l'IA dans le sillage de la cybernétique**

Entre 1940 et 1960, la période a été fortement marquée par la conjonction de développements technologiques (dont la seconde guerre mondiale a été un accélérateur) et la volonté de comprendre comment faire se rejoindre le fonctionnement des machines et des êtres organiques. **Norbert Wiener**, pionnier de la cybernétique, avait pour objectif d'unifier la théorie mathématique, électronique et automatisation en tant que « théorie entière de la commande et de la communication, aussi bien chez l'animal que dans la machine ». Dès **1943**, **Warren McCulloch** et **Walter Pitts** avaient créé un premier modèle mathématique et informatique du neurone biologique (neurone formel).

John Von Neumann et **Alan Turing** ont été les pères fondateurs de la logique binaire (qui utilise l'algèbre booléenne pour traiter des chaînes plus ou moins importantes de 0 ou de 1) au début du 1950, bien qu'ils n'aient pas inventé le terme d'IA. Les deux chercheurs ont ainsi formalisé l'architecture de nos ordinateurs modernes et démontré qu'ils étaient une machine universelle capable d'exécuter ce qu'on lui programme. Dans son article de **1950** « *Computing Machinery and Intelligence* », **Turing** a posé la question de l'intelligence potentielle d'une machine et a décrit un "jeu de l'imitation" dans lequel un individu devrait pouvoir déterminer s'il parle avec une machine ou un homme en utilisant un téléscripteur. Cet article, bien que controversé (ce "test de Turing" n'apparaît pas qualifiant pour de nombreux experts), sera souvent cité comme étant à l'origine du débat sur la frontière entre l'humain et la machine.

John McCarthy du MIT (Massachusetts Institute of Technology) est connu pour avoir inventé le terme « IA », qui, selon **Marvin Minsky** de l'université de Carnegie-Mellon, signifie « *la construction de programmes informatiques qui s'adonnent à des tâches qui sont actuellement accomplies de manière plus satisfaisante par les êtres humains* » car elles demandent des processus mentaux de haut niveau tels que l'apprentissage perceptuel, l'organisation de la mémoire. La discipline est considérée comme ayant été fondée par la conférence qui a eu lieu pendant l'été **1956** au Dartmouth College, financée par le Rockefeller Institute. Il convient de souligner le grand succès d'estime de ce qui n'était pas une conférence mais plutôt un atelier de

travail, de manière anecdotique. Tout au long de ces travaux (qui s'appuyaient essentiellement sur des développements basés sur de la logique formelle), seuls six personnes, dont McCarthy et Minsky, étaient restées présentes de manière constante.

Bien que l'économiste et sociologue **Herbert Simon** ait prédestiné en **1957** que l'IA serait capable de battre un humain aux échecs dans les 10 années qui suivraient, l'IA a finalement commencé à fonctionner. Cependant, la vision de **Simon** sera véridique 30 ans après.

- **1980-1990 : Les systèmes experts**

En 1968, **Stanley Kubrick** mettra en scène "2001 l'Odyssée de l'espace" dans lequel un ordinateur nommé HAL 9000, qui n'est qu'une lettre derrière celle d'IBM, résume toutes les questions éthiques posées par l'IA. Après avoir atteint un niveau élevé de sophistication, cela sera-t-il bénéfique ou préjudiciable à l'humanité ? Bien que l'impact du film ne soit pas scientifique, il contribuera à vulgariser le thème, tout comme **Philip K. Dick**, l'écrivain de science-fiction, qui ne cesse de s'interroger si, un jour, les machines éprouveront des émotions. L'IA est entrée dans l'âge d'or des systèmes experts avec l'avènement des premiers microprocesseurs fin 1970.

Dès 1965, le MIT avait ouvert la voie avec DENDRAL, un système expert spécialisé dans la chimie moléculaire, et MYCIN, un système spécialisé dans le diagnostic des maladies du sang et la prescription de médicaments, à l'université de Stanford. Ces systèmes étaient basés sur un "moteur d'inférence", qui était conçu pour être un reflet logique de la pensée humaine. Le moteur fournissait ainsi des réponses expertes en entrant des données.

Bien que les engagements prévoient un développement important, l'enthousiasme diminuera à nouveau fin 1980 et début 1990. La programmation de telles connaissances demandait en réalité beaucoup d'efforts, et à partir de 200 à 300 règles, il y avait un effet "boîte noire" où l'on ne savait plus comment la machine raisonnait. En conséquence, la mise au point et la maintenance devenaient extrêmement difficiles et, surtout, on arrivait à les faire plus rapidement et d'autres manières moins complexes et moins chères. Il est important de se rappeler que dans les années 1990, le terme « intelligence artificielle » était presque devenu tabou et des dénominations

plus discrètes comme « informatique avancée » étaient même entrées dans le langage universitaire.

Le triomphe de Deep Blue (un système expert d'IBM) face à **Garry Kasparov** en mai 1997 confirmera la prophétie de 1957 d'Herbert Simon, mais ne permettra pas de soutenir les financements et les avancées de cette forme d'IA. En effet, Deep Blue utilisait un algorithme de force brute systématique qui évaluait et pondérait tous les coups potentiels. Bien que la défaite de l'humain ait été considérée comme symbolique dans l'histoire, Deep Blue n'avait réussi à comprendre qu'un domaine très restreint (celui des règles du jeu d'échec), bien loin de la capacité à représenter la complexité du monde.

- **Depuis 2010, une nouvelle expansion des données massives et une nouvelle capacité de calcul ont vu le jour.**

En 2010, la discipline a connu un nouvel essor grâce à deux raisons.

- a. Pour commencer, accéder à un grand volume de données. Il fallait auparavant réaliser soi-même un échantillonnage pour pouvoir utiliser des algorithmes de classification d'image et de reconnaissance d'un chat, par exemple. Aujourd'hui, des millions peuvent être trouvés en effectuant une simple recherche sur Google.
- b. Après cela, la découverte de la très grande efficacité des processeurs de cartes graphiques des ordinateurs pour accélérer le calcul des algorithmes d'apprentissage. Cela pouvait prendre des semaines avant 2010 pour traiter l'intégralité d'un échantillon, car le processus est très itératif. La capacité de calcul de ces cartes, qui peuvent effectuer plus de mille milliards d'opérations par seconde, a connu un grand développement malgré un coût financier limité (moins de 1000 euros par carte).

Il y a eu quelques succès publics importants grâce à cette nouvelle industrie technologique, qui a également relancé les financements. En 2011, Watson, l'IA d'IBM, a remporté les parties contre deux champions du « Jeopardy! ». Google X, le laboratoire de recherche de Google, parviendra à reconnaître des chats sur une vidéo en 2012. Cette dernière tâche nécessite plus de 16 000 processeurs, mais le potentiel est alors extraordinaire : une machine arrive à apprendre à distinguer quelque

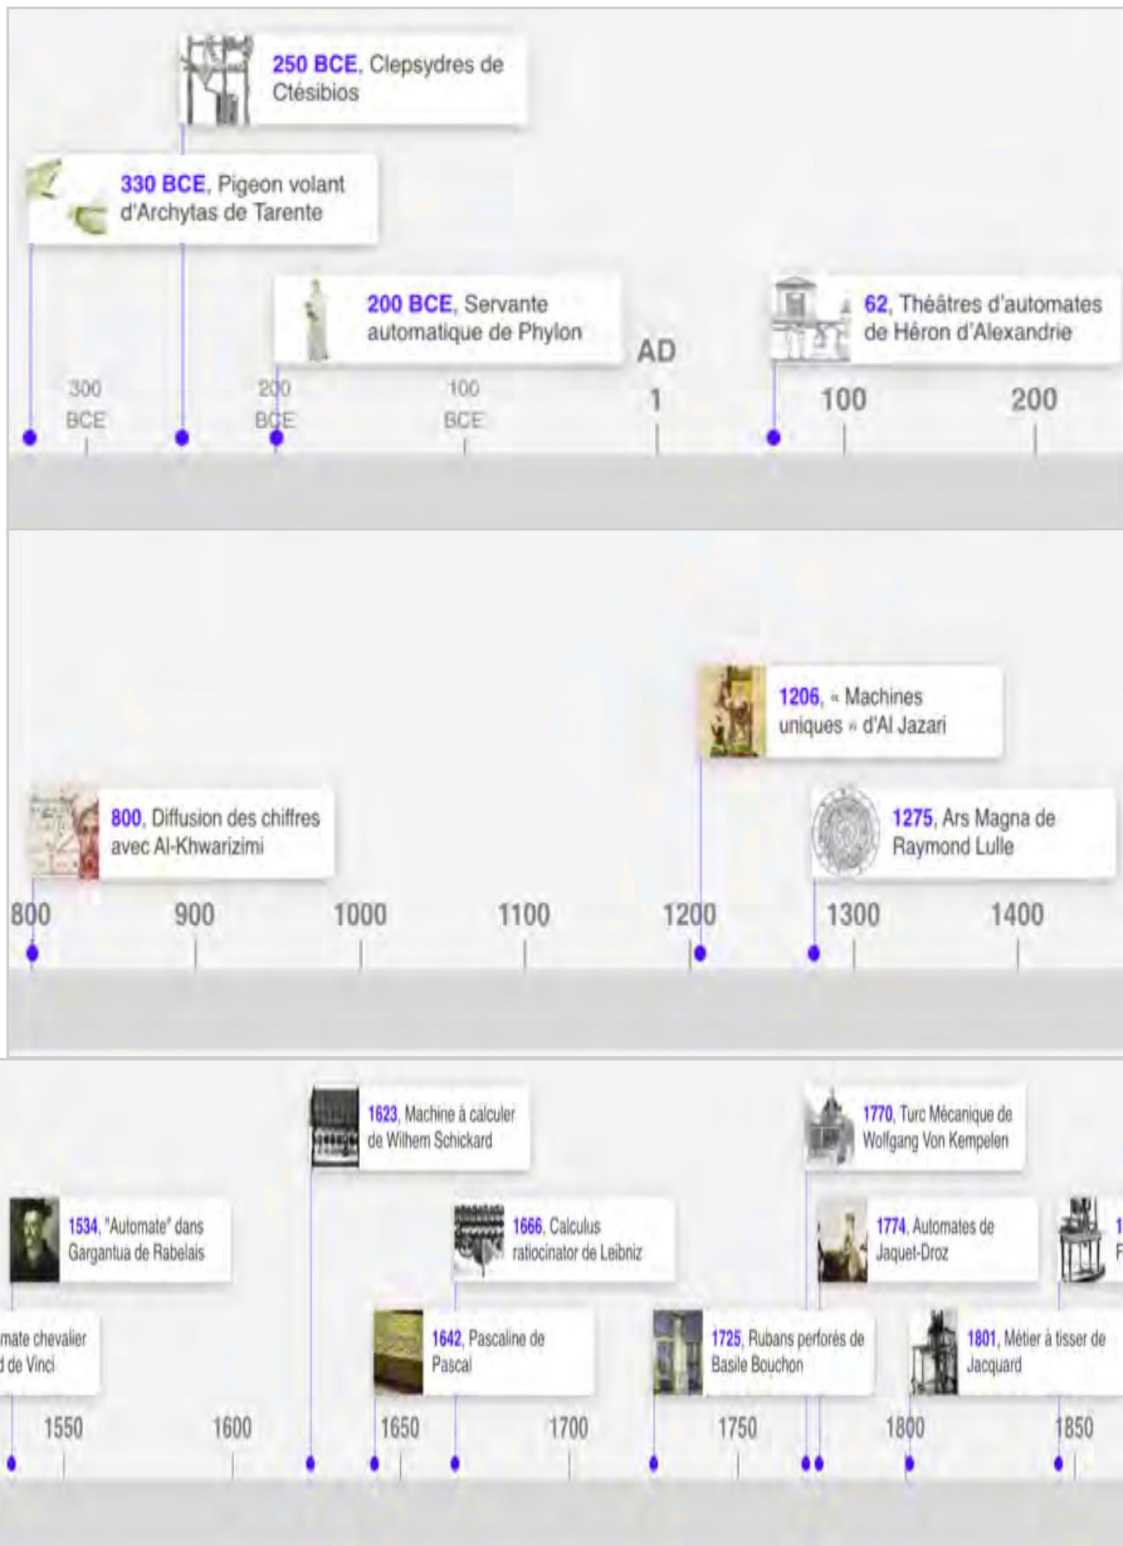
chose. AlphaGO, une IA de Google spécialisée dans le jeu de Go, va vaincre le champion d'Europe Fan Hui et le champion du monde **Lee Sedol** en 2016, avant de devenir elle-même AlphaGo Zero. Assurez-vous que la combinatoire du jeu de Go est plus importante que les échecs (égale au nombre de particules dans l'univers) et qu'il est impossible d'obtenir des résultats aussi importants en force brute (comme ceux de Deep Blue en 1997).

Ceci a été possible grâce à un changement de paradigme complet par rapport aux systèmes experts. L'approche est devenue inductive : il ne s'agit plus de coder les règles comme pour les systèmes experts, mais de laisser les ordinateurs les découvrir seuls, sur la base d'une quantité massive de données, en utilisant la corrélation et la classification.

L'apprentissage machine profond semble être la méthode la plus prometteuse pour de nombreuses applications, telles que la reconnaissance de vocale ou d'images. Dès 2003, **Geoffrey Hinton** de l'Université de Toronto, **Yoshua Bengio** de l'Université de Montréal et **Yann LeCun** de l'Université de New York avaient pris la décision de lancer un projet de recherche visant à moderniser les réseaux neuronaux. Des expériences menées simultanément à Microsoft, Google et IBM avec l'aide du laboratoire de Toronto de Hinton ont alors démontré que ce type d'apprentissage pouvait réduire de moitié les taux d'erreurs pour la reconnaissance vocale. L'équipe de reconnaissance d'image Hinton a obtenu des résultats similaires.

Du jour au lendemain, la plupart des équipes de recherche ont adopté cette technologie aux avantages indéniables. Ce type d'apprentissage a également permis des progrès considérables dans la reconnaissance de texte, mais il existe encore beaucoup de chemin à parcourir pour produire des systèmes de compréhension de texte, selon les experts comme **Yann LeCun**. Ce problème est bien illustré par les agents conversationnels : nos smartphones peuvent déjà retranscrire une instruction, mais ils ne peuvent pas la contextualiser complètement et analyser nos intentions.

INTELLIGENCE ARTIFICIELLE ET DETECTION PRECOCE DES TUMEURS CEREBRALES A PARTIR D'IMAGES RADIOLOGIQUES



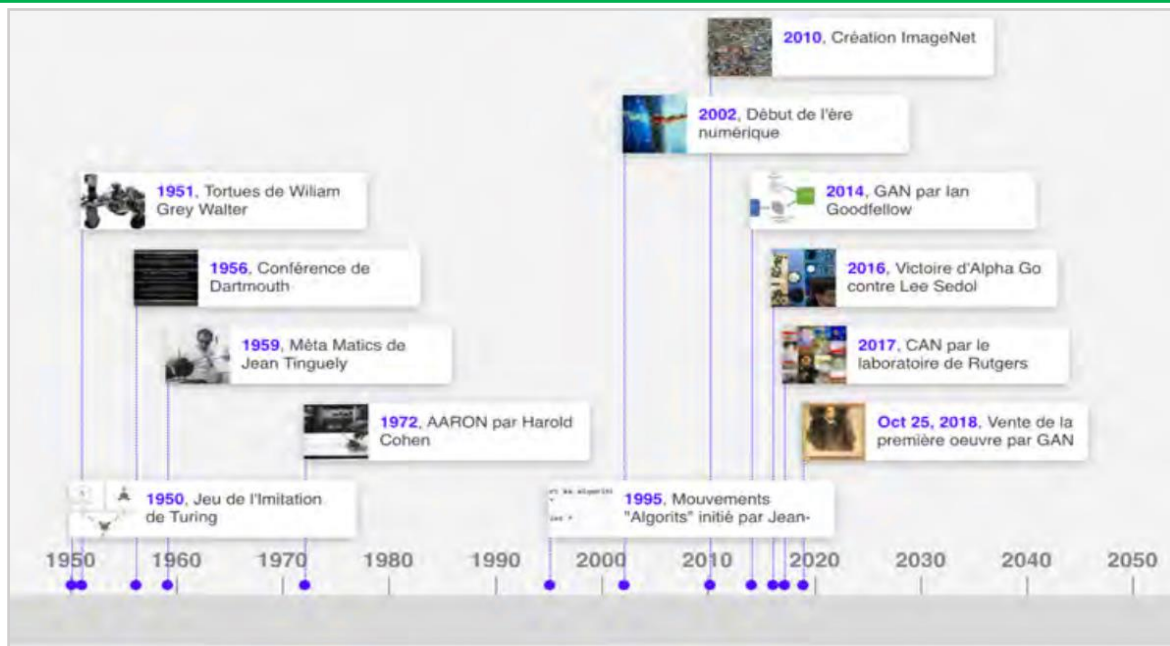


Figure I. 2. Évolution de l'IA (wikipedia.org s.d.)^b

I.2. Définition

I.2.1. Qu'est-ce qu'une Intelligence Artificielle ?

Au cours des années, le concept et la définition de l'IA ont été défini selon plusieurs auteurs comme suit ;

« C'est la construction de programmes informatiques qui s'adonnent à des tâches qui sont actuellement accomplies de manière plus satisfaisante par les êtres humains. » (Selon **Marvin Minsky**)

« C'est la science et l'ingénierie de la création de machines intelligentes, en particulier de programmes informatiques intelligents. La compréhension de l'intelligence humaine à l'aide d'ordinateurs est une tâche similaire, mais l'IA ne doit pas se limiter aux méthodes biologiquement observables. » (Selon **John McCarthy 2004**). De ce fait, l'intelligence artificielle est un domaine de l'informatique qui vise à créer des machines intelligentes en "opposition" à l'intelligence naturelle des êtres vivants. Le terme a beaucoup changé au fil du temps et comprend maintenant toutes les idées visant à permettre à une machine de pouvoir imiter et surpasser les capacités cognitives de l'Homme. Le concept d'intelligence artificielle créé en 1956 par **John McCarthy** suite aux nombreuses recherches menées après la Seconde Guerre mondiale et est l'un de

b. https://fr.wikipedia.org/com/artificial_intelligence_evolution

domaine d'étude les plus récents dans les domaines des sciences et de l'ingénierie. Cela fait suite aux nombreuses inventions au fil des siècles qui ont permis aux machines de calculer que l'hypothèse qu'elles pourraient penser et agir par elles-mêmes aie également vu le jour.

Alan Turing, le père de l'informatique moderne, avait déjà établi un ensemble de conditions à respecter pour pouvoir définir une intelligence artificielle. La version complète du test de Turing comprend six éléments : la capacité de la machine à communiquer, ce qui a ouvert la voie au traitement du langage naturel, la mémorisation des informations, le raisonnement sur ces mêmes informations, l'apprentissage, avec la détection des invariants et l'extrapolation sur des bases de données plus restreintes, la perception et la reconnaissance.

Il est important de savoir que l'important n'est pas de reproduire à la perfection le cheminement de la pensée d'un être humain, mais plutôt d'appréhender les concepts sous-jacents afin de les appliquer pour mettre au point des intelligences artificielles qui ne nous méprennent pas. L'exemple le plus concret est celui de la recherche de la capacité à voler ; de nombreuses personnes ont essayé de reproduire le mouvement des oiseaux à l'aide de créations qui les reproduisaient, mais elles n'ont pas eu beaucoup de succès. Nous avons pu créer des machines capables de parcourir le ciel en s'écartant de cette vision et en adaptant les concepts assimilés aux capacités de l'Homme.

Le but n'était pas de nous transformer en oiseaux, mais plutôt de pouvoir nous déplacer dans l'espace. Nous pensons que le principe est similaire dans la réflexion d'une machine : le but n'est pas de reproduire à la perfection le fonctionnement du cerveau humain, mais plutôt d'adapter les mécanismes qui interviennent aux possibilités des machines que nous construisons.

Les origines de l'intelligence artificielle doivent être étudiées afin de mieux comprendre sa théorie. Les premiers éléments remontent à Socrate, qui a ouvert le domaine de la logique, amenant la tradition logiciste (mathématiques = extension de la logique) pour mettre en place des systèmes intelligents, où il y instaura une qualité importante : L'intelligence artificielle est soumise aux lois de la pensée, c'est-à-dire que la validité des inférences est importante, mais que la capacité de prendre des décisions

même si on ne peut pas déterminer avec certitude laquelle est la meilleure est tout aussi importante. Dans certains cas, il n'est pas nécessaire de dépenser du temps pour prendre la meilleure décision, car certaines décisions rapides sont plus efficaces que celles qui nécessitent du temps de réflexion.

Par conséquent, le terme "agent rationnel" est apparu : il fait référence à une intelligence artificielle capable d'accomplir les mêmes tâches qu'un être humain tout en adoptant un comportement "rationnel". On entend par rationnel qu'il serait capable de prendre des décisions lui permettant d'obtenir le plus de succès possible dans la réalisation des tâches que les hommes lui auraient assignées, et qu'il tendrait donc vers la meilleure solution prévisible. La théorie de la décision, qui combine la théorie des probabilités et de l'utilité, a un impact économique sur le développement de l'intelligence artificielle. Elle fournit un cadre formel complet pour les décisions dans un environnement incertain où les probabilités ont la possibilité d'influencer le preneur de décision. Cela a conduit à la création de modèles de prises de décision basés sur le choix le plus satisfaisant, qui est le plus proche du comportement humain : la maximisation du gain.

1.2.2. Apprentissage automatique (Machine Learning (ML)) (Azencott s. d.)

« L'apprentissage est une modification d'un comportement basée sur une expérience. » (Selon **Fabien Benureau (2015)**)

Une autre définition donnée en ce qui concerne un programme informatique « on parle d'apprentissage automatique, lorsqu'il est capable d'apprendre sans que cette modification ne soit explicitement programmée » (Selon **Arthur Samuel (1959)**). En contraste à un programme classique, on peut ainsi dire qu'un programme d'apprentissage automatique qui utilise les données et les réponses pour créer la procédure permet d'obtenir les premières à partir des premiers instants.


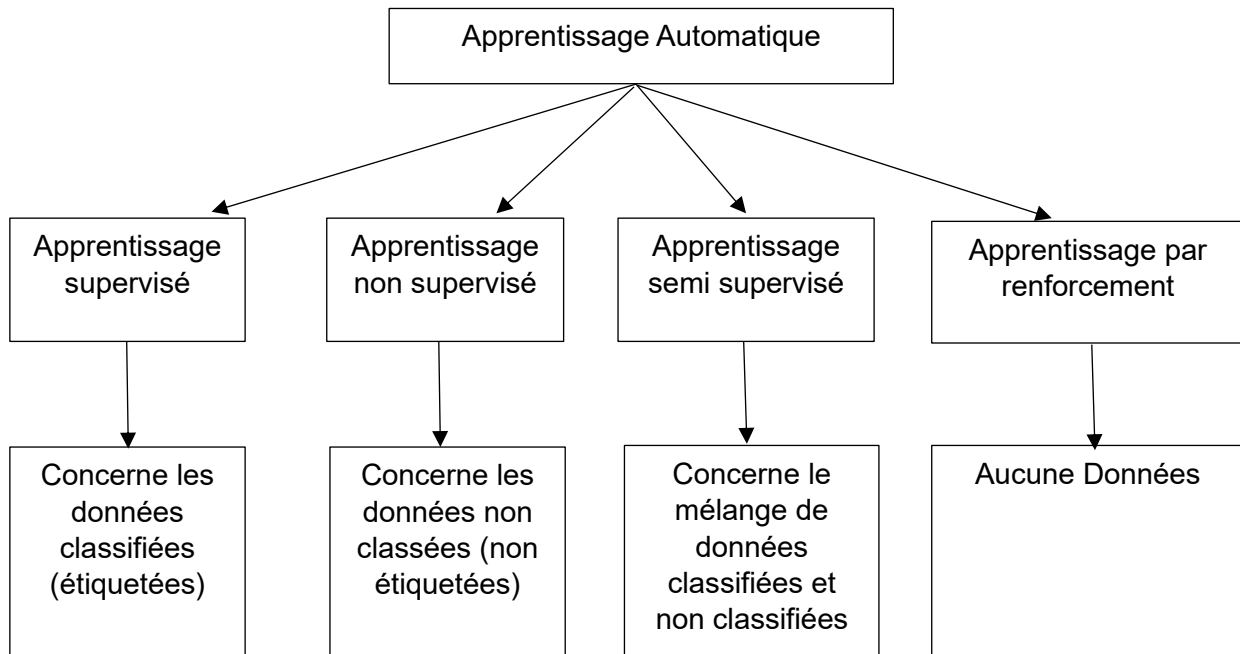


Figure 1. 3. Apprentissage automatique (Azencott s.d.)^c

c. Azencott, Chloé-Agathe. s. d. « Introduction au Machine Learning »

L'Apprentissage automatique encore appelé Machine Learning (en anglais) est un vaste ensemble qui regorge quatre sous type :

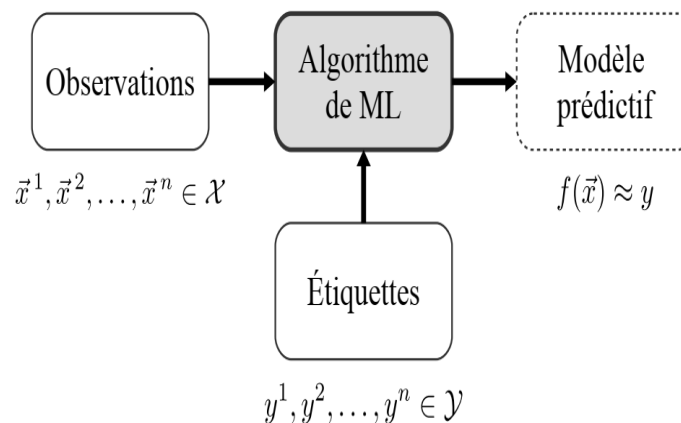


1.2.2.1. L'Apprentissage supervisé

L'objectif de l'apprentissage supervisé est de déduire une fonction ou une cartographie des données d'apprentissage étiquetées. Les données d'apprentissage sont composées d'un vecteur d'entrée X et d'un vecteur de sortie Y qui contiennent des étiquettes ou des annotations. Une étiquette ou une balise du vecteur Y décrit son exemple d'entrée du vecteur d'entrée X . Ils sont un exemple de formation ensemble. En d'autres termes, les exemples sont inclus dans les données d'apprentissage. Si le vecteur d'entrée X n'a pas d'étiquetage, X est une donnée non étiquetée.

Pourquoi s'appelle-t-il apprentissage supervisé ? Chaque exemple de formation dans les données de formation est identifié par un vecteur de sortie Y . Le superviseur fournit ces étiquettes au vecteur de sortie. Ces superviseurs sont généralement des humains, mais ils peuvent également être utilisés par des machines. Bien que les jugements humains soient plus coûteux que les machines, les taux d'erreur plus élevés des données étiquetées par les machines indiquent que les jugements humains sont supérieurs. Une ressource précieuse et fiable pour l'apprentissage supervisé est la donnée étiquetée manuellement. Cependant, les machines peuvent être utilisées pour un étiquetage fiable dans certains cas.

Le plus souvent, l'espace sur lequel sont définies les données est $X = \mathbb{R}^p$.



Deux groupes ou catégories d'algorithmes relèvent de l'apprentissage supervisé. Ils sont les suivants

- La régression
- La classification

Exemple de données non étiquetées	Exemple de jugement pour l'étiquetage	Possible Étiquettes	Possible Superviseur
Tweet	Sentiment de la tweet	Positive / Négative	Homme / machine
Photo	Contient une maison et une voiture	Oui / Non	Homme / machine
Enregistrement audio	Le mot football est altéré	Oui / Non	Homme / machine
Vidéo	Des armes sont-elles utilisées dans la vidéo ?	Violent / Non violent	Homme / machine
Rayon X	Présence d'une tumeur aux rayons X	Présent / Absent	Experts / machine

Tableau I. 1. Exemples de données non étiquetées et problèmes d'étiquetage (Azencot s. d.)

1.2.2.2. L'Apprentissage non supervisé

Nous manquons de superviseurs ou de données de formation dans l'apprentissage non supervisé. En d'autres termes, nous ne possédons que des données non étiquetées. L'objectif ici est de découvrir une structure cachée dans ces informations. Il existe de nombreuses raisons pour lesquelles les données ne sont pas étiquetées. Il peut s'agir d'un manque de ressources pour payer l'étiquetage manuel ou de la nature inhérente des données elles-mêmes.

Les données sont aujourd'hui collectées à un rythme sans précédent grâce aux nombreux dispositifs de collecte de données. Les Big Data sont perçus et jugés en fonction de la variété, de la vitesse et du volume. Il est crucial d'utiliser ces données sans superviseur. C'est le défi que le praticien de l'apprentissage automatique doit relever aujourd'hui.

La situation à laquelle est confronté un praticien de l'apprentissage automatique est en quelque sorte similaire à la scène des *Adventures d'Alice aux pays des merveilles* [5, p. 100], un roman de 1865, où Alice, cherchant à aller quelque part, parle au chat du Cheshire.

Alice parle au chat du Cheshire car elle cherche à aller quelque part.

*... Elle poursuit. "Pourriez-vous me dire, s'il vous plaît,
quel chemin je dois prendre à partir d'ici ?"*

"Cela dépend beaucoup de l'endroit où tu veux aller", dit le chat.

"Je me fiche pas mal de savoir où..." dit Alice.

"Alors le chemin que tu prendras n'a pas d'importance", dit le Chat.

"du moment que j'arrive quelque part", ajouta Alice en guise d'explication.

"Oh, tu es sûre d'y arriver, dit le Chat, si tu marches assez longtemps.

Le regroupement probable (un algorithme d'apprentissage non supervisé) est similaire à l'instruction "marcher suffisamment longtemps" du chat du Cheshire dans la communauté de l'apprentissage automatique. La recherche de régularités dans l'entrée est équivalente au quelque part d'Alice.

1.2.2.3. L'Apprentissage semi supervisé

Les données de ce type d'apprentissage sont une combinaison de données classées et non classées. Un modèle de classification approprié des données est créé à l'aide de cette combinaison de données étiquetées et non étiquetées. Comme indiqué précédemment dans la description de l'apprentissage non supervisé, les données étiquetées sont rares et les données non étiquetées sont abondantes dans la plupart des cas.

- Données non étiquetées fournies par l'environnement. Au début, l'environnement d'un enfant est rempli de données non étiquetées
- Données étiquetées du superviseur. Par exemple, un père apprend à ses enfants les noms (étiquettes) des objets en les pointant du doigt et en prononçant leur nom.

1.2.2.4. L'Apprentissage par renforcement

La méthode d'apprentissage par renforcement vise à prendre des mesures qui maximiseraient la récompense ou minimiseraient le risque en utilisant les observations recueillies lors de l'interaction avec l'environnement.

Les étapes de l'apprentissage par renforcement sont nécessaires pour créer des programmes intelligents (ou agents) :

- Un agent est défini qui observe les états en entrée.
- L'agent est autorisé à effectuer une action en utilisant la fonction de prise de décision.
- L'agent reçoit une récompense ou un renforcement de l'environnement ou un renforcement de l'environnement après avoir effectué l'action.
- Les informations relatives à la récompense sont stockées dans le couple état-action

Les informations stockées permettent d'affiner la politique d'action pour un état particulier, ce qui aide l'agent à prendre des décisions optimales.

1.2.3. Présentation des algorithmes de classification, avantage et inconvénient en Machine Learning (Azencott s. d.)

a) Machine à Vecteur de Support (Support Vector Machine (SVM))

Les SVM sont des algorithmes d'apprentissage automatique supervisé à la fois puissants et adaptables. Ils sont utilisés pour la classification et la régression. Comparées à d'autres méthodes d'apprentissage automatique, les machines à vecteurs de support ont une méthode de mise en œuvre distincte. En raison de leur capacité à traiter plusieurs variables continues et catégorielles, elles sont extrêmement répandues. Le modèle de SVM est essentiellement une représentation de plusieurs classes dans un hyperplan multidimensionnel. La machine à vecteurs de support construit l'hyperplan de manière itérative afin de réduire l'erreur. L'objectif est de

classer les ensembles de données afin d'identifier l'hyperplan marginal le plus grand. Il construit un hyperplan ou un groupe d'hyperplans dans un espace à haute dimension, et l'hyperplan ayant la plus grande distance avec le point de données d'apprentissage le plus proche de n'importe quelle classe permet d'obtenir une excellente séparation entre les deux classes. La puissance réelle de cette approche dépend de la fonction noyau employée. Les noyaux les plus fréquents sont le noyau linéaire, le noyau gaussien et le noyau polynomial.




Figure 1. 4. Illustration Machine à vecteur de support (medium.com s.d.) ^d

Avantage	Inconvénient
Meilleur algorithme lorsque les classes sont séparables	Ne convient pas aux problèmes non linéaires
Non biaisé par les valeurs aberrantes	Lenteur
Non sensible au sur apprentissage	Mauvaises performances avec les classes superposées ;
Performant	La sélection d'hyper paramètres appropriés est importante

Tableau 1. 2. Avantage et inconvénient d'une machine à vecteur de support (Azencot s. d.)

K – Plus proche voisin (K-Nearest Neighbor (KNN))

K-Nearest Neighbor est une approche de classification et de régression non paramétrique. Dans les deux cas, les données d'entrée sont les k exemples d'apprentissage les plus proches dans l'espace des caractéristiques. C'est de loin l'algorithme le plus basique. Il s'agit d'une approche d'apprentissage non paramétrique et paresseuse qui ne fait qu'approximer la fonction localement et reporte le calcul complet jusqu'à l'évaluation de la fonction. Cette technique permet de classer des points de données inconnus en choisissant la classe la plus fréquente parmi les

d. https://www.medium.com/machine_/svm%

k échantillons les plus proches, en se basant uniquement sur la distance entre les vecteurs de caractéristiques. Pour utiliser la classification par k-voisins les plus proches, nous devons d'abord établir une métrique de distance ou une fonction de similarité, les options les plus fréquentes étant la distance euclidienne et la distance de Manhattan. Le résultat est l'appartenance à une classe. Un vote à la pluralité de ses voisins permet de classer un objet, l'objet étant affecté à la classe la plus répandue parmi ses k voisins les plus proches (k est un nombre positif, souvent petit). Si $k = 1$, l'objet est simplement affecté à la classe du plus proche voisin de l'objet. Le plus proche voisin condensé (CNN, l'algorithme de Hart) est une approche de réduction des données pour la classification par K plus proches voisins.

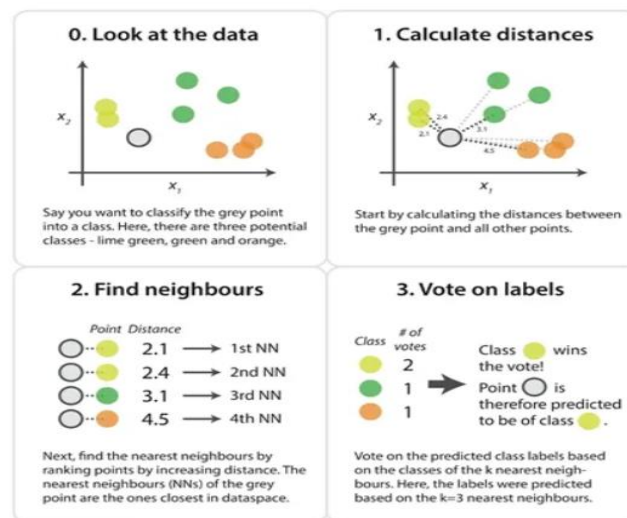


Figure 1.5. Illustration K-plus proche voisin (medium.com s.d.)^e

Avantage	Inconvénient
Simple à comprendre	Lenteur pour les grands ensembles de données
Aucune hypothèse sur les données	Il faut choisir le nombre de voisins "k"
Rapide et efficace	Sensible aux valeurs aberrantes
Modèle en constant évolution	Fonctionne difficilement sur les données non équilibrées

Tableau 1.3. Avantage et inconvénient de K-plus proche voisin (Azencot s. d.)

e. https://www.medium.com/machine_l/k_nearestneighbour%

b) Forêt aléatoire (Random Forest)

La forêt aléatoire est une méthode d'apprentissage supervisée qui peut être utilisée pour la classification et la régression. Comme nous le savons, une forêt est composée d'arbres, et plus il y a d'arbres, plus la forêt est robuste. De la même manière, l'algorithme de la forêt aléatoire génère des arbres de décision sur des échantillons de données, puis reçoit des prédictions de chacun d'entre eux, et enfin vote pour déterminer la meilleure option. Il s'agit d'une approche d'ensemble qui est plus performante qu'un arbre de décision unique, car elle élimine l'ajustement excessif en établissant une moyenne des résultats. La forêt aléatoire est une technique de classification composée de plusieurs arbres de décision. Lors de la création de chaque arbre individuel, il utilise la méthode du sac et la randomisation des caractéristiques pour tenter de produire une forêt d'arbres non corrélés dont les prévisions par comité sont plus précises que celles de n'importe quel arbre individuel.

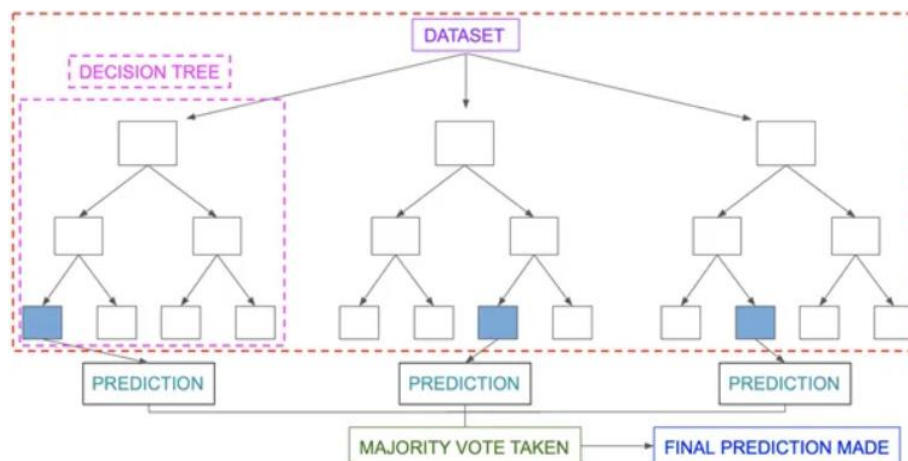


Figure I. 6. Illustration Forêt aléatoire (medium.com s.d.)

Avantage	Inconvénient
Robuste, puissant et précis	Pas d'interprétabilité
Bonne performance sur de nombreux problèmes y compris les non linéaires	Le sur apprentissage peut facilement se produire
Erreur réduite	Les prédictions des arbres doivent être non corrélées
Faible impact des valeurs aberrantes	Apparaît comme une boîte noire : Il est difficile de savoir ce qui se passe

Utile pour extraire l'importance des caractéristiques	Il faut choisir le nombre d'arbres ; Les caractéristiques doivent avoir un certain pouvoir prédictif
Bonne performance sur les ensembles de données déséquilibrées	

Tableau I. 4. Avantage et inconvénient d'une forêt aléatoire (Azencot s. d.)

1.2.4. Apprentissage profond (Deep Learning (DL)) (Mathew, Amudha, et Sivakumari 2021) ¹

De nos jours, l'intelligence artificielle (IA), l'apprentissage machine (ML) et l'apprentissage profond (DL) sont trois termes populaires qui sont parfois utilisés de manière interchangeable pour décrire des systèmes ou des logiciels qui se comportent de manière intelligente. Dans la figure ci-dessous nous illustrons la position qu'occupe l'apprentissage profond comparé à d'autre tel que l'apprentissage automatique et l'intelligence artificielle

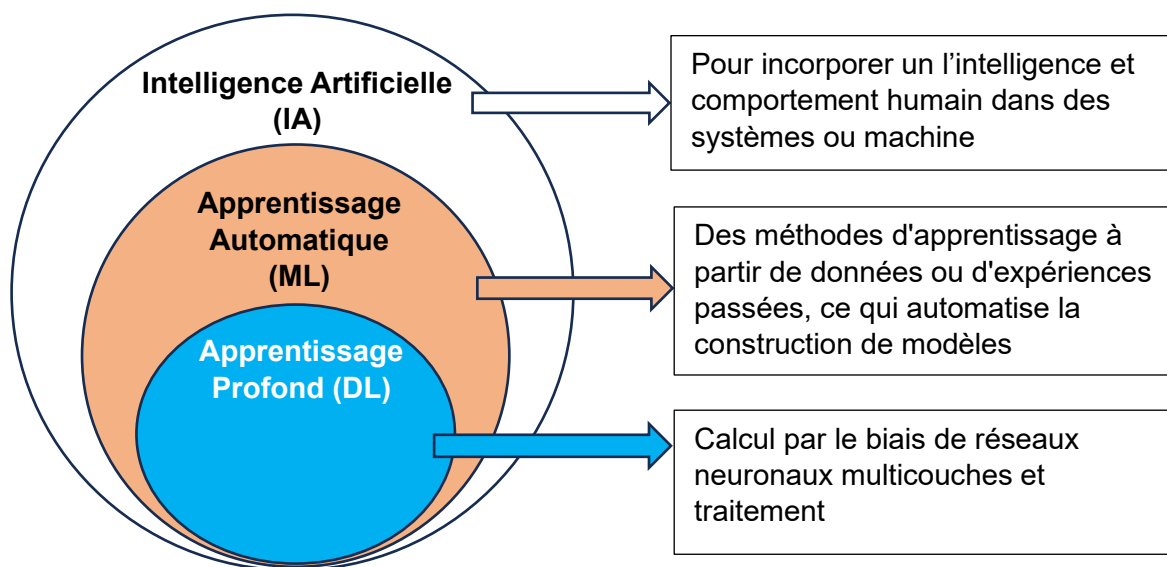


Figure I. 7. Relation entre Deep Learning avec le ML et IA (Mathew et al. 2021)

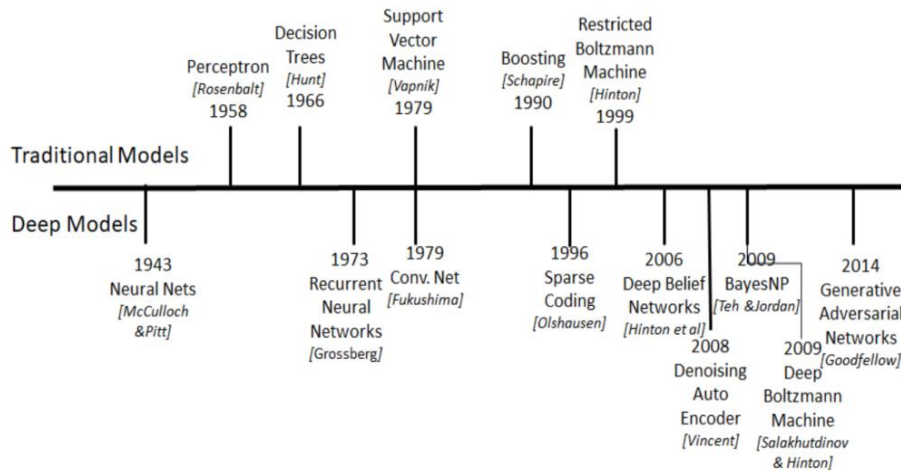
L'apprentissage profond est donc une technique d'apprentissage automatique basées sur l'apprentissage des modèles de données

1.2.3.1. Evolution de l'Apprentissage profond

La première génération de réseaux neuronaux artificiels (Artificial Neural Network (ANN)) était composée de perceptrons en couches neuronales, qui étaient limités dans les calculs. La deuxième génération calculait le taux d'erreur et

1. Mathew et al. - 2021 - Deep Learning Techniques An Overview

rétro-propageait l'erreur. La machine restreinte de Boltzmann a surmonté les limites de la rétropropagation, ce qui a facilité l'apprentissage. Par rapport aux méthodes d'apprentissage traditionnelles, les performances des classificateurs utilisant l'apprentissage profond s'améliorent à grande échelle avec une quantité accrue de données. La chronologie de l'évolution des modèles profonds par rapport aux modèles traditionnels est illustrée à sur la figure suivante.



1.2.3.2. Domaine d'application de l'Apprentissage profond

On retrouve un très vaste secteur dans lequel l'apprentissage profond est appliqué notamment :

- Dans la reconnaissance visuelle, il est utilisé pour la reconnaissance faciale par des caméras. Il est également très utilisé par les voitures autonomes
- Dans le secteur de la robotique, il est utilisé pour automatiser certaines tâches nécessitant une réflexion humaine et une précision accrue
- Dans le secteur de la santé, il est notamment utilisé pour la détection des tumeurs et la prédiction de certaines maladies
- Dans le secteur de la sécurité, il est utilisé pour la reconnaissance vocale
- Dans le secteur de l'éducation, il est utilisé pour la traduction automatique de langues, la synthèse des textes, et pour créer des assistants virtuels

1.2.3.3. Architectures fondamentales de l'Apprentissage profond

- **Réseaux non supervisés pré-entraînés :** Dans les réseaux non supervisés pré-entraînés, un modèle est formé de manière non supervisée, puis le modèle est utilisé pour la prédiction. Quelques sous-types sont des

auto-encodeurs, Deep Belief Network (DBN), Réseaux adverbiaux génératifs (**Generative Adversarial Network (GAN)**)

- **Réseaux neuronaux convolutifs** : Les réseaux neuronaux convolutifs (ou encore **Convolutional Neural Network (CNN)**) sont principalement utilisés pour les images. Il attribue des poids et des biais aux différents objets de l'image et les différencie les uns des autres. Il nécessite moins de prétraitement que les autres algorithmes de classification. Le CNN utilise des filtres pertinents pour capturer les dépendances spatiales et temporelles d'une image. Les différents types de CNN sont LeNet, AlexNet, ResNet, ZFNet, VGGNet
- **Réseaux neuronaux récurrents** : Dans les réseaux neuronaux récurrents (ou encore **Recurrent Neural Network (RNN)**) (RNN), les sorties des états précédents servent d'entrée à l'état actuel. Les couches cachées des RNN peuvent mémoriser des informations. L'état caché est mis à jour en fonction de la sortie générée dans l'état précédent. Le RNN peut être utilisé pour la prédiction de séries temporelles car il peut également se souvenir des entrées précédentes, ce que l'on appelle la mémoire à long et court terme.

1.2.5. Présentation des algorithmes de classification en deep learning, avantage et inconvénient (Azencott s. d.) ²

a) Réseau de neurone convolutif (Convolutional Neural Network (CNN))

Les réseaux neuronaux convolutifs (CNN) sont un type de réseau neuronal multicouche destiné à identifier des motifs visuels directement à partir d'images pixellisées avec peu de prétraitement. Il s'agit d'un type d'architecture de réseau neuronal artificiel. Les réseaux neuronaux convolutifs utilisent certaines des caractéristiques du cortex visuel et ont donc obtenu des résultats de pointe dans les défis de la vision par ordinateur. Les réseaux neuronaux convolutifs sont constitués de deux composants simples : les couches convolutives et les couches de mise en commun. Malgré leur simplicité, il existe une infinité de façons d'assembler ces couches pour répondre à un problème particulier de vision par ordinateur. Les composants des réseaux neuronaux convolutifs, tels que les couches convolutives et de mise en commun, sont très simples à comprendre. L'aspect difficile de l'utilisation

2. Azencott, Chloé-Agathe. s. d. « Introduction au Machine Learning »

des réseaux neuronaux convolutifs dans la réalité consiste à déterminer comment construire des topologies de modèles qui exploitent au mieux ces éléments fondamentaux. Les réseaux neuronaux convolutifs sont très populaires en raison de leur conception ; le plus important est qu'aucune extraction de caractéristiques n'est nécessaire. Le système apprend à effectuer l'extraction des caractéristiques et la notion clé est qu'il utilise la convolution d'images et de filtres pour construire des caractéristiques invariantes qui sont transmises à la couche suivante. Les caractéristiques de la couche suivante sont modifiées à l'aide de différents filtres afin d'obtenir des caractéristiques plus invariantes et plus abstraites, et le processus est répété jusqu'à ce que la caractéristique finale appelé la sortie soit invariante par rapport à l'occlusion.




Figure I. 8 Illustration d'un CNN (medium.com s.d.)

Avantage	Inconvénient
Traitement efficace des images	Exigences de calcul élevées
Taux de précision élevés	Difficultés avec les petits ensembles de données,
Robustesse au bruit	Les CNN nécessitent également de grands ensembles de données pour atteindre des taux de précision élevés
Apprentissage par transfert	Vulnérabilité aux attaques adverses.
Extraction automatisée des caractéristiques.	

Tableau I. 5. Avantage et inconvénient d'un CNN (Azencot s. d.)

1.2.6. Types d'algorithme du réseau de neurone convolutif (Convolutional Neural network (CNN))

- **LeNeT** : L'algorithme LeNet est un CNN de pointe conçu pour reconnaître les caractères manuscrits. Yann LeCun, Leon Bottou, Yoshua Bengio et Patrick

Haffner l'ont proposé à la fin des années 1990. LeNet est composé de nombreuses couches convolutives et de mise en commun, ainsi que d'une couche entièrement connectée et d'un classificateur softmax.

- **AlexNet** : L'algorithme AlexNet a remporté le concours de reconnaissance visuelle à grande échelle ImageNet (ILSVRC) en 2012, en réduisant la marge d'erreur de 26 % à 15 %. Il a été créé à l'université de Toronto par Alex Krizhevsky, Ilya Sutskever et Geoffrey Hinton. Le AlexNet est composé de cinq couches convolutives avec mise en commun maximale et de trois couches FC, qui utilisent toutes des fonctions d'activation ReLU. Il dispose d'un total de 33 filtres, ainsi que de filtres convolutifs 5x5 et 11x11.
- **VGG** : Le VGG (Visual Geometry Group) est un groupe de recherche du département des sciences de l'ingénieur de l'Université d'Oxford. Le groupe VGG est connu pour ses contributions à la vision par ordinateur, notamment les réseaux neuronaux convolutifs (CNN).
- **MobileNet** : L'algorithme MobileNet est une famille de réseaux neuronaux convolutifs destinés aux appareils mobiles et embarqués. Ils sont conçus pour être efficaces et rapides tout en atteignant une grande précision dans des tâches telles que la reconnaissance d'images.

1.2.7. Composante du réseau de neurone convolutif (Convolutional Neural network (CNN)) (Jul s. d.)³

1.2.7.1. Couche de neurone

Un réseau neuronal est un modèle informatique de la structure et de la fonction du cerveau humain. Il s'agit d'un élément essentiel de l'apprentissage automatique et de l'intelligence artificielle. L'identification d'images, le traitement du langage naturel et l'apprentissage par renforcement ne sont des activités pour lesquelles les réseaux neuronaux sont utilisés.




Figure 1. 9. Couche de neurone (openclassroom.com s. d.)^f

3. Jul, Himadri Sankar Chatterjee. s. d. « A Basic Introduction to Convolutional Neural Network »;

f. https://www.openclassroom.com/deep_learning/les%_neurones

Quelques concepts et composants clés des réseaux neuronaux sont :

- **Neurone** : Les neurones sont les éléments fondamentaux des réseaux neuronaux. Chaque neurone reçoit des signaux, les analyse et les émet. Ces neurones synthétiques sont également appelés nœuds ou unités.




Figure I. 10. Représentation d'un neurone artificielle

- **Couches** : Les réseaux neuronaux sont souvent organisés en couches qui comprennent une couche d'entrée, une ou plusieurs couches cachées et une couche de sortie. Les données sont reçues par la couche d'entrée, traitées par les niveaux cachés et produites par la couche de sortie.
- **Pondérations et biais** : Les poids et les biais sont liés aux connexions neuronales. Au cours du processus de formation, ces paramètres sont appris pour modifier l'impact d'un neurone sur un autre. L'apprentissage consiste à déterminer les meilleures valeurs pour ces poids et biais afin de réduire l'erreur du réseau.
- **Fonction d'activation** : La fonction d'activation d'un neurone est une fonction qui génère sa sortie en fonction de la somme pondérée de ses entrées et d'un biais. Exemple de fonction d'activation : Sigmoidale, ReLU (Rectified Linear Unit) et tanh (tangente hyperbolique), Softmax.
- **Feedforward et Backpropagation (Rétropropagation)** : Les réseaux neuronaux créent des prédictions à l'aide d'un processus en amont, tandis que la rétropropagation est utilisée pendant la formation pour modifier les poids et les biais. Les erreurs sont transmises à l'arrière du réseau pendant la rétropropagation afin de mettre à jour les paramètres.
- **La fonction de perte** : La fonction de perte mesure la différence entre les prédictions du réseau et les valeurs cibles réelles. Au cours de la formation, l'objectif est de réduire cette fonction de perte.

1.2.7.2. Couche de convolution

Une couche convolutive, souvent appelée couche Conv, est un élément de base des réseaux neuronaux convolutifs (CNN). Les réseaux neuronaux convolutifs sont principalement utilisés pour traiter des données de type matriciel, telles que des photos et des films. Les couches convolutives sont destinées à apprendre et à extraire automatiquement les caractéristiques des données d'entrée.

- **Fonctionnement**
 - La convolution est le processus fondamental d'une couche convolutive. Un minuscule filtre (également appelé noyau) glisse ou "convole" sur les données entrantes tout au long de cette procédure. Généralement, le filtre est une minuscule matrice de forme carrée dont les poids peuvent être appris. La région de l'entrée prise en compte par le filtre à chaque étape est déterminée par sa taille.
 - **Cartes de caractéristiques** : Le filtre effectue des multiplications et des additions par éléments au fur et à mesure qu'il passe en revue l'entrée afin de générer une valeur unique. Cette valeur est ensuite assignée à une nouvelle structure en forme de grille appelée carte de caractéristiques ou carte d'activation. Une couche convolutive utilise de nombreux filtres, ce qui donne lieu à de nombreuses cartes de caractéristiques. Chaque carte de caractéristiques indique l'existence d'une certaine caractéristique ou d'un certain modèle dans les données d'entrée.
 - **Paramètres apprenables** : Les poids de la couche convolutive sont des paramètres apprenables qui sont modifiés par rétropropagation tout au long du processus d'apprentissage. Ces poids permettent au réseau d'apprendre et de s'adapter automatiquement pour extraire les caractéristiques pertinentes de l'entrée.
 - Après la procédure de convolution, une fonction d'activation (généralement ReLU ou une variante) est appliquée élément par élément aux cartes de caractéristiques. Cette fonction ajoute de la non-linéarité au réseau, ce qui lui permet de simuler des interactions de données complexes.

I.2.7.3. Pooling

Une couche de mise en commun, également appelée couche de pool, est un composant important des réseaux neuronaux convolutifs (CNN) qui sont utilisés pour analyser des entrées en forme de grille, telles que des images. La principale fonction d'une couche de mise en commun est de minimiser les dimensions spatiales (largeur et hauteur) des cartes de caractéristiques tout en conservant les informations les plus importantes. Le pooling améliore l'efficacité de calcul du réseau, réduit le surajustement et rend les caractéristiques apprises plus insensibles aux changements minimes de l'entrée.

La mise en commun maximale et la mise en commun moyenne sont les deux formes les plus courantes de processus de mise en commun employées dans les CNN :

- **Max Pooling** : Dans le cas du Max Pooling, une fenêtre étroite (généralement 2x2 ou 3x3) se déplace sur la carte des caractéristiques, en sélectionnant la valeur maximale dans cette fenêtre à chaque endroit. Il en résulte une carte de caractéristiques sous-échantillonnée, chaque valeur représentant la valeur maximale dans une région particulière de l'entrée. La mise en commun maximale est bien connue pour conserver les caractéristiques les plus importantes de l'entrée et est fréquemment utilisée dans les systèmes CNN.
- **Average Pooling** : Une fenêtre coulissante similaire traverse la carte des caractéristiques dans la mise en commun moyenne, mais au lieu de choisir la plus grande valeur, elle calcule la valeur moyenne à l'intérieur de la fenêtre. La mise en commun moyenne lisse les informations et est utilisée dans certaines situations où le lissage ou le calcul de la moyenne est avantageux.




figure I. 11. pooling (researchgate.net s. d.)^g

g. https://www.researchgate.net/figure/Pooling-layer-operation-oproaches-1-Pooling-layers-For-the-function-of-decreasing-the_fig4_340812216

1.2.7.4. Fully Connected Network (FCN)

Une couche entièrement connectée, également appelée couche dense ou couche de réseau neuronal entièrement connecté (FCN), est un composant essentiel de nombreuses topologies de réseaux neuronaux artificiels, tels que les réseaux neuronaux feedforward et les réseaux neuronaux convolutifs (CNN). Les couches entièrement connectées sont chargées de comprendre les modèles et les connexions complexes dans les données, ce qui les rend utiles pour la classification des images, l'identification des objets, le traitement du langage naturel et d'autres applications d'apprentissage automatique.

Une couche entièrement connectée possède les propriétés et fonctions importantes suivantes :

- Neurone
- Pondération et biais
- Fonction d'activation
- Sortie ou Résultat




Figure I. 12. Fully connected Network (Jul s. d.)

1.2.8. Méthode d'optimisation et mesure de performance

1.2.8.1. Méthode d'optimisation

- ***Les Hyperparamètres***

Les hyperparamètres sont les variables qui influencent la topologie du réseau (par exemple, le nombre d'unités cachées) et la manière dont le réseau est entraîné (par exemple, le taux d'apprentissage). Les hyperparamètres sont établis Avant l'apprentissage (avant d'améliorer les poids et les biais).

- **Validation croisée (Cross Validation (CV))**

La validation croisée (CV) est une technique utilisée pour vérifier l'efficacité d'un modèle d'apprentissage ; il s'agit également d'une stratégie de rééchantillonnage utilisée pour évaluer un modèle lorsque les données sont limitées. Les étapes de cette procédure sont les suivantes :

- Divise les n observations de l'ensemble de données en k "plis" mutuellement exclusifs et de taille égale ou presque.
- Ajuster le modèle avec k-1 plis comme ensemble d'apprentissage et un pli (k-ième) comme ensemble de test. Enregistrez l'erreur du modèle après chaque itération.
- Répétez cette procédure k fois, en utilisant à chaque fois un pli différent comme ensemble de test et les plis restants (k-1) comme ensemble d'apprentissage.
- Prendre la moyenne des k modèles lorsque toutes les itérations sont terminées. Il s'agit de l'erreur quadratique moyenne du modèle.

$$CV_k = \frac{1}{k} \sum_{i=1}^k MSE_i$$

Le nombre de plis utilisés est un aspect important de cette stratégie. Le nombre de plis doit être choisi en tenant compte du fait que chaque pli doit inclure suffisamment de points de données pour offrir une évaluation raisonnable de la performance du modèle p. Cependant, la valeur k ne peut pas être aussi minimale que 2 afin d'avoir suffisamment de modèles entraînés pour évaluer la performance du modèle.

	K1	K2	K3	K4	K5
Iter 1	Test Data 20% of data	Train Data	Train Data	Train Data	Train Data
Iter2	Train Data	Test Data 20% of data	Train Data	Train Data	Train Data
Iter3	Train Data	Train Data	Test Data 20% of data	Train Data	Train Data
Iter 4	Train Data	Train Data	Train Data	Test Data 20% of data	Train Data
Iter 5	Train Data	Train Data	Train Data	Train Data	Test Data 20% of data

figure I. 13. Cross validation (medium.com s.d.)^h

h. https://www.medium.com/AI/model_parameter/cross_validation

- **Random search**

La recherche aléatoire crée une grille de données hyperparamétriques et choisit des combinaisons aléatoires pour construire le modèle et le score. Cela vous permet de limiter directement le nombre de combinaisons de paramètres qui sont essayées. Le nombre d'itérations de recherche est déterminé par le temps ou les ressources. ScikitLearn fournit à cet effet la fonction `RandomizedSearchCV`.




Figure I. 14. Random search (quora.com s. d.)ⁱ

- **Grid Search**

La recherche de grille est le processus d'exécution d'une configuration hyperparamétrique afin de trouver les meilleures valeurs pour un modèle particulier. Ceci est important car la performance du modèle entier est déterminée par les paramètres hyperparamétriques.




Figure I. 15. Grid Search (quora.com s. d.)

i. https://www.quora.com/opt%method/random_search

I.3. Généralité sur les tumeurs cérébrales (Ali-Osman 2002) ⁴

I.3.1. Définition

Le terme **tumeur** (du latin *tumere*, enfler) en médecine, signifie une augmentation du volume d'un tissu, mais sans cause connue. Plus précisément c'est la croissance anormale des cellules. Les cellules sont les éléments de base de l'organisme : elles constituent les tissus et les organes. Le corps fabrique constamment de nouvelles cellules pour nous aider à grandir, à remplacer les tissus usés et à guérir les blessures

Normalement, les cellules se multiplient et meurent de manière ordonnée, de sorte que chaque nouvelle cellule remplace une cellule perdue. Cependant, il arrive que des cellules deviennent anormales et continuent de croître. Dans les cancers solides, comme les tumeurs cérébrales, les cellules anormales forment une masse ou une grosseur appelée tumeur.

Une tumeur cérébrale est donc une accumulation ou formation de masse de cellules anormales dans la région de la tête, plus précisément au cerveau.

Le cerveau est un organe qui reçoit et interprète les informations transmises par les nerfs des organes sensoriels qui contrôlent le goût, l'odorat, le toucher, la vue et l'ouïe. Il envoie également des messages aux muscles et aux organes par l'intermédiaire des nerfs. Le cerveau est responsable de la mémoire, de la personnalité et du comportement. Les principales parties du cerveau sont le cerveau, le cervelet et le tronc cérébral.

4. Ali-Osman, Francis. 2002. « Brain Tumors ». P. 167-84 in *Human Cell Culture*. Vol. 2, *Human Cell Culture*, édité par J. R. W. Masters et B. Palsson. Dordrecht: Kluwer Academic Publishers.




Figure I. 16. Présentation du cerveau humain (google.com s.d.)

1.3.2. Classification des tumeurs cérébrales (Ali-Osman 2002)

La plupart du temps, les tumeurs cérébrales sont classées comme bénignes ou malignes. Les tumeurs dans d'autres parties du corps sont également couvertes par ces termes. Cependant, la distinction n'est pas aussi évidente dans le cas des tumeurs cérébrales.

1.3.2.1. Tumeurs bénignes

Les tumeurs cérébrales bénignes se développent généralement lentement et ne risquent pas de se propager. Une tumeur bénigne peut se développer et affecter le fonctionnement du cerveau. Cela peut mettre la vie en danger et nécessiter un traitement urgent. Il arrive qu'une tumeur bénigne évolue avec le temps et devienne maligne.

1.3.2.2. Tumeurs malignes

Une tumeur cérébrale maligne peut être appelée cancer du cerveau. Certaines tumeurs cérébrales malignes se développent lentement, d'autres rapidement. Elles sont considérées comme mettant la vie en danger parce qu'elles peuvent grossir, se propager dans le cerveau ou la moelle épinière, ou réapparaître après un traitement. On distingue deux types de ces tumeurs appelé également cancer du cerveau ;

- **Cancer Primaire** : Le cancer primitif du cerveau est un cancer qui se développe dans le cerveau. Il peut s'étendre à d'autres parties du corps. Les cancers primitifs du cerveau ne se propagent généralement pas en dehors du cerveau et de la moelle épinière, contrairement à d'autres tumeurs malignes qui peuvent se propager dans tout le corps.
- **Cancer Secondaire** : Il arrive que le cancer se propage par la circulation sanguine jusqu'au cerveau et se déclare dans une autre partie du corps. Il s'agit d'un cancer secondaire ou d'une métastase. Le mélanome, le cancer du poumon, du sein, du rein et de l'intestin sont les cancers les plus susceptibles de se propager au cerveau. Le nom du cancer d'origine est conservé dans une métastase. Par exemple, même si la personne présente des symptômes, un cancer de l'intestin qui s'est propagé au cerveau est toujours appelé cancer de l'intestin métastatique.




Figure I. 17. Formation des cellules cancéreuses (Ali-Osman 2002)

I.3.3. Types de tumeur cérébrale

Tumeurs de type Gliome	
Ces tumeurs se développent dans les cellules gliales (névroglies) du cerveau.	
Astrocytome	<ul style="list-style-type: none"> • Commence dans les cellules gliales appelées astrocytes • Peut-être bénigne ou maligne
Glioblastome	<ul style="list-style-type: none"> • Type d'astrocytome malin • Peut se développer à partir d'un astrocytome à croissance lente • Représente plus de la moitié des gliomes • Fréquente chez les adultes et les enfants

Ependymome	<ul style="list-style-type: none"> • Commence dans les cellules gliales appelées cellules épendymaires • Plus fréquente chez les enfants que chez les adultes • Peut-être bénigne ou maligne
Oligodendrogliome	<ul style="list-style-type: none"> • Commence dans les cellules gliales appelées oligodendrocytes • Plus fréquente chez les jeunes adultes • Maligne ; peut-être à croissance lente ou rapide
Tumeurs de type non Gliome	
Ces tumeurs se développent dans d'autres types de cellules présentes dans le cerveau	
Médulloblastome	<ul style="list-style-type: none"> • Tumeur maligne ; commence dans le cervelet • Plus fréquente chez les enfants ; rare chez les adultes
Méningiome	<ul style="list-style-type: none"> • Commence dans les membranes (méninges) qui recouvrent le cerveau et la moelle épinière. Le cerveau et la moelle épinière • Tumeur cérébrale primaire la plus fréquente, généralement bénigne et à croissance lente
Tumeur hypophysaire	<ul style="list-style-type: none"> • Commence dans l'hypophyse • Généralement bénigne
Schwannome	<ul style="list-style-type: none"> • Commence dans les cellules de Schwann, qui entourent les nerfs du cerveau et de la moelle épinière. • Généralement bénigne

Tableau I. 6. Types courants de tumeurs cérébrales primaires (Ali-Osman 2002)

1.3.4. Diagnostic (Ali-Osman 2002)

De nombreuses personnes diagnostiquées avec une tumeur du cerveau consultent d'abord leur médecin généraliste parce qu'elles ne se sentent pas bien. Il arrive qu'une tumeur cérébrale soit découverte lors d'un examen ophtalmologique ou d'un scanner pour un problème sans rapport, tel qu'un traumatisme crânien. Certaines personnes présentent des symptômes soudains (maux de tête intenses, crise d'épilepsie ou perte de conscience) et se rendent directement au service des urgences d'un hôpital.

Le médecin vous interrogera sur vos symptômes et vos antécédents médicaux et procédera à un examen physique. S'il soupçonne la présence d'une tumeur du cerveau, il vous orientera vers d'autres examens pour confirmer le diagnostic. Il existe

quelque différent type de méthode pour procéder à un diagnostic tel que : tomographie assistée par ordinateur, test sanguin, l'examen physique et les scans d'imagerie par résonance magnétique (IRM) qui es la méthode au quelle nous allons intéresser.

- **Fonctionnement d'une IRM ([wikipedia.org s.d.](https://fr.wikipedia.org/wiki/Imagerie_par_r%C3%A9sonance_magn%C3%A9tique))**

L'Imagerie par résonance magnétique est une technique d'imagerie médicale utilisée en radiologie pour obtenir des images de l'anatomie et des processus physiologiques du corps. Les scanners IRM utilisent des champs magnétiques puissants, des gradients de champ magnétique et des ondes radio pour générer des images des organes du corps. L'IRM n'utilise pas de rayons X ni de radiations ionisantes, ce qui la distingue de la tomodensitométrie et de la tomographie par émission de positons.

Dans la plupart des applications médicales, les noyaux d'hydrogène, constitués uniquement d'un proton, qui se trouvent dans les tissus créent un signal qui est traité pour former une image du corps en termes de densité de ces noyaux dans une région spécifique. Étant donné que les protons sont affectés par les champs d'autres atomes auxquels ils sont liés, il est possible de séparer les réponses de l'hydrogène dans des composés spécifiques. Pour réaliser une étude, la personne est placée dans un scanner IRM qui forme un champ magnétique puissant autour de la zone à imager. Tout d'abord, l'énergie d'un champ magnétique oscillant est temporairement appliquée au patient à la fréquence de résonance appropriée. Le balayage à l'aide de bobines de gradient X et Y permet à une région sélectionnée du patient de subir le champ magnétique exact nécessaire à l'absorption de l'énergie.

Les atomes sont excités par une impulsion a fréquence radio et le signal résultant est mesuré par une bobine réceptrice. Le signal de radiofréquence peut être traité pour déduire des informations sur la position en examinant les changements de niveau et de phase de la radiofréquence provoqués par la variation du champ magnétique local à l'aide de bobines de gradient. Comme ces bobines sont rapidement commutées pendant l'excitation et la réponse pour effectuer un balayage linéaire mobile, elles créent le bruit répétitif caractéristique d'un balayage IRM car les enroulements se déplacent légèrement en raison de la magnétostriktion. Le contraste entre les différents tissus est déterminé par la vitesse à laquelle les atomes excités

INTELLIGENCE ARTIFICIELLE ET DETECTION PRECOCE DES TUMEURS CEREBRALES A PARTIR D'IMAGES RADIOLOGIQUES

reviennent à l'état d'équilibre. Des agents de contraste exogènes peuvent être administrés à la personne pour rendre l'image plus claire.




Figure I. 18. Schéma d'un supraconducteur cylindrique à résonance magnétique (wikipedia.org s.d.)




Figure I. 19. Scan par IRM d'un cerveau sain (google.com s.d.)




Figure I. 20. Scan par IRM d'un cerveau avec présence de tumeur (google.com s.d.)

I.4. Etat de l'art

I.4.1. Segmentation des tumeurs cérébrales sur des images IRM à l'aide d'un réseau neuronal convolutif anisotrope supervisé en profondeur (par M. M. Islam, Zhijie Wang, M. A. Iqbal, Guangxiao Song 2018)

Le gliome est la forme la plus courante et la plus cancéreuse des tumeurs cérébrales à un stade précoce qui se développent à partir des cellules gliales. Les solutions basées sur l'apprentissage profond sont flexibles dans l'analyse d'images de tumeurs cérébrales et le diagnostic assisté par ordinateur, mais elles n'atteignent pas la précision souhaitée. La segmentation manuelle des tumeurs cérébrales est une tâche difficile pour les cliniciens, c'est pourquoi les chercheurs travaillent en

permanence à l'amélioration de la précision de la segmentation des tumeurs cérébrales à l'aide de la segmentation automatique. Dans cet article, nous avons segmenté la tumeur cérébrale en trois régions, à savoir la tumeur entière, la tumeur qui s'améliore et la tumeur qui ne s'améliore pas, à l'aide d'un réseau neuronal convolutif (CNN) implémenté par convolution dilatée anisotrope avec des blocs résiduels, en utilisant en outre des couches supervisées en profondeur. L'expérience montre que notre méthode proposée a atteint les scores de 0,91, 0,78, 0,84 pour la tumeur entière, la tumeur améliorante et la tumeur non améliorante respectivement, ce qui est mieux que le défi BraTS 2017 et d'autres approches rapportées.

1.4.2. Apprentissage profond et fusion d'étiquettes sémantiques basées sur la texture pour la segmentation des tumeurs cérébrales (par L. Vidyaratne, M. Alam, Z. A. Shboul, K. Iftekharruddin 2018)

La segmentation des tumeurs cérébrales est une étape fondamentale du traitement chirurgical et de la thérapie. De nombreuses méthodes artisanales et basées sur l'apprentissage ont été proposées pour la segmentation automatique des tumeurs cérébrales à partir de l'IRM. Des études ont montré que ces approches ont leurs avantages et leurs limites inhérents. Ce travail propose un algorithme de fusion d'étiquettes sémantiques en combinant deux algorithmes de segmentation représentatifs de l'état de l'art : les méthodes artisanales basées sur la texture et les méthodes basées sur l'apprentissage profond afin d'obtenir une segmentation robuste des tumeurs. Nous évaluons la méthode proposée à l'aide de l'ensemble de données publiques BRATS 2017 brain tumor segmentation challenge. Les résultats montrent que la méthode proposée offre une segmentation améliorée en atténuant les faiblesses inhérentes : faux positifs étendus dans la méthode basée sur la texture, et le faux problème de classification des tissus tumoraux dans la méthode d'apprentissage profond, respectivement. En outre, nous étudions l'effet du sexe du patient sur les performances de segmentation en utilisant un sous-ensemble de données de validation. Notons que l'amélioration substantielle de la performance de segmentation des tumeurs cérébrales proposée dans ce travail nous a récemment permis d'obtenir la première place de notre groupe dans la tâche de prédiction de la survie globale des patients au défi BRATS 2017.

1.4.3. Segmentation des tumeurs cérébrales basée sur le SFCM à l'aide d'un réseau neuronal à rétropropagation. (S. Raja 2017)

La surveillance des maladies infectieuses (ré) émergentes est effectuée à l'aide de bases de données de santé publique ou de réseaux de surveillance régionaux, nationaux et internationaux, qui sont tous basés sur les rapports des prestataires de soins ou des patients eux-mêmes. En collaboration avec l'Institut Robert Koch, l'organisation de recherche internationale à but non lucratif Vienna Vaccine Safety Initiative a développé deux programmes de qualité entre 2009 et 2015 dans l'un des plus grands centres de soins tertiaires pédiatriques d'Europe, la Charité Centre médical universitaire de Berlin, dans le but d'améliorer le contrôle des infections et la surveillance des maladies infectieuses. A l'aide de la technologie de santé mobile, les présentations cliniques et la gravité de la maladie chez les patients atteints de syndrome grippal ont été évaluées en temps réel. L'application des algorithmes de l'apprentissage automatique a démontré que la classification automatique des cas et la métagénomique sont utiles pour combler les « lacunes diagnostiques » dans les infections complexes.

1.4.4. Enquête sur l'analyse d'images médicales basée sur l'IRM pour l'étude des tumeurs cérébrales (Par S. Bauer, R. Wiest, L. Nolte, M. Reyes 2013)

L'analyse d'images médicales basée sur l'IRM pour l'étude des tumeurs cérébrales attire de plus en plus l'attention ces derniers temps en raison d'un besoin accru d'évaluation efficace et objective de grandes quantités de données. Alors que les approches pionnières appliquant des méthodes automatisées pour l'analyse des images de tumeurs cérébrales remontent à près de vingt ans, les méthodes actuelles deviennent plus matures et se rapprochent d'une application clinique de routine. Cette étude vise à fournir une vue d'ensemble complète en commençant par une brève introduction aux tumeurs cérébrales et à l'imagerie des tumeurs cérébrales. Ensuite, nous passons en revue l'état de l'art en matière de segmentation, d'enregistrement et de modélisation des images cérébrales porteuses de tumeurs, en mettant l'accent sur les gliomes. L'objectif de la segmentation est de délimiter la tumeur, y compris ses sous-compartiments et les tissus environnants, tandis que le principal défi de l'enregistrement et de la modélisation est la gestion des changements morphologiques

causés par la tumeur. Les qualités des différentes approches sont discutées en mettant l'accent sur les méthodes qui peuvent être appliquées aux protocoles d'imagerie clinique standard. Enfin, une évaluation critique de l'état actuel est réalisée et les développements et tendances futurs sont abordés, en accordant une attention particulière aux développements récents des lignes directrices pour l'évaluation radiologique des tumeurs.

1.4.5. Détection du mélanome (Par Esteva A. Nature 2017)

Lors de leur expérimentation, le défi a consisté à apprendre à un algorithme à reconnaître différents types de cancers de la peau et leur gravité, "d'un carcinome malin à une kératose séborrhéique bénigne". Pour ce faire, les chercheurs ont utilisé un algorithme déjà existant de Google, qui s'est déjà fait remarquer en apprenant à traiter 1,28 million d'images représentant 1000 catégories d'objets. Il n'y avait pas de bases de données photographiques pour l'apprentissage de l'algorithme dans le cas des cancers de la peau. Afin de créer une taxonomie appropriée, il a donc fallu d'abord créer cette base de données à partir des informations disponibles sur Internet et collaborer avec l'école médicale de Stanford. Le résultat final comprend 129 450 images qui représentent 2032 maladies de la peau.

En premier lieu, on a demandé aux 21 dermatologues d'analyser chaque photo haute qualité pour déterminer s'ils ou elles recommandaient une biopsie, un traitement ou simplement de rassurer le patient si le cas était bénin. Sur plus de 370 images, les chercheurs ont ensuite évalué le succès de chaque dermatologue à effectuer le bon diagnostic. La performance de l'algorithme a quant à elle été mesurée à l'aide d'une courbe spécificité/sensibilité, qui représente la capacité de l'algorithme à présenter le moins de faux positifs, c'est-à-dire le moins de cancers graves qui ne le sont pas en fait (spécificité) et la capacité à présenter le moins de faux négatifs, c'est-à-dire des cancers graves qui ne sont pas détectés. L'ordinateur devait effectuer trois diagnostics : évaluer les carcinomes kératinisant épidermoïdes, évaluer les mélanomes et évaluer les mélanomes pris en photo à l'aide d'une dermoscopie.

Dans les trois cas de diagnostics, l'algorithme a obtenu des résultats similaires à ceux des humains dans la courbe de spécificité/sensibilité, avec ses résultats se situant dans une zone qui représente 91 % de la courbe.

1.4.6. Segmentation des tumeurs cérébrales basée sur une forêt extrêmement aléatoire avec des caractéristiques de haut niveau (par Adriano Pinto, Sérgio Pereira, H. Correia, Jorge Oliveira, D. Rasteiro, Carlos Alberto Silva 2015)

Les gliomes sont parmi les tumeurs cérébrales les plus courantes et les plus agressives. La segmentation de ces tumeurs est importante pour la chirurgie et la planification du traitement, mais aussi pour les évaluations de suivi. Il s'agit toutefois d'une tâche difficile, étant donné que leur taille et leur localisation sont variables, et que la délimitation de tous les tissus tumoraux n'est pas triviale, même avec toutes les différentes modalités de l'imagerie par résonance magnétique (IRM). Nous proposons une méthode discriminante et entièrement automatique pour la segmentation des gliomes, en utilisant des caractéristiques basées sur l'apparence et le contexte pour alimenter une forêt extrêmement aléatoire (Extra-Trees). Certaines de ces caractéristiques sont calculées à partir d'une transformation non linéaire de l'image. La méthode proposée a été évaluée à l'aide de la base de données publique Challenge de BraTS 2013, et a obtenu un score de Dice de 0,83, 0,78 et 0,73 pour la tumeur complète, le noyau et les régions améliorées, respectivement. Nos résultats sont compétitifs lorsqu'ils sont comparés à d'autres résultats obtenus avec la même base de données

Conclusion

Dans ce chapitre nous avons examiné une revue littéraire qui a mis en lumière les développements et les problèmes importants qui ont façonné ce sujet en constante évolution. Le cadre théorique nous a plongés dans le domaine complexe de l'intelligence artificielle, apprentissage automatique et l'apprentissage profond. Ces connaissances théoriques sont essentielles pour comprendre comment l'intelligence artificielle a évolué au fil du temps. Ensuite nous avons étudié les différentes tumeurs cérébrales ainsi que leurs différents types et leurs formations.

En résumé, ce chapitre a jeté des bonnes bases qui nous a permis de comprendre les fondements théoriques et les avancées technologiques. Dans le chapitre suivant, nous allons nous plonger dans la méthodologie appliquée a notre travaille et présentant nos différentes variables de recherche ainsi que les outils utilisés pour l'implémentation de notre solution.

CHAPITRE II : METHODOLOGIE DE RECHERCHE

Introduction

Au cœur de toute recherche significative se trouve une méthodologie solide qui guide l'exploration et l'analyse des questions fondamentales. Dans ce chapitre, nous présentons dans un premier temps la nature de notre étude, en révélant les facteurs importants que nous étudions ainsi que les instruments cruciaux qui guident notre méthodologie.

L'identification précoce des tumeurs cérébrales à l'aide de l'intelligence artificielle est une entreprise aux multiples facettes qui nécessite une connaissance complète des éléments essentiels qui la composent. C'est pourquoi nous commencerons par décrire la nature de notre étude, en insistant sur son caractère mixte. Les variables de l'étude, qui sont les facteurs mesurables qui encadrent notre stratégie, seront ensuite présentées. La compréhension de ces variables est essentielle pour la conception de nos tests et l'analyse des résultats. La boîte à outils méthodologique que nous utilisons pour mener notre étude est représentée en fin par des outils de recherche. Les logiciels et bibliothèques d'apprentissage profond, les plateformes de déploiement en font partie. Ces technologies nous permettent de concrétiser nos idées et de quantifier objectivement les résultats.

En résumé, ce chapitre sert de fondement méthodologique à notre recherche. Il définit la nature de notre étude, expose les variables qui sous-tendent nos investigations et présente les outils essentiels qui nous aident à réaliser nos objectifs. C'est à travers cette méthodologie que nous progressons vers la réalisation de notre mission : Améliorer les diagnostics médicaux en utilisant judicieusement l'intelligence artificielle pour l'identification précoce des cancers du cerveau, un objectif qui peut avoir une influence substantielle sur la vie des patients et du personnel soignant.

II.1. Nature de la recherche

La nature de notre travail est principalement mixte (c'est-à-dire qualitative et quantitative). Cette approche de recherche est choisie pour plusieurs raisons ;

- **Compréhension contextuelle (Qualitative)**

La compréhension contextuelle à travers des entretiens avec des prestataires de soins de santé, des radiologues et des patients, par exemple, pourraient fournir des informations utiles sur le contexte clinique et les besoins uniques en matière de détection précoce des tumeurs cérébrales. Ces données contextuelles sont essentielles pour créer des solutions d'IA qui s'intègrent parfaitement dans les procédures médicales établies.

- **Collecte des données (Quantitative)**

Les données quantitatives, telles que les radiographies, sont fondamentales pour la recherche en IA. Les modèles d'apprentissage profond utilisent des images du cerveau qui ont été marquées avec des informations sur la présence ou l'absence de tumeurs malignes. Des méthodologies quantitatives sont nécessaires pour évaluer les performances des modèles d'IA en termes de sensibilité, de spécificité et d'autres paramètres critiques.

- **Validation clinique (qualitative et quantitative) :**

La validation clinique des performances de l'IA dans l'identification des tumeurs cérébrales implique à la fois des données quantitatives (telles que la comparaison des résultats de l'IA avec ceux des radiologues) et des données qualitatives (telles que les commentaires des médecins sur la convivialité et les effets cliniques). Cette technique hybride donne une vue d'ensemble des performances de l'IA.

II.2. Variable de recherche

II.2.1. Définition Conceptuelle

Les variables sont cruciales pour structurer notre étude et évaluer son impact. Nous allons présenter dans cette partie les différentes variables de notre étude et les indicateurs qui ont façonnés leur sélection respective.

II.2.1.1. Variables dépendantes :

- **Temp du diagnostic de la tumeur** : Cette variable dépendante représente le temp mis pour le diagnostic d'une tumeur par les spécialistes de santé
 - **INDICATEUR** : les délais entre l'examen radiologique et diagnostique, temps de diagnostic moyen pour des cas spécifiques
- **La précision du diagnostic du type de tumeur** : Cette variable dépendante représente le type précis de tumeur cérébrale découvert par l'algorithme
 - **INDICATEUR** : les tumeurs de type gliome, les tumeurs de type méningiome, les tumeurs de type hypophysaire

II.2.1.2. Variables indépendantes :

- **L'intelligence artificielle** : L'IA est une variable indépendante dans cet environnement de recherche car elle peut être ajustée, modifiée et contrôlée afin d'altérer les performances du modèle dans la détection précoce des tumeurs cérébrales. Elle offre une flexibilité et une adaptabilité considérables, ce qui en fait une variable essentielle pour optimiser le temps de diagnostic et la précision de la détection.
 - **INDICATEUR** : Architecture du réseau neuronal, l'ensemble des données d'entraînement, les hyperparamètres, technique de régularisation, les méthodes d'entraînements

II.2.1. Limites et difficultés

- **Variabilité des images radiologiques** : La qualité, la résolution, la dimension des images radiologiques varie sur une minorité des images présent dans notre base de données. Alors un processus manuel de sélection et suppression est fait afin de ne pas compliquer la normalisation et le prétraitement des données ce qui peut affecter les performances du modèle.
- **Annotation des données** : Notre base de données présente une minorité de donnée mal annotée et possédant un format d'image invalide. Cela est un problème difficile à résoudre et encore plus dans les cas où il doit être fait manuellement. Afin de pallier à cela, nous devons créer une petite fonction qui doit prendre en paramètre une image et vérifier son état. En cas d'invalidité, l'image est supprimée de la base de données.
- Les modèles d'apprentissage profond s'appuient fréquemment sur certains hyperparamètres, tels que le taux d'apprentissage ou la taille du lot, qui doivent être soigneusement ajustés pour obtenir des performances optimales.

II.3. Outils de recherche

Afin de pouvoir réaliser notre travail, un questionnaire a travers un google form sera utilisé comme outil de recherche pour notre quête. Ceci est choisi pour plusieurs raison :

- **Collecte de données** : Pour recueillir des informations démographiques et médicales sur les patients, telles que l'âge, le sexe, les symptômes. Ces données sont essentielles pour déterminer l'utilité des modèles d'IA dans divers contextes thérapeutiques.
- **Évaluation des besoins cliniques** : Pour s'enquérir des besoins des professionnels de la santé, tels que les radiologues et les neurologues, en matière d'identification précoce des tumeurs cérébrales. Leurs réponses peuvent aider à orienter la recherche vers les aspects les plus critiques de la pratique médicale.

- Enquête de satisfaction des patients : Les patients qui ont subi des procédures de diagnostic de tumeurs cérébrales peuvent être invités à répondre à un questionnaire sur leur expérience. Cela nous permet de mesurer la satisfaction des patients, d'identifier les forces et les faiblesses du processus de diagnostic et d'y apporter les modifications nécessaires.
- Évaluation des besoins de formation : Les besoins de formation et d'éducation liés à l'application de l'IA dans la détection des tumeurs cérébrales peuvent être découverts en interrogeant le personnel de santé et les patients. Cela peut contribuer à l'élaboration de programmes de formation appropriés.
- Évaluation de l'acceptabilité de la technologie : Utilisés pour évaluer l'adoption de l'IA par les professionnels de la santé et les patients. Comprendre ce qu'ils pensent de cette technologie peut aider à anticiper les problèmes potentiels lors de l'adoption.
- Suivi longitudinal des patients : des questionnaires peuvent être utilisés pour suivre les patients atteints de tumeurs cérébrales dans le temps. Ils peuvent aider à déterminer l'efficacité de la thérapie, la qualité de vie du patient et les taux de récurrence.

À l'aide d'un questionnaire ou d'un formulaire, nous pouvons recueillir des données qualitatives et quantitatives essentielles pour guider notre étude, comprendre les besoins des patients et des professionnels de la santé et analyser l'effet potentiel de l'IA sur le diagnostic précoce des cancers du cerveau. Cet outil vous permet de recueillir des informations en plus des données d'imagerie radiologique, ce qui nous donne une image plus complète du sujet de l'étude.

Conclusion

Le caractère expérimental notre recherche démontre notre volonté de repousser les frontières de la connaissance médicale tout en explorant le potentiel de l'intelligence artificielle. Cette combinaison de rigueur scientifique et de recherche frontières est essentielle pour progresser dans un domaine aussi complexe que l'identification précoce des tumeurs cérébrales. Les aspects importants qui façonnent nos expériences et notre analyse sont les variables de l'étude que nous avons découvertes. Leur connaissance approfondie est essentielle pour développer des études pertinentes et interpréter les données de manière significative. En mettant l'accent sur ces éléments, nous fournissons un cadre solide pour notre stratégie d'étude. Les outils de recherche, quant à eux, sont les instruments qui vont nous permettre de donner vie à notre approche. Ces technologies nous permettent de mettre nos idées en action et d'en mesurer objectivement les résultats.

Le chapitre suivant nous allons présenter le site ou nous avons effectué notre travail, la source et présentation des données utilisé pour la réalisation de ce travail.

CHAPITRE III : PRESENTATION DE LA SITUATION

Introduction

L'IA s'est imposée comme un acteur de premier plan dans le domaine de la médecine. Dans ce chapitre, nous commencerons par une présentation complète du site de recherche, qui permettra de comprendre sa structure, son fonctionnement et son objectif principal. Ensuite, nous commencerons à présenter et analyser les données que nous avons méticuleusement collectées au cours de notre enquête. Ces résultats sont le fruit pour comprendre les problèmes et comment s'y prendre afin de proposer une solution adéquate au problème rencontré. Nous examinerons les résultats, les grandes tendances et les leçons que nous pouvons tirer de cette mine de données.

Ce chapitre est une étape importante de notre étude puisqu'il révèle le cadre qui soutient notre travail ainsi que les connaissances importantes que nous en avons tirées afin que cette étude puisse éclairer les perspectives d'avenir de cette technologie dans le domaine médical.

III.1. Présentation du site de recherche

III.1.1. Historique et mission

C'est en ce jour du 08 Mai 2023 que nous sommes accueilli au sein l'entreprise appelé Cabinet Fadjeu. Le cabinet Fadjeu est un cabinet de conseils et d'expertise spécialisé dans le domaine du numérique (développement de logiciel et application), de représentation commerciale, dans le domaine industrielle (planification dans la production agroalimentaire), dans les BTP (conception et maîtrise d'œuvre) et dans la formation (transmission de notre savoir-faire)

Créé depuis 2015, le groupe Fadjeu apporte son expertise et son savoir-faire dans le monde du numérique et de nouvelles technologies à ses nombreux clients. Son objectif est de faciliter l'intégration du digitale et du numérique au sein des entreprises en apportant son savoir-faire et expertise dans le domaine de l'industrie allant de la conception du dit produit à la production au stockage jusqu'à la vente de du produit. Le groupe Fadjeu suis toute la chaîne de valeur de votre entreprise et enfin facilite la représentation de certaine marque et produit sur le marché Camerounais où Africain en générale.

III.1.2. Organisation

Le Cabinet Fadjeu est organisé comme suit : une direction générale, une direction des affaires financières, une direction de communication et la cellule des développeurs qui sont définis comme suit :

- **Direction Générale** : La Direction Générale a à sa tête un Directeur général qui applique les décisions du pour le bon déroulement de l'entreprise.
- **La Direction Des Affaires financières** : La Direction des Affaires a à sa tête une Directrice chargées des affaires financières qui s'occupe de toute la gestion financière de l'entreprise. Elle reçoit les fonctions qui lui sont assignées par le directeur générale.
- **La Direction de Communication et marketing** : Elle est sous l'autorité du responsable de la Communication qui se charge de la publication des produits et de toute l'organisation marketing de l'entreprise tant interne qu'externe.

- **La cellule des développeurs** : Ici sont présent tous les développeurs responsables du développement des produit et la réalisation des projets de l'entreprise.

III.1.3. Organigramme de la structure

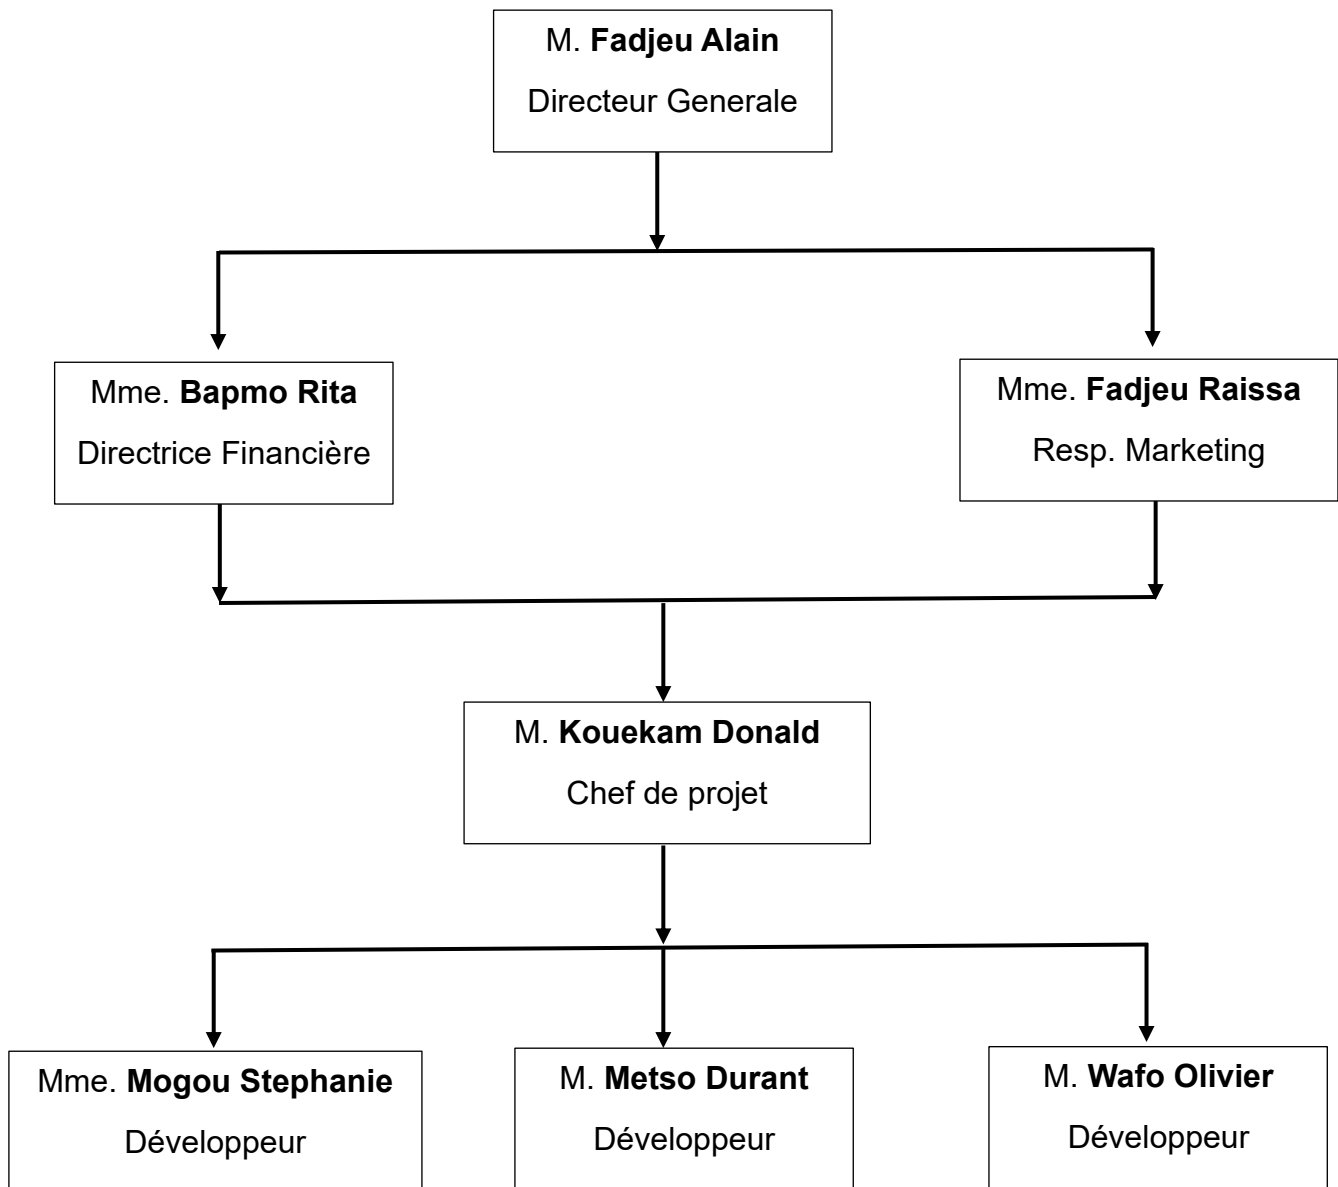


Figure III. 1. Organigramme du cabinet Fadjeu

III.1.4. Localisation

Comme indiqué sur la figure ci-dessous, le cabinet Fadjeu est une entreprise située dans la ville de Yaoundé, région du centre-Cameroun au lieu-dit **descente éleveur**.

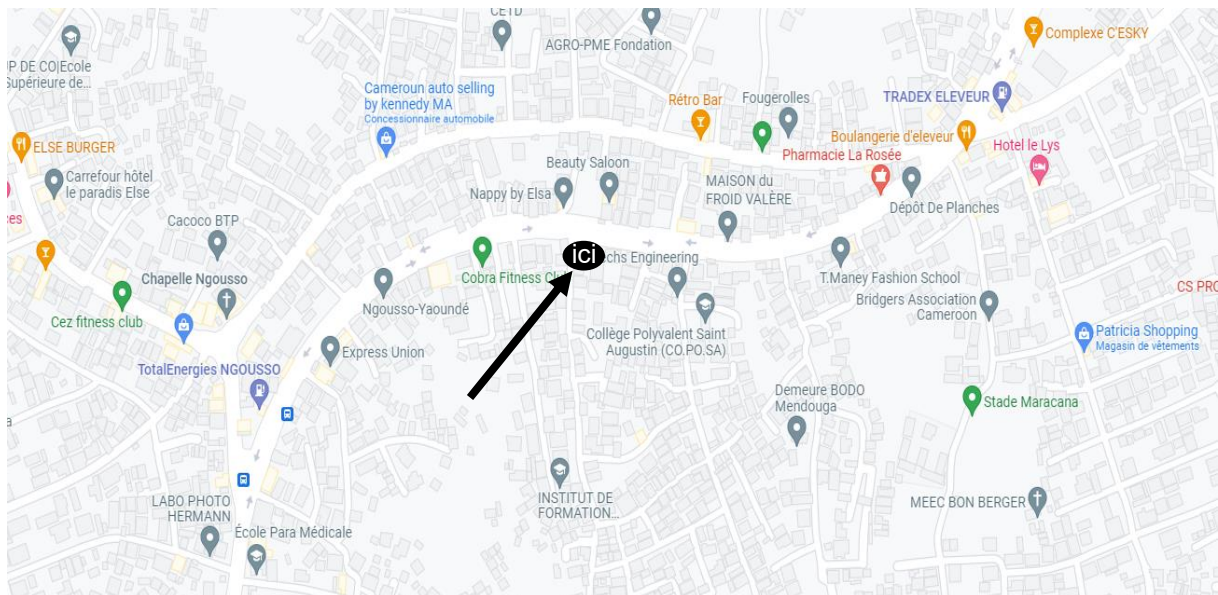


Figure III. 2. Situation Géographique (google.com/maps s.d.)

III.1.5. Ressource Matérielles

III.1.5.1. Micro-ordinateur

Le parc informatique fonctionnel des services de la direction et de la cellule des développeurs sont constitués des postes de travail et Serveurs micros détaillé sur le tableau ci-après :

DIVISION	ORDINATEUR			IMPRIMANTE	
	Nombre	Marque	System Exploitation	Nombre	Marque
Direction Générale	01	HP : L170	Windows 10	01	HP Officejet 6006 Wireless, Deskjet, laser jet
Direction Financières	01	HP : L170	Windows 10	01	HP Officejet 6006 Wireless,

					Deskjet, laser jet
Direction Marketing	01	HP : L170	Windows 8	01	HP Officejet 6006 Wireless, Deskjet, laser jet
Cellule des développeurs	05	HP : L1911	Windows 10	00	

Tableau III. 1. Ressource matérielle micro-ordinateur

III.1.5.1. Equipements réseaux

Le cabinet Fadjeu dispose d'un réseau local et d'une connexion internet avec un débit minimal de 2 Mo/s sur ses segments. On retrouve ainsi ;

MATERIELS	NOMBRE
Un routeur CISCO 2800 qui gère le MPLS (Multiple Protocol Label Switch)	01
Un routeur CISCO 1840 qui permet la connexion internet	01
Climatiseurs pour maintenir les équipements dans les bonnes conditions de température ;	01

Tableau III. 2. Ressource matérielle (équipement réseau)

III.2. Présentation des données et analyse

Nous avons réalisé notre questionnaire dans un google form dans lequel un certain nombre de question ont été posées afin de recueillir des problèmes potentiels. Ensuite le lien vers le questionnaire a été partagé entre divers personne incluant des

professionnels de la santé, patient et autre. Plus de 100 personnes se ont répondu à notre questionnaire et nous présentons dans cette partie une interprétation et une analyse du résultat obtenu.

- Lorsqu'il a été posé la question de savoir si ces derniers avaient déjà entendu parler d'une tumeur cérébrale ou s'il avait déjà été victime d'une tumeur cérébrale, les résultats obtenus montre des réponses significatives concernant les connaissances et l'expérience des participants en matière de tumeurs cérébrales représente comme suit :
 - La réponse "Oui, J'ai des parents ou des connaissances à qui l'on a diagnostiqué une tumeur cérébrale " a recueilli 66,7 % des voix. La grande majorité des participants ont des connaissances ou des parents à qui l'on a diagnostiqué une tumeur cérébrale. Cela montre que leur cercle social est affecté par leur état de santé.
 - La réponse "Oui, On m'a déjà diagnostiqué une tumeur cérébrale " a recueilli 22,2 % des voix. " : Bien que ce taux soit nettement inférieur au précédent, cela suggère que l'échantillon de recherche comprend des personnes qui ont une expérience personnelle de la maladie.
 - 11,1% pour "Non, je suis désolé, pas du tout"




Figure III. 3. Résultat 1

- Lorsqu'il a été posé la question de savoir quel diagnostic ces derniers avaient reçu :
 - 62,5 % pour "IRM" : L'écrasante majorité des participants (62,5 %) a indiqué que l'IRM (imagerie par résonance magnétique) est la méthode d'imagerie médicale qu'ils associent principalement au diagnostic.

- 25% pour "Tomographie assistée par ordinateur" : Un quart des participants (25%) ont mentionné la tomodensitométrie (CT-scan) comme méthode d'imagerie associée au diagnostic des tumeurs cérébrales qu'ils ont reçues. Bien que ce pourcentage soit inférieur à celui associé à l'IRM, il démontre que la tomodensitométrie reste une méthode d'imagerie médicale importante dans la perception des participants concernant le diagnostic des tumeurs cérébrales.
- 12,5% pour "Autre" : Un petit pourcentage de participants (12,5%) a indiqué "Autre" comme méthode d'imagerie médicale associée au diagnostic. Cette catégorie "Autre" pourrait inclure d'autres techniques d'imagerie médicale moins courantes, telles que la spectroscopie par résonance magnétique (SRM), les scanners cérébraux ou d'autres approches spécialisées.




Figure III. 4. Résultat 2

- Lorsqu'il a été posé la question de savoir s'il pense qu'un meilleur moyen doit être trouvé afin d'optimiser la détection d'une tumeur cérébrale après un scan, nous avons obtenu les résultats suivants :
 - 75% ont répondu « Oui ». Une majorité des participants au questionnaire face à cette question pense qu'un meilleur moyen devrait être mis en place afin de pouvoir optimiser la précision du diagnostic actuel.
 - 12,5% ont répondu « Non ». Cela implique que 12,5% des participants au questionnaire sont satisfaits de la méthode actuelle qui est mise en place
 - 12,5% ont répondu « Je ne sais ». Impliquant que ces derniers sont plus ou moins satisfait de la méthode actuelle




Figure III. 5. Résultat 3

- Et enfin lorsqu'il a été posé la question de savoir le problème qu'ils ont avec la méthode de détection actuelle dans les services de santé ?
 - 62,5% ont répondu que leur principal souci avec la méthode actuelle réside dans le fait que cela prend beaucoup de temps et n'est pas souvent très optimal pour une détection rapide.
 - 25% quand à eux ont répondu que la méthode actuelle est rapide mais pas très optimale
 - 12,5% ont quant à eux répondu favorablement à la méthode actuelle de diagnostic




Figure III. 6. Résultat 4

Grâce à l'ensemble des résultats obtenus, il est évident à travers le questionnaire qu'une grande majorité de la population interrogée rencontre un problème avec la méthode de détection actuelle. Et de ce fait aimerait voir une amélioration dans le processus de diagnostic des tumeurs cérébrales. Afin de répondre à ce problème, nous nous proposons de présenter les méthodes de l'intelligence artificielle afin de pallier à celui-ci.

Conclusion

Pour conclure ce chapitre sur la présentation de la situation, il est évident que la qualité et la préparation rigoureuse des données sont essentielles à la réussite de notre quête. La sélection minutieuse des données, ainsi que l'assurance de leur légitimité et de leur pertinence par rapport aux objectifs du projet, sont autant de préoccupations essentielles.

En outre Ce chapitre met l'accent sur la nécessité d'une présentation du site de recherche, de la présentation et l'analyse appropriés des données pour la réalisation de notre travail. Une stratégie rigoureuse axée sur les données collectées garantissent que le fondement de notre quête et la stratégies a mettre en place pour la résolution de notre tâche. Dans le chapitre suivant nous examinerons en détail l'analyse et la présentation des résultats pour la proposition d'intervention.

CHAPITRE IV : ANALYSE DE LA SITUATION ET PROPOSITION D'INTERVENTION

Introduction

Prendre du recul pour évaluer la situation actuelle, présenter notre proposition d'intervention, définir clairement nos objectifs, élaborer une stratégie d'action et examiner la faisabilité de notre approche est essentiel dans notre démarche visant à améliorer la détection précoce des tumeurs cérébrales grâce à l'intelligence artificielle.

Ce chapitre est donc consacré à la contemplation stratégique, qui nous oriente vers la réalisation de notre mission. Nous commençons par un examen du scénario actuel, en analysant les lacunes existantes dans les approches de détection des tumeurs cérébrales. Ensuite vient l'intervention que nous proposons. Nous expliquons comment nous comptons utiliser l'intelligence artificielle pour combler ces lacunes et améliorer la détection précoce. Ensuite, nous décrivons explicitement les objectifs de notre solution et enfin, nous évaluons l'aspect pratique de notre méthode, en tenant compte des ressources disponibles et des limites budgétaires. Il s'agit d'une étape cruciale pour s'assurer que notre approche est faisable et réalisable.

IV.1. Présentation et analyse de la situation

Dans le domaine médical et principalement dans la majorité des centres de sante présent au Cameroun, la détection des tumeurs cérébrales repose sur des méthodes traditionnelles d'imagerie médicale et d'analyse visuelle. Dans cette situation, les professionnels de la santé dépendent principalement de techniques telles que l'imagerie par résonance magnétique (IRM) et la tomodensitométrie (scanner) pour visualiser le cerveau et identifier les anomalies potentielles. Bien que ces méthodes aient été révolutionnaires dans le domaine médical, elles présentent encore des défis importants :

- **Subjectivité de l'interprétation :** Les connaissances et l'expérience du radiologue sont utilisées pour interpréter les images radiologiques. L'interprétation individuelle des résultats peut entraîner des faux positifs ou des faux négatifs.
- **Détection tardive :** Les tumeurs cérébrales, en particulier à un stade précoce, peuvent être difficiles à identifier par l'imagerie standard. Par conséquent, le diagnostic est souvent retardé, ce qui compromet les perspectives d'une thérapie efficace.
- **Charge de travail élevée :** L'analyse manuelle d'énormes quantités d'images radiologiques est une tâche ardue et chronophage pour les professionnels de la santé. Cela peut entraîner des retards de diagnostic et une charge de travail supplémentaire.
- Les radiologues ont besoin d'une formation substantielle pour acquérir leurs compétences en matière d'identification des tumeurs cérébrales, ce qui peut coûter beaucoup de temps et d'argent.

La subjectivité et l'imprévisibilité des résultats, ainsi que la question du diagnostic précoce, sont les principaux défis à relever pour identifier les cancers du cerveau sans l'aide de l'IA. Les approches traditionnelles ne permettent pas toujours de détecter systématiquement de petites anomalies ou des tumeurs à un stade précoce, ce qui peut entraîner des retards de traitement et des répercussions catastrophiques pour les patients.

En outre, la charge de travail élevée des professionnels de la santé et l'exigence de compétences spécialisées pèsent encore davantage sur les institutions de soins de santé. Il est donc essentiel de créer des méthodes plus efficaces et plus fiables de détection précoce des tumeurs cérébrales, ce qui peut être réalisé en intégrant l'intelligence artificielle dans le processus d'analyse de l'imagerie médicale. Cette technologie peut contribuer à l'automatisation de la détection, à la réduction de la subjectivité et à la précision globale de la détection des tumeurs cérébrales.

IV.2. Intervention proposée et justification

L'intervention proposée, basée sur l'intelligence artificielle pour le diagnostic précoce des tumeurs cérébrales, repose sur la promesse d'améliorer les soins de santé, d'accroître la précision du diagnostic et de contribuer à la recherche médicale. La création d'une application web qui exploite notre modèle algorithmique est au cœur de cette intervention. Cette application permettra non seulement un diagnostic plus précis et plus sensible, mais elle facilitera son intégration et adoption ciblée à travers une interface conviviale pour les professionnels de la santé.

La justification de notre intervention repose sur les lacunes que présente les méthodes traditionnelles. Particulièrement dans notre pays où les centres de santé sont très souvent confrontés à un manque de professionnel spécialisé pour interpréter correctement les résultats radiologiques et à un manque de ressource. Et tant bien même ceci disponible dans d'autres, le processus de diagnostic de tumeur cérébrales est très difficile et peut prendre un temps considérable.

IV.3. Objectifs de l'intervention

IV.3.1. Objectif générale

Notre objectif est de développer un modèle d'intelligence artificielle très précis, et fiable, capable de détecter rapidement et avec précision les tumeurs du cerveau sur les radiographies, afin d'améliorer les chances de traitement précoce et de survie des patients.

IV.3.2. Objectif spécifique

Pour atteindre l'objectif général, plusieurs objectifs spécifiques sont définis :

- Construire la base de Données de Formation Complète
- Développer un modèle IA performant
- Optimiser la sensibilité et spécificité
- Valider cliniquement la solution
- Favoriser l'adoption
- Contribuer à la recherche médicale

IV.4. Composantes de l'intervention envisagée

II.4.1. Anaconda

Anaconda est une importante distribution open-source des langages informatiques Python et R pour le calcul scientifique, la recherche de données, l'apprentissage automatique ou profonde et d'autres sujets connexes. Son objectif est de faciliter l'installation, la maintenance et le travail avec de nombreuses bibliothèques et outils souvent utilisés dans ces domaines.

Anaconda nous fournit les outils suivants qui font de lui un choix majeur pour la réalisation de notre solution :

- **Conda** : Un système de gestion de paquets et d'environnement qui vous permet d'établir des environnements distincts pour différents projets. Cela permet d'éviter les problèmes de dépendance entre les paquets. Conda est capable d'installer, de mettre à jour et de gérer des paquets de logiciels.

INTELLIGENCE ARTIFICIELLE ET DETECTION PRECOCE DES TUMEURS CEREBRALES A PARTIR D'IMAGES RADIOLOGIQUES

- **Anaconda Navigator** : Une interface utilisateur graphique (GUI) pour gérer les environnements, installer des paquets et lancer des programmes. Elle est particulièrement pratique pour les personnes qui préfèrent une interface graphique à la ligne de commande.
- **Jupyter Notebook** : Un environnement interactif basé sur le web pour créer et partager des documents avec du code en direct, des équations, des visualisations et de la prose narrative. Il est utilisé pour l'analyse de données, la visualisation et les expériences d'apprentissage automatique.
- **Python et R** : Anaconda comprend les langages de programmation Python et R, ainsi qu'un certain nombre de bibliothèques remarquables dans le domaine de la science des données et de l'apprentissage automatique.

Les scientifiques des données, les chercheurs et les développeurs utilisent Anaconda pour créer des environnements reproductibles, gérer les dépendances et collaborer à des projets d'analyse de données, d'apprentissage automatique et de recherche scientifique. Anaconda est très utile pour travailler avec des piles de programmes complexes et de nombreuses versions de bibliothèques.

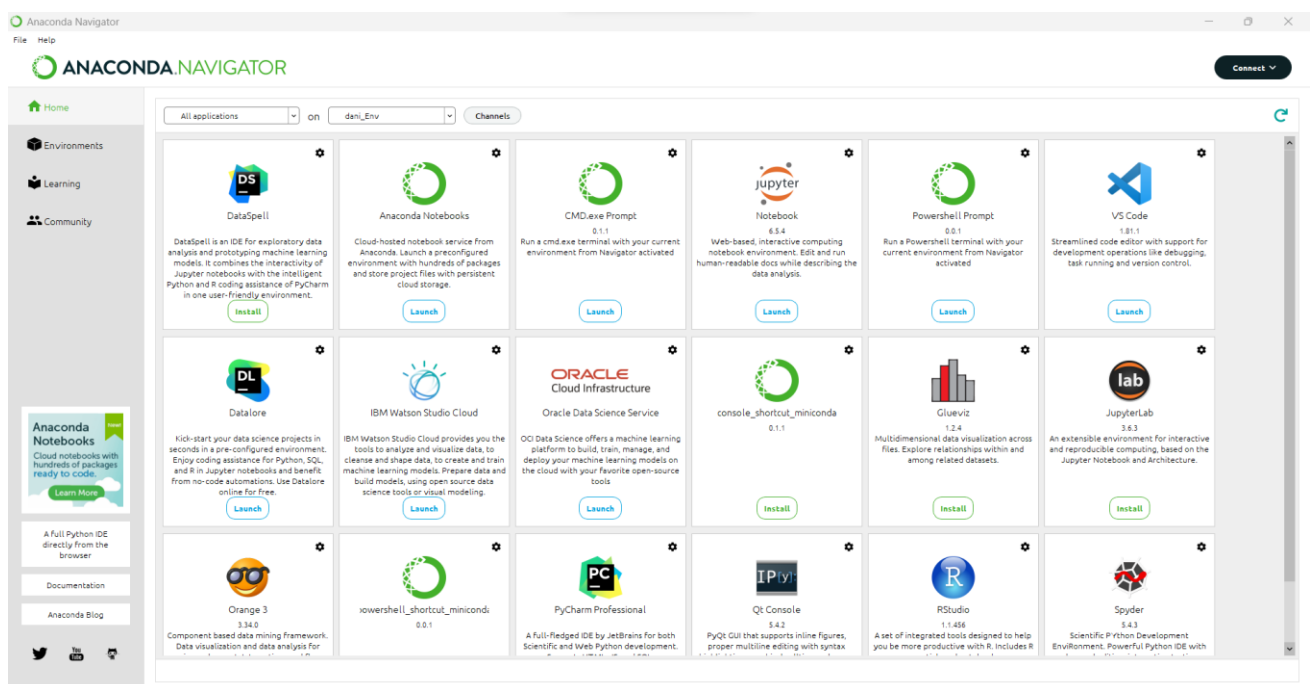


Figure IV. 1. Présentation de l'outil Anaconda (anaconda.com s.d.) ^j

j. <https://www.anaconda.com/products/distribution>

II.4.2. Jupyter Notebook

Jupyter Notebook est un logiciel interactif en ligne, gratuit et open-source, qui permet de créer et de partager des documents contenant du code, des équations, des visualisations et de la prose narrative en direct. Il est largement utilisé pour l'analyse et la visualisation des données, les expériences d'apprentissage automatique, la recherche scientifique et l'enseignement. Le mot "Jupyter" est un mélange de trois langages de programmation : Julia, Python et R.

Voici quelques caractéristiques et aspects clés de Jupyter Notebook qui favorise son choix pour la réalisation de notre solution :

- Jupyter Notebook offre un environnement interactif dans lequel vous pouvez créer et exécuter du code dans des cellules. Vous pouvez exécuter les cellules de code individuellement, ce qui est important pour l'examen étape par étape et le débogage.
- Jupyter Notebook était à l'origine destiné à prendre en charge Python, mais il prend actuellement en charge un large éventail de langages informatiques. Chaque notebook peut avoir son propre noyau, qui est un environnement d'exécution de code pour un certain langage de programmation. Jupyter s'adapte ainsi à une grande variété d'activités.
- Prise en charge du texte enrichi : Grâce à la notation LaTeX, vous pouvez utiliser les cellules Markdown pour générer du texte structuré, des en-têtes, des listes, des tableaux et même des calculs mathématiques. Cela vous permet d'élaborer des documents qui combinent du code, des explications et des images.
- Jupyter Notebook permet l'intégration de plusieurs cadres de visualisation de données tels que Matplotlib, Seaborn, Plotly, et d'autres. Pour visualiser vos données, vous pouvez produire des tracés, des diagrammes et des graphiques directement dans le notebook.

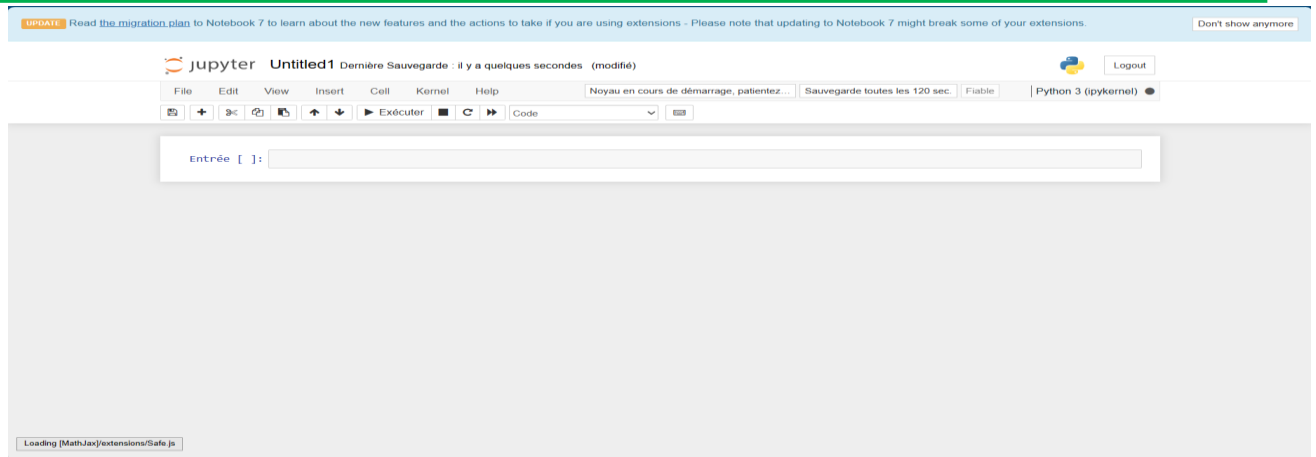


Figure IV. 2. Présentation de l'outil Jupyter (anaconda.com s.d.)

II.1.3. Hugging Face

Hugging Face est une plateforme open-source et une entreprise qui se concentre sur le traitement du langage naturel (NLP) et l'apprentissage automatique et profonde. La plateforme Hugging Face est bien connue de la communauté du traitement du langage naturel pour ses contributions, et elle fournit un certain nombre d'outils et de ressources pour travailler avec des modèles de traitement du langage naturel.

Quelques aspects clés de la plateforme Hugging Face inclus :

- **La bibliothèque Transformers** est l'une des offres les plus populaires. Elle propose un ensemble varié de modèles NLP de pointe pré-entraînés, comprenant à la fois des modèles plus anciens tels que BERT, GPT et RoBERTa et des modèles plus récents. Ces modèles peuvent être affinés pour des tâches de TAL spécifiques telles que la catégorisation de textes et l'identification d'entités nommées, entre autres.
- Hugging Face fournit un dépôt centralisé connu sous le nom de "**Model Hub**" dans lequel vous pouvez découvrir un grand nombre de modèles pré-entraînés, ainsi que leur code et leur documentation. Cela facilite l'accès, l'expérimentation et le déploiement des modèles d'intelligence artificielle.
- Hugging Face propose des "**pipelines**" préconstruits qui facilitent l'utilisation de modèles pré-entraînés pour les tâches typiques, notamment la création de texte, d'image et bien d'autre. Cela simplifie l'intégration des capacités des algorithmes d'IA dans les applications des développeurs.

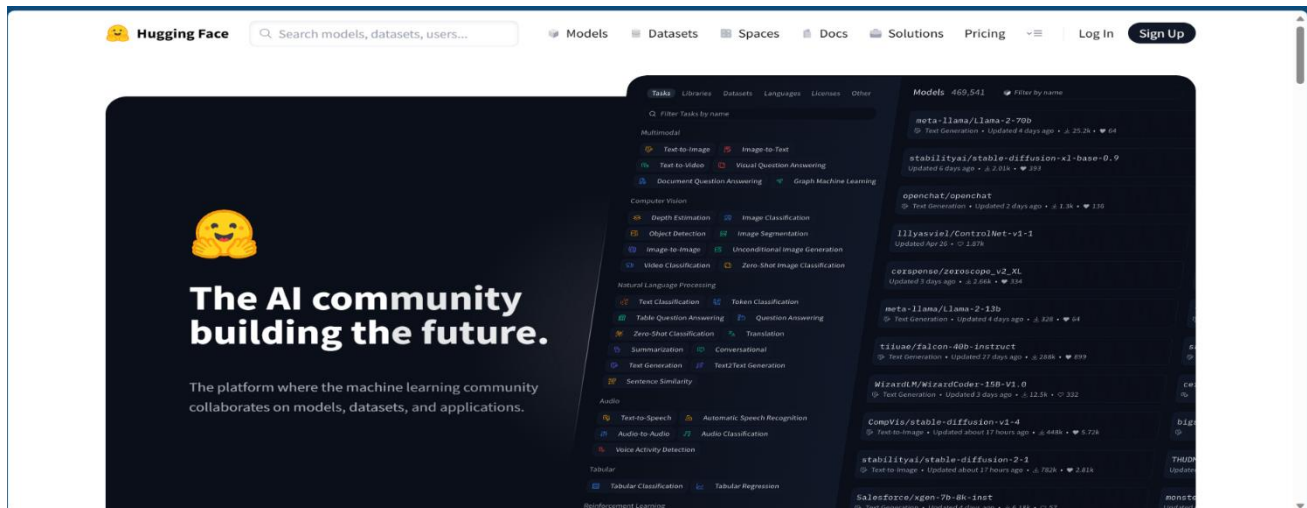


Figure IV. 3.Présentation de l'interface hugging face (huggingface.co s.d.)^k

II.1.4. ReactJS

React, souvent connu sous le nom de React.js ou ReactJS, est une boîte à outils JavaScript open-source développée par Facebook pour la création d'interfaces utilisateur, notamment pour la création d'applications web dynamiques et interactives. Il est couramment utilisé pour développer des applications à page unique (SPA) et gérer la couche d'affichage des applications web.

L'avantage d'utilisation de React inclus :

- Architecture basée sur les composants : La notion de séparation des interfaces utilisateur en composants réutilisables est au cœur de React. Chaque composant représente un aspect différent de l'interface utilisateur et peut être combiné pour créer des interfaces plus complexes.
- Le DOM virtuel est une version virtuelle du modèle d'objet de document (DOM) utilisé par React. Lorsque l'état d'un composant change, React calcule efficacement les modifications minimales nécessaires pour mettre à jour le DOM réel, éliminant ainsi les goulets d'étranglement en matière de performances.
- JSX (JavaScript XML) : JSX est une extension syntaxique de JavaScript qui vous permet de construire un code de type HTML à l'intérieur du code JavaScript. JSX facilite la spécification de la structure et de l'interface utilisateur de vos composants.

k. <https://www.huggingface.co>

- Les crochets (Hooks) : Les crochets sont des méthodes introduites dans les versions de React 16.8 qui vous permettent d'accéder à l'état de React et aux fonctionnalités du cycle de vie à partir de composants fonctionnels. Ils facilitent la gestion de l'état et des effets secondaires dans les composants fonctionnels en étant plus brefs et plus lisibles.

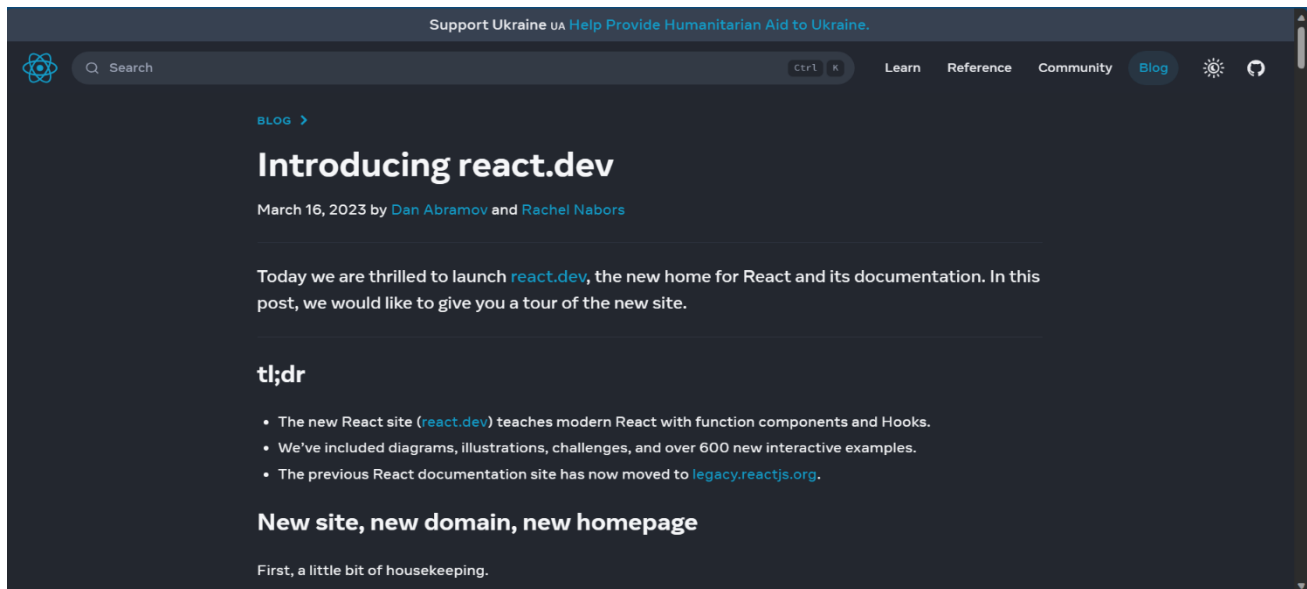


Figure IV. 4. Interface de ReactJS (react.dev s.d.)

II.1.5. Visual Studio Code (VS Code)

VSCode de Microsoft, ou Visual Studio Code, est un éditeur de code léger, libre et gratuit. Il est fréquemment utilisé par les programmeurs pour écrire du code dans un certain nombre de langages informatiques.

Voici quelques-uns des principaux avantages d'utilisation de VSCode :

- **Support de nombreux langages** : Grâce à des extensions téléchargeables, VSCode prend en charge un large éventail de langages de programmation. Vous pouvez modifier l'éditeur pour répondre à vos besoins personnels.
- VSCode est apprécié pour son interface utilisateur claire et intuitive, qui comprend des fonctionnalités telles que la coloration syntaxique, l'autocomplétions, l'autoformatages et la navigation facile dans le code.
- **Extensions** : L'écosystème d'extensions est l'un des principaux atouts de VSCode. Des extensions peuvent être ajoutées à l'éditeur pour améliorer son utilité, que ce soit pour le contrôle de version, le débogage, la gestion de projet, l'interaction avec des services en nuage ou d'autres objectifs particuliers.

- **Intégration Git** : VSCode supporte l'intégration native de Git, ce qui vous permet de suivre les changements de code et de gérer les branches directement depuis l'éditeur.
- **Terminal intégré** : VSCode dispose d'un terminal intégré qui vous permet d'exécuter des commandes directement depuis l'éditeur, ce qui est très pratique pour le travail de développement.
- **Débogage intégré** : Vous pouvez déboguer votre code directement à partir de VSCode, en définissant des points d'arrêt, en inspectant les variables et en parcourant le code.



Figure IV. 5. Visual Studio Code (code.visualstudio.com s.d.)^l

II.1.6. Python

Python est un langage de programmation interprété. Il a un large éventail d'utilisations. Python est utilisé comme langage d'introduction à la programmation dans certains lycées et universités car il est simple à apprendre, mais il est également utilisé par des ingénieurs logiciels professionnels comme Google, la NASA, et Lucasfilm Ltd. Python est donc le langage de programmation le plus utilisé dans l'apprentissage automatique et la recherche de données.



Figure IV. 6. Python (python.developpez.com s.d.)^m

IV.1.7. JavaScript

JavaScript est un langage informatique populaire qui est surtout connu pour son utilisation dans la création de sites web dynamiques et interactifs. Il s'agit d'une technologie fondamentale de développement web qui permet aux développeurs de concevoir un large éventail de fonctionnalités et de caractéristiques pour les applications en ligne. Tous les navigateurs web actuels prennent en charge JavaScript, ce qui en fait un outil essentiel pour le développement frontal et, de plus en plus, pour le développement dorsal.

l. <https://www.code.visualstudio.com>

m. <https://www.python.developpez.com>



Figure IV. 7. JavaScript (bing.com s.d.)

IV.1.8. TensorFlow

TensorFlow est un framework open source de Google utilisé principalement pour construire des modèles d'apprentissage automatique et d'apprentissage profond. C'est l'une des bibliothèques les plus connues et les plus utilisées dans le domaine de l'intelligence artificielle. TensorFlow présente les caractéristiques et les points critiques suivants :

- TensorFlow fournit un environnement de développement polyvalent qui vous permet de créer un large éventail de modèles d'apprentissage automatique, tels que des réseaux neuronaux profonds, des modèles de régression, des modèles de classification, des modèles de traitement du langage naturel (NLP), des modèles de vision par ordinateur, et bien d'autres encore.
- TensorFlow utilise un modèle de programmation basé sur les graphes de calcul. Cela signifie que vous devez d'abord spécifier le graphe des opérations (calculs) que vous avez l'intention de faire avant de les exécuter. Cette méthode permet une gestion fine des flux de données et simplifie la répartition des calculs entre les Central Processing Unit (CPU) et les Graphical Processing Unit (GPU).
- TensorFlow est censé exploiter les accélérations matérielles telles que les unités de traitement graphique (GPU) et les unités de traitement extensibles (TPU), ce qui permet d'accélérer considérablement l'apprentissage des modèles.
- TensorFlow intègre la bibliothèque Keras, une API conviviale pour la création de réseaux neuronaux profonds. Cela permet de créer et d'entraîner rapidement des modèles profonds à l'aide de l'API de haut niveau de Keras.
- TensorFlow facilite le déploiement de modèles sur de nombreuses plateformes, y compris les applications mobiles, les systèmes embarqués, les serveurs et le cloud.



Figure IV. 8. TensorFlow (tensorflow.org s.d.)

IV.5. Stratégies d'action

IV.5.1. Architecture de la solution

La mise en œuvre de notre solution d'intelligence artificielle (IA) nécessite une approche bien pensée pour assurer la réussite du projet. Nous allons examiner notre plan d'action étape par étape pour la mise en œuvre de cette solution. Afin d'atteindre notre but fixé dans notre objectif, nous proposons une solution basée sur une classification multi-class. Notre base de données d'image est constituée de 4 classes d'images, 3 correspondants aux trois types de tumeur cérébrale majeur et récurrent et la dernière classe correspond à l'absence de tumeur (c'est-à-dire cerveau pas malade). Le processus de notre travail est détaillé comme suit :

a. Prétraitement des données :

- Normalisation des images radiologiques pour les mettre à une échelle commune.
- Suppression du bruit et des artefacts pour améliorer la qualité des images.
- Recadrage et redimensionnement des images pour obtenir une taille homogène.

b. Extraction des caractéristiques :

- Utilisation d'un réseau neuronal convolutif pré-entraîné (ex. : ResNet, VGG) pour extraire automatiquement les caractéristiques des images radiologiques.
- Les couches convolutives permettent de capturer les motifs et les structures importantes des tissus cérébraux.

c. Réseau de détection :

- Utilisation d'un réseau de neurones spécifiquement conçu pour la détection d'objets, tel qu'un détecteur d'objets basé sur le YOLO (You Only Look Once) ou Faster R-CNN.
- Ce réseau prend les caractéristiques extraites en entrée et prédit les boîtes englobantes des tumeurs cérébrales et leur probabilité d'appartenance à cette classe.

d. Entraînement du modèle :

- Utilisation d'un ensemble de données annotées comprenant des images radiologiques avec les régions des tumeurs cérébrales marquées.
- L'entraînement se fait par rétropropagation du gradient pour ajuster les poids du réseau de détection en fonction des annotations de vérité terrain.

e. Validation et ajustement :

- Division de l'ensemble de données en ensembles d'entraînement et de validation pour évaluer la performance du modèle.
- Ajustement des hyperparamètres du réseau pour optimiser les performances de détection.

f. Évaluation du modèle :

- Utilisation d'un ensemble de test distinct pour évaluer les performances du modèle sur des données non vues auparavant.
- Calcul des métriques d'évaluation telles que la précision, la sensibilité, la spécificité et l'AUC.

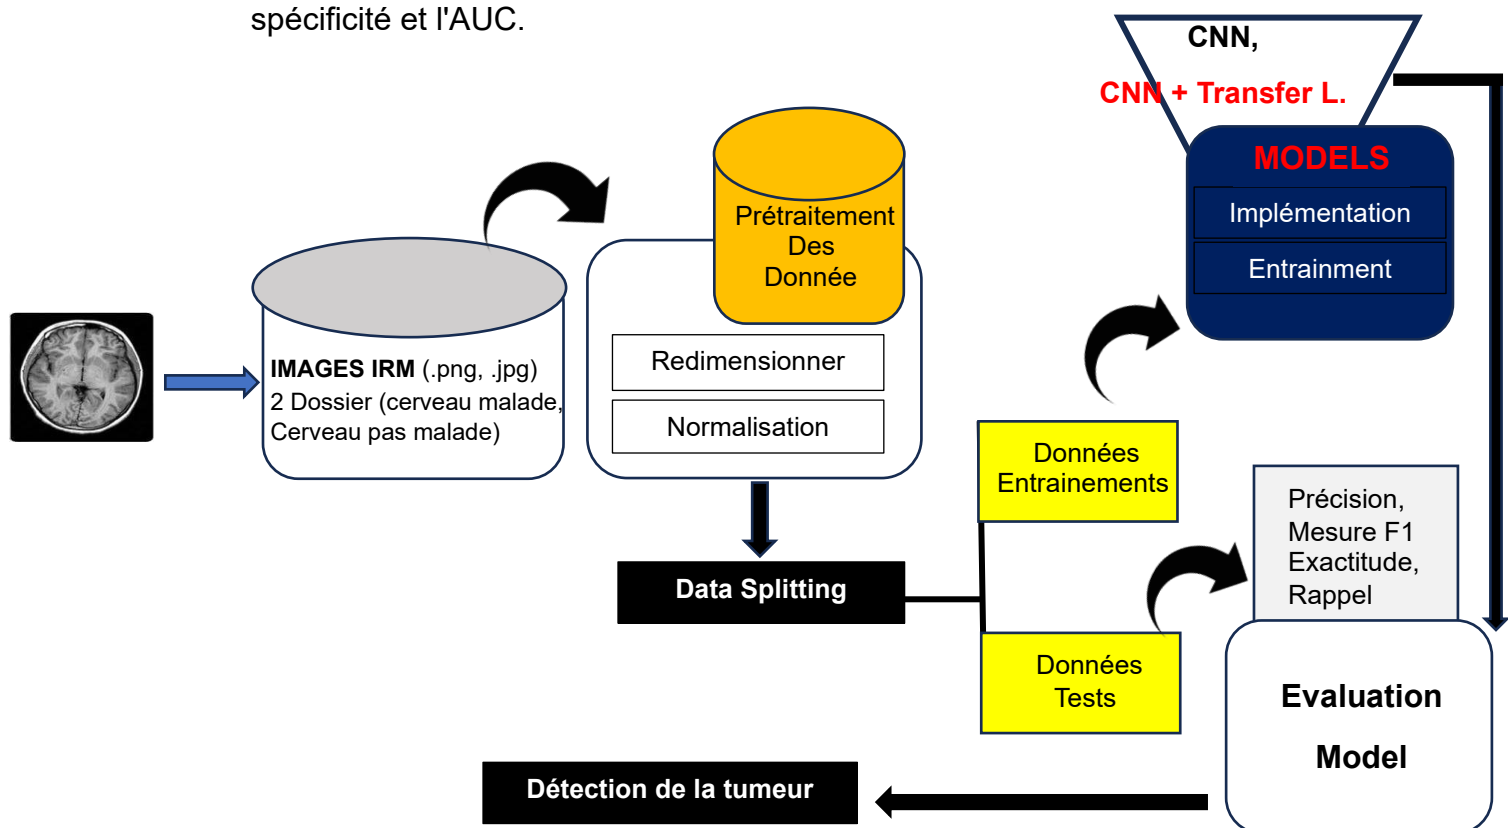


Figure IV. 9 Architecture de la solution

IV.5.2. Présentation du Jeu de données sur les tumeurs cérébrales

L'ensemble de données utilisé a été téléchargé sur la plateforme populaire de data science « **Kaggle** ». Il est composé d'une collection d'image des tumeurs cérébrales provenant d'un ensemble de données bien connus dans le domaine de la classification des tumeurs cérébrales (brain_data_tumors). Le nombre d'échantillons dans l'ensemble est suffisant pour former un algorithme d'apprentissage profond.

Cet ensemble de données a été utilisé pour étudier la catégorisation des types de tumeurs à l'aide d'architectures de réseaux neuronaux profonds, ainsi que pour étudier certaines des possibilités d'apprentissage par transfert sur ce jeu. Ces images sont prétraitées et segmentées, chaque segment correspondant à une classe de tumeur

- Nombre d'échantillons d'images : **21,672 images**
- Nombre de classes ou catégories : **4**
- Taille de l'ensemble des données : **226Mb**
- Source de données : [Crystal Clean: Brain Tumors MRI Dataset | Kaggle](#)
- Classes : ['glioma_tumor', 'no_tumor', 'meningioma_tumor', 'pituitary_tumor']

Les images sont tous classées par catégorie dans son dossier et annotée

IV.5.2.1. Fichier de donnée et répartition des données sur les tumeurs cérébrales

Cet ensemble de données est constitué de 4 dossiers et chaque dossier est constitué d'une série de fichiers d'image avec l'extension .jpg. Chacun de ces fichiers .jpg correspond à une classe d'image.

Nom	Statut	Modifié le	Type	Taille
glioma_tumor	✓	23/08/2023 07:36	Dossier de fichiers	
meningioma_tumor	✓	23/08/2023 07:36	Dossier de fichiers	
no_tumor	✓	23/08/2023 07:36	Dossier de fichiers	
pituitary_tumor	✓	23/08/2023 07:36	Dossier de fichiers	

Figure IV. 10. Présentation du fichier des données

- Nombre de fichier pour type de tumeur gliome : **6307 images**
- Nombre de fichier pour absence de tumeur : **3066 images**
- Nombre de fichier pour type de tumeur méningiome : **6391 images**
- Nombre de fichier pour type de tumeur hypophysaire : **5908 images**

La répartition de chaque type de tumeur sur l'ensemble des données nous donnent :




Figure IV. 11. Répartition des données

IV.5.2.2. Prétraitement et préparation du dataset

Pour préparer notre base de données d'image afin qu'elle soit prête d'être utilisée dans la construction de notre model, nous procédons par une série de prétraitement comme suit ;

- **Choisir le dataset**

La première étape consiste à sélectionner l'ensemble de notre base de données contenant 21,672 images d'IRM du cerveau réparties sous 4 classes dans 4 dossiers et ensuite le charger dans une variable de notre espace de travail avec la méthode `path.join()` du module `os` intégrée dans notre environnement python.

- **Préparer l'ensemble de données d'entraînement**

L'ensemble de données est ensuite chargé et préparé pour la formation. Il s'agit de diviser l'ensemble de données en ensembles de validation et de test, puis de normaliser les valeurs des pixels de l'image dans une fourchette de 0 à 1 en utilisant la méthode **One Hot Encoder**

- **Créer des données de test et les étiqueter**

Nous utiliserons l'ensemble d'images et d'étiquettes d'entraînement pour entraîner le CNN. Nous utiliserons la méthode **shuffle ()** pour mélanger les données. Nous attribuerons des étiquettes aux données en convertissant les étiquettes des classes catégorielles en vecteurs codés à un seul point. Après ces trois étapes nos données sont enfin prêt a être utilisée pour la construction de notre model

```
labels = ['glioma_tumor', 'no_tumor', 'meningioma_tumor', 'pituitary_tumor']
```

Figure IV. 12. Création des étiquettes pour les classes

```
X_train = []
y_train = []
image_size = 150
base_dir = "C:/Users/Lenovo/OneDrive/Desktop/ECOLE5/source_code/data_2"
for i in labels:
    folderPath = os.path.join(base_dir, 'Training', i)
    for j in tqdm(os.listdir(folderPath)):
        img = cv2.imread(os.path.join(folderPath, j))
        img = cv2.resize(img, (image_size, image_size))
        X_train.append(img)
        y_train.append(i)

for i in labels:
    folderPath = os.path.join(base_dir, 'Testing', i)
    for j in tqdm(os.listdir(folderPath)):
        img = cv2.imread(os.path.join(folderPath, j))
        img = cv2.resize(img, (image_size, image_size))
        X_train.append(img)
        y_train.append(i)

X_train = np.array(X_train)
y_train = np.array(y_train)
```

100%	5257/5257	[00:08<00:00, 631.23it/s]
100%	2456/2456	[00:02<00:00, 1055.19it/s]
100%	5221/5221	[00:06<00:00, 781.65it/s]
100%	4748/4748	[00:07<00:00, 596.91it/s]
100%	1150/1150	[00:02<00:00, 514.81it/s]
100%	610/610	[00:00<00:00, 732.39it/s]
100%	1170/1170	[00:02<00:00, 581.02it/s]
100%	1160/1160	[00:02<00:00, 484.22it/s]

Figure IV. 13. Chargement du dataset et splitting

```
# Normalisation du modele avec One Hot Encoder
y_train_new = []
for i in y_train:
    y_train_new.append(labels.index(i))
y_train = y_train_new
y_train = tf.keras.utils.to_categorical(y_train)

y_test_new = []
for i in y_test:
    y_test_new.append(labels.index(i))
y_test = y_test_new
y_test = tf.keras.utils.to_categorical(y_test)
```

Figure IV. 14. Normalisation des données

IV.5.3. Procédure d'implémentation

Dans l'implémentation de notre modèle, nous avons utilisé deux approches. Une approche par apprentissage normal et un autre, apprentissage par transfert. L'apprentissage par transfert est une technique d'apprentissage automatique qui consiste à utiliser des modèles pré-entraînés dans l'implémentation d'un algorithme pour la construction d'un model afin d'obtenir de meilleur résultat plus optimisé. Pour cela nous avons choisi d'appliquer deux model afin de les comparés et sélectionner le meilleur en termes de précision, rappel et F1 score pour le déploiement et l'exploitation.

IV.5.3.1. Utilisation d'un CNN normale

L'implémentation de notre modèle se fait avec l'outils anaconda, plus précisément jupyter. Apres leurs ouvertures, nous créons on fichier jupyter, et dans le fichier, nous commençons tout d'abord par l'importation des librairies nécessaires. Parmi ces librairies nous avons ;

- TensorFlow qui intègre la toutes les librairies de keras et est utilisé ici pour la construction de notre modèle. Ensuite nous avons la librairie OS qui nous permet d'avoir accès au répertoire de l'ordinateur. PIL pour l'importation et manipulation des images, Keras pour la construction de notre CNN, numpy et pandas qui sont des librairies incontournables en ML et DL et sont utilisés ici

pour le traitement matriciel des valeurs, seaborn et matplotlib sont utilisées pour le traçage des courbe et tendances

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import os
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.metrics import classification_report, confusion_matrix
from PIL import Image
import cv2
import tensorflow as tf
from tqdm import tqdm
from keras.models import Sequential
from keras.layers import Conv2D
from keras.layers import MaxPooling2D
from keras.layers import Flatten
from keras.layers import Dense
import random
```

Figure IV. 15. Importation des librairies CNN normale

- Ensuite les données sont chargées et prétraité comme décrit dans la partie le **IV.5.2.2.** de ce chapitre afin d'être conforme pour la prochaine étape

Remarque : il faut noter que lors de la séparation des données en données de test et de validation, cela a été fait suivant un pourcentage (75% de l'ensemble des données affectées aux données de test et 25% de l'ensemble des donnée affectées aux données de validation)

- Après l'étape précédente vient ensuite la construction du model. Nous passons une première couche de convolution dans laquelle nous paramétrons 3 neurones, la taille des images a entrainer, la fonction d'activation relu. Ensuite une couche de pooling, et enfin deux couche Fully Connected Layer (Dense) dont la dernière a pour nombre de neurone correspondant au nombre de classe a prédire et une fonction d'activation softmax

```
model = tf.keras.Sequential([
    #1. Premiere couche de Convolution
    Conv2D(3, (3, 3), activation = 'relu', input_shape = (150, 150, 3)),
    #2. premier couche de Max pooling
    MaxPooling2D(2,2),
    #3. Deuxieme couche de Convolution
    Conv2D(6, (3, 3), activation = 'relu'),
    #4. Deuxieme couche de Max pooling
    MaxPooling2D(2,2),
    #5. Flattening
    Flatten(),
    #6. Dense
    Dense(10, activation='relu'),
    #7. Deuxieme couche de Dense
    Dense(nb_classes, activation='softmax')
])
```

Figure IV. 16. Construction du modèle CNN normale

- Ensuite nous compilons le modèle en évaluant la précision et en optimisant avec adam. Puis on lance l'entrainement du modèle

Compilation du modele

```
model.compile(optimizer = 'adam', loss = 'sparse_categorical_crossentropy', metrics=['accuracy'])
```

Entrainement du modele

```
history = model.fit(train_images, train_labels, batch_size=32, epochs=5, validation_split = 0.2)
```

```
Epoch 1/5  
443/443 [=====] - 39s 76ms/step - loss: 1.0622 - accuracy: 0.4959 - val_loss: 2.7184 - val_accuracy:  
0.0031  
Epoch 2/5  
443/443 [=====] - 30s 68ms/step - loss: 0.8284 - accuracy: 0.6484 - val_loss: 2.3904 - val_accuracy:
```

Figure IV. 17. Compilation et entrainement du modèle CNN normale

Résultat obtenu

a. La courbe ROC

La courbe ROC (Receiver Operating Characteristic) est une représentation graphique utilisée pour illustrer et analyser les performances d'un modèle d'apprentissage automatique. Elle permet d'évaluer l'efficacité d'un modèle à distinguer les classes positives et négatives en fonction de différents seuils de prédiction. La courbe ROC est construit en affichant le taux de vrais positifs (TPR) par rapport au taux de faux positifs (FPR) à différents niveaux de seuil. Le TPR, également connu sous le nom de sensibilité ou de rappel, est calculé comme $TP / (TP + FN)$. Le TFP est déterminé en divisant FP par $(FP + TN)$.

La courbe obtenue pour notre modèle est présentée ci-dessous

Epochs vs. Training et Validation Precision(Acc.)/Perte(loss)




Figure IV. 18 Courbe ROC du CNN normale

b. Matrice de confusion

Nous avons obtenu la matrice de confusion suivante

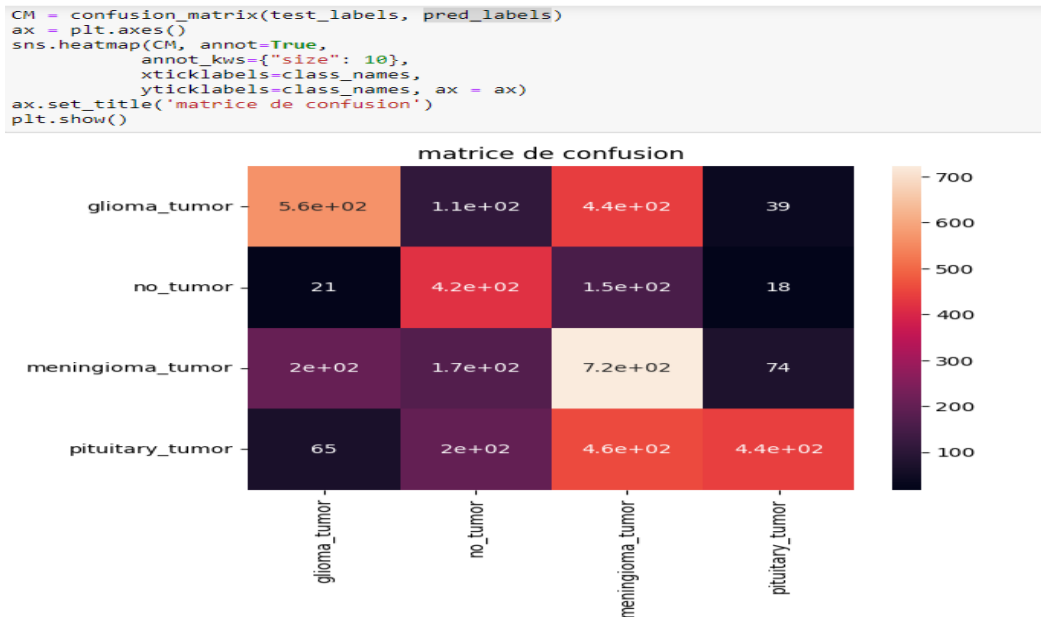


Figure IV. 19. Matrice de confusion CNN normale

Les différentes valeurs de la matrice sont les suivant :

Vrai Positif (TP) = $5.6e+02$: ce qui signifie que 560 images de classe positive ont été correctement classée par notre model

Vrai Négatif (TN) = $(4.2e+02) + (1.5e+02) + (1.7e+02) + (7.2e+02) + (2e+02) + (4.6e+02) + (4.4e+02) + 74 + 18$: 2652 images de la classe négative ont été correctement classée par notre model

Faux Positif (FP) = $(2e+02) + 21 + 65$ soit 286 images de la classe négative ont été mal classées par le model

Faux Négatif (FN) = $(1.1e+02) + (4.4e+02) + 39$ soit 589 images de la classe positive ont été mal classée par le model

c. Rapport de classification

Pour la classification avec le modèle CNN normal, nous obtenons une précision de qui varie entre 0,41 à 0,77 pour les 4 classes, un rappel qui varie entre 0,38 à 0,69, un score F1 qui varie entre 0,49 à 0,56. Pour une exactitude totale de $(0,52 * 100) = 52\%$ ce qui n'est pas un très bon résultat.

```
print(classification_report(test_labels,pred_labels))
```

	precision	recall	f1-score	support
0	0.66	0.49	0.56	1150
1	0.47	0.69	0.55	610
2	0.41	0.62	0.49	1170
3	0.77	0.38	0.51	1160
accuracy			0.52	4090
macro avg	0.58	0.54	0.53	4090
weighted avg	0.59	0.52	0.53	4090

Figure IV. 20. Rapport de classification CNN normale

IV.5.3.2. Utilisation d'un CNN + Transfer Learning (Efficient Net)

Nous commençons tout d'abord par le chargement et importation des librairies nécessaires. Parmi ces librairies nous avons ;

- TensorFlow qui intègre la toutes les librairies de keras et est utilisé ici pour la construction de notre modèle. Ensuite nous avons la librairie OS qui nous permet d'avoir accès au répertoire de l'ordinateur. PIL pour l'importation et manipulation des images. Et nous importons le model du transfert EfficientNetB0

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
import cv2
import tensorflow as tf
from tensorflow.keras.preprocessing.image import ImageDataGenerator
from tqdm import tqdm
import os
from sklearn.utils import shuffle
from sklearn.model_selection import train_test_split
from tensorflow.keras.applications import EfficientNetB0
from tensorflow.keras.callbacks import EarlyStopping, ReduceLROnPlateau, TensorBoard, ModelCheckpoint
from sklearn.metrics import classification_report, confusion_matrix
import ipywidgets as widgets
import io
from PIL import Image
from IPython.display import display, clear_output
from warnings import filterwarnings
```

Figure IV. 21. Importation des librairies

- Ensuite les données sont chargées et prétraité comme décrit dans la partie le **IV.5.2.2.** de ce chapitre afin d'être conforme pour la prochaine étape

- Téléchargement et affectation du module Efficient Net. Lors de cette phase, nous passons en paramètre les dimensions de l'image souhaité qui est dans notre cas 150 x 150 à travers la variable image_size

```
effnet = EfficientNetB0(weights='imagenet',include_top=False,input_shape=(image_size,image_size,3))
```

- Ensuite nous passons à la construction du model. La construction du model se fait à travers une série de ligne de code. Nous appliquons tout d'abord un procédé qui s'appelle le **pooling** grâce à la fonction *GlobalAveragePooling2D()* du module **keras.layers**. Ceci ajoute une couche de neurone dans notre réseau ce qui permet de sous-échantillonner une image lors de sa classification. Ensuite nous appliquons un procédé de dropout qui permet d'éviter le surapprentissage et enfin le dense layer qui est une couche qui prend en paramètre le nombre de classe a prédire et un fonction d'activation

```
model = mobilenet.output
# Utilisation du GlobalAveragePooling similaire au max pooling
model = tf.keras.layers.GlobalAveragePooling2D()(model)
# Dropout
model = tf.keras.layers.Dropout(rate=0.5)(model)
# Fonion d'activation Softmax
model = tf.keras.layers.Dense(4,activation='softmax')(model)
model = tf.keras.models.Model(inputs=mobilenet.input, outputs = model)
```

Figure IV. 22. Construction du modèle avec EfficientNet

- Ensuite nous faisons une description de notre model qui nous donne le nombre total de paramètre. Nous avons eu : 4,054,695 de paramètre

Entrée [15]: `model.summary()`

top_bn (BatchNormalization)	(None, 5, 5, 1280)	5120	['top_conv[0][0]']
top_activation (Activation)	(None, 5, 5, 1280)	0	['top_bn[0][0]']
global_average_pooling2d (GlobalAveragePooling2D)	(None, 1280)	0	['top_activation[0][0]']
dropout (Dropout)	(None, 1280)	0	['global_average_pooling2d[0][0]']
dense (Dense)	(None, 4)	5124	['dropout[0][0]']

=====

Total params: 4054695 (15.47 MB)
 Trainable params: 4012672 (15.31 MB)
 Non-trainable params: 42023 (164.16 KB)

Figure IV. 23. Description avec le modèle EfficientNet

- Ensuite nous passons à la compilation de notre model. Nous faisons la compilation du model en passant en paramètre un optimiseur qui nous permet

de minimiser la fonction d'erreur et de maximiser les performances de notre model

```
model.compile(loss='categorical_crossentropy',optimizer = 'Adam', metrics= ['accuracy'])
```

Figure IV. 24. Compilation du modèle avec EfficientNet

- Ensuite nous procédons à l'entraînement du model. Cela se fait a travers le méthode **fit()**. Cette prend en paramètre les données d'entraînement (x_train, y_train), les données de validation, le nombre d'époque (**epochs**) qui définit le nombre de fois notre model doit être entraîné (dans notre cas nous avons spécifié 12), un paramètre **callbacks** qui nous permet de contrôler l'entraînement afin de ne sauvegarder que le meilleur apprentissage.

```
history = model.fit(X_train,y_train,validation_split=0.1, epochs =12, verbose=1, batch_size=32,  
callbacks=[tensorboard,checkpoint,reduce_lr])
```

Figure IV. 25. Entraînement du modèle avec EfficientNet

- Nous faisons une prédiction sur les données de test afin d'évaluer notre modèle

```
pred = model.predict(x_test)  
pred = np.argmax(pred,axis=1)  
y_test_new = np.argmax(y_test,axis=1)  
69/69 [=====] - 22s 313ms/step
```

Figure IV. 26. Prédiction avec EfficientNet

Résultat obtenu :

a. La courbe ROC

La courbe ROC (Receiver Operating Characteristic) est une représentation graphique utilisée pour illustrer et analyser les performances d'un modèle d'apprentissage automatique. Elle permet d'évaluer l'efficacité d'un modèle à distinguer les classes positives et négatives en fonction de différents seuils de prédiction. La courbe ROC est construit en affichant le taux de vrais positifs (TPR) par rapport au taux de faux positifs (FPR) à différents niveaux de seuil. Le TPR, également connu sous le nom de sensibilité ou de rappel, est calculé comme $TP / (TP + FN)$. Le TFP est déterminé en divisant FP par $(FP + TN)$.

La courbe obtenue pour notre model est présentée ci-dessous




Figure IV. 27. Courbe ROC avec EfficientNet

b. Matrice de confusion

Nous obtenons la matrice de confusion suivant

Matrice de confusion




Figure IV. 28. Matrice de confusion avec EfficientNet

Les différentes valeurs de la matrice sont les suivant :

Vrai Positif (TP) = 6.5×10^2 : ce qui signifie que 650 images de classe positive ont été correctement classée par notre model

Vrai Négatif (TN) = $(3.1 \times 10^2) + (6.2 \times 10^2) + (5.9 \times 10^2) + 2 + 1$: 1,523 images de la classe négative ont été correctement classée par notre model

Faux Positif (FP) = 2 images de la classe négative ont été mal classées par le model

Faux Négatif (FN) = 1 image de la classe positive a été mal classée par le model

c. Le rapport de classification

```
print(classification_report(y_test_new,pred))
```

	precision	recall	f1-score	support
0	1.00	0.99	0.99	660
1	1.00	1.00	1.00	307
2	0.98	1.00	0.99	623
3	1.00	1.00	1.00	588
accuracy			0.99	2178
macro avg	0.99	0.99	0.99	2178
weighted avg	0.99	0.99	0.99	2178

Figure IV. 29. Rapport de classification avec EfficientNet

Pour la classification avec le modèle pré-entraîné **Efficient Net**, notre modèle final donne une précision de qui varie entre 0,98 à 1 pour les 4 classes, un rappel qui varie entre 0,99 à 1, un score F1 qui varie entre 0,99 à 1. Pour une exactitude totale de $(0,99 * 100) = 99\%$ ce qui est un très bon résultat et supérieure au CNN normale.

MODELE	RESULTAT		
	Précision	F1-Score	Rappel
CNN Normale	0,52	0,52	0,54
CNN + Transfert L.	0,99	0,98	0,99

D'après le tableau ci-dessous les résultats obtenus avec ce modèle par transfert **Efficient-Net** sera donc choisi en raison de plus de précision pour être déployé sur la plateforme de hugging face afin d'être plus accessible à travers plusieurs plateformes.

IV.5.3.3. Déploiement de la solution sur Hugging face

Après la sélection et l'obtention de notre modèle finale, vient ensuite la phase du déploiement. Il existe plusieurs plateformes pour le déploiement et hébergement des modèles d'apprentissage automatique et profond, parmi lesquelles nous pouvons citer ;

- Hugging face
- Streamlit Cloud
- Heroku
- Deta

- Replit

IV.5.3.3.1. *Avantage de Hugging face*

- Donne accès a des milliers de modèle NLP et autres
- Il est facile de tester le modèle sur le site web lui-même pour en vérifier l'exactitude sans avoir à le mettre en œuvre.
- Possède un espace "Hugging Face space" pour le déploiement d'applications de démonstration
- Prise en charge étendue de l'analyse linguistique et d'autres tâches pertinentes

IV.5.3.3.2. *Procédure de déploiement du modèle*

- Nous nous rendons sur le site officiel de hugging face à travers le lien : <https://huggingface.co> puis on procède à la création d'un compte
- La création du compte sur le site nous donne droit à une clé d'identifiant unique appelé **token**
- Ensuite dans nous installons deux librairies supplémentaire important a travers le mot clé : ***pip install transformers datasets***
- Nous procédons à l'importation des libraires dans un nouveau fichier jupyter

```
import numpy as np

from datasets import load_dataset, load_metric
from transformers import (
    AutoModelForSequenceClassification,
    AutoTokenizer,
    DataCollatorWithPadding,
    Trainer,
    TrainingArguments,
)
```

Figure IV. 30. Importation des librairies

- Ensuite nous spécifions notre modèle obtenu précédemment à travers

```
checkpoint = "effnet.h5"
```

Figure IV. 31. Importation du modèle choisi

- Puis dans l'étape suivante nous déclarons un ensemble de paramètre dans lequel nous spécifions le nom de notre modèle, notre base de données d'images, notre identifiant unique fourni par hugging face, se rassurer que le paramètre *push_to_hub* soit vrai pour transférer l'exécution du code dans notre dépôt créé dans notre compte hugging face

```

base_dir = "C:/Users/Lenovo/OneDrive/Desktop/ECOLIS/source_code/data_2"
raw_datasets = load_dataset(base_dir)

tokenizer = AutoTokenizer.from_pretrained(checkpoint)

tokenized_datasets = raw_datasets.map(tokenize_function, batched=True)

model = AutoModelForSequenceClassification.from_pretrained(checkpoint, num_labels=2)

training_args = TrainingArguments(
    "wolf_brain_tumor_model",
    per_device_train_batch_size=16,
    per_device_eval_batch_size=16,
    learning_rate=2e-5,
    weight_decay=0.01,
    evaluation_strategy="epoch",
    logging_strategy="epoch",
    log_level="error",
    push_to_hub=True,
    push_to_hub_model_id="wolf_brain_tumor_model",
    # push_to_hub_organization="huggingface",
    push_to_hub_token="hf_vetJPBgVxRR0tTVVaHtduvKucGHINRG1HC",
)

data_collator = DataCollatorWithPadding(tokenizer)

metric = load_metric(base_dir)

def compute_metrics(eval_preds):
    logits, labels = eval_preds
    predictions = np.argmax(logits, axis=-1)
    return metric.compute(predictions=predictions, references=labels)

```

Figure IV. 32. Configuration des paramètres pour exécuter sur hugging face

- Et enfin nous procédons à un nouvel entraînement

```

trainer = Trainer(
    model,
    training_args,
    train_dataset=tokenized_datasets["train"],
    eval_dataset=tokenized_datasets["validation"],
    data_collator=data_collator,
    tokenizer=tokenizer,
    compute_metrics=compute_metrics,
)

trainer.train()

```

Figure IV. 33. Entraînement sur hugging face

IV.5.3.4. Création d'une page client avec ReactJs pour exploiter notre modèle sur Hugging face

Après le déploiement de notre modèle dans notre dépôt sur hugging face, le modèle est ensuite prêt à être exploité par d'autre développeur et data scientist a travers une connexion internet. Dans la suite de notre travail nous avons choisi de créer une interface web plus conviviale et user friendly afin qui utilise notre modèle pour la prédiction. Nous avons donc choisi d'utiliser l'un des Framework javascript les plus populaire appelé reactJS. Pour installer reactJS sur pc nous procédons d'abord au téléchargement et installation de NodeJs en nous rendant directement sur le lien <https://nodejs.org/en/download> et choisissant la version correspondante a son système d'exploitation et par la suite en cliquant sur télécharger

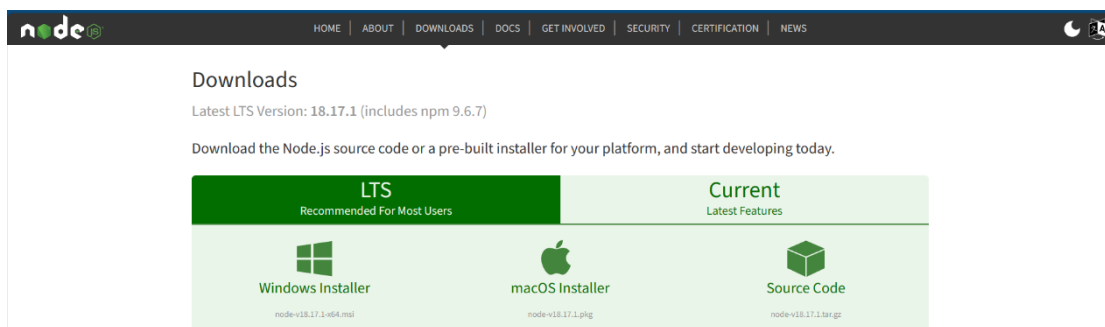


Figure IV. 34. Node Js (nodejs.org s.d.)

Après l'installation de NodeJs nous ouvrons notre terminal de notre system d'exploitation et écrivons les lignes de code suivantes afin d'installer reactJS

- npm install -g create-react-app


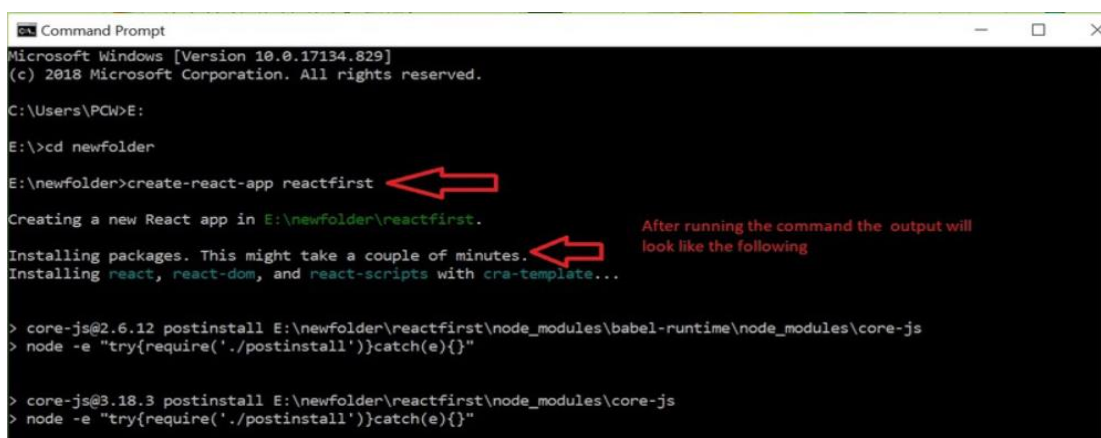


Figure IV. 35. Installation de reactJS

Ensuite nous créons un nouveau projet react avec la ligne de code

- create-react-app reactfirst



INTELLIGENCE ARTIFICIELLE ET DETECTION PRECOCE DES TUMEURS CEREBRALES A PARTIR D'IMAGES RADIOLOGIQUES

Figure IV. 36. Création d'un projet reactJS

Nous ouvrons ensuite notre projet avec l'éditeur de code VS Code puis on démarre le serveur reactJS et on procède au développement de l'interface cliente

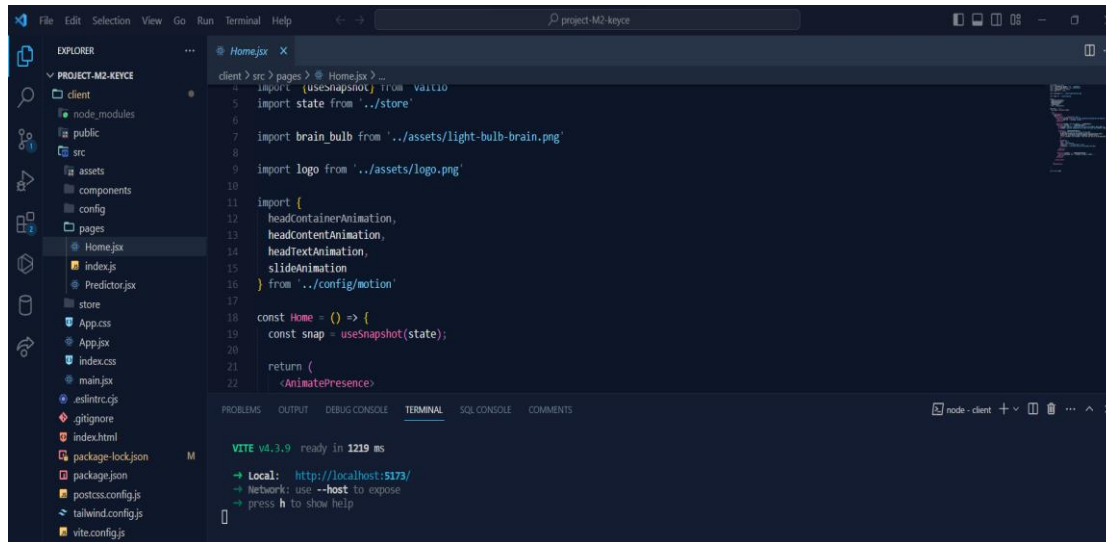


Figure IV. 37. Présentation de la structure du projet avec React

Résultat finale :




Figure IV. 38. Interface client

IV.6. Faisabilité

La réussite de notre quête dépend de sa faisabilité sur plusieurs aspects tel qu'économique et technique.

IV.6.1. Economique

PHASES	COUTS en FCFA	TOTAL en FCFA
		COUTS TOTAL DE REALISATION : 13 000 000 FCFA
Collecte des données	1 000 000	
Développement du modèle IA	10 000 000	
Intégration et déploiement	1 000 000	
Formation	500 000	
Maintenance et mis a jour	200 000	
Support Technique	300 000	

Tableau IV. 1 Faisabilité économiques

IV.6.1.1. Technique

LOGICIELS					
No	Outils	Versions	Prix Unitaire en FCFA	Prix Total en FCFA	
01	AVG Antivirus	20.4.3125	25 000	25 000	
02	MS Windows (System d'Exploitation)	11 (22h2)	150 000	150 000	
Prix TOTAL : 175 000 FCFA					
MATERIELS					
No	Désignations	Caractéristiques	Quantités	Prix Unitaire en FCFA	Prix Total en FCFA
01	Ordinateur	Laptop : LENOVO IdeaPad Gaming Processeur : AMD Ryzen RAM : 24Go GPU : NVIDIA GTX 1650Ti 6 Dédié Stockage : 1To SSD	01	700 000	700 000

INTELLIGENCE ARTIFICIELLE ET DETECTION PRECOCE DES TUMEURS CEREBRALES A PARTIR D'IMAGES RADIOLOGIQUES

02	Stockage	Clé USB Kingston 32 GB	01	15 000	15 000
03	Support Papier	Format A4 (poids de 96 - 110g of)	04	5 000	20 000
04	Régulateur de tension	A UPS capacité de 600 VA	01	50 000	50 000
Prix TOTAL : 785 000 FCFA					
HUMAINES					
No	Rôles	Acteurs	Durée en mois	Prix Unitaire en FCFA	Prix total en FCFA
01	Etude et choix de l'architecture	Ingénieur Data scientifique	02	300 000	600 000
02	Analyse et Conception	Ingénieur Data Scientiste	01	300 000	300 000
03	Développement interface utilisateur	Analyste Programmeur	02	200 000	200 000
04	Déploiement	Analyste Programmeur + ingénieure data scientifique	01	200 000	200 000
05	Test	Professionnel de santé	01	200 000	200 000
Prix TOTAL : 1 500 000 FCFA					
AUTRES					
No	Désignations		Durée par heure	Durée totale en mois	Prix total en FCFA
01	Accès Internet		24h/24	03	150 000
Prix TOTAL : 150 000 FCFA					

Tableau IV. 2. Faisabilité technique (mercurial 2022)

IV.6.2. Sociale

L'aspect sociale implique l'évaluation de l'acceptation sociale, de l'impact sur les patients et de l'intégration dans la société. Nous pouvons citer entre autres :

- **Acceptation Sociale**

Tel que :

- Consultation des parties prenantes à travers notamment des médecins, radiologues, des patients, afin de recueillir leur opinion sur l'utilisation de notre solution pour la détection précoce des tumeur cérébrales.
- Education du public a travers des programmes sur la sensibilisation de l'utilisation de l'IA.

- **Impact sur les patients**

Tel que :

- L'évaluation de l'introduction de l'IA sur l'expérience des patients en termes de réduction des délais
- S'assurer que notre solution ne créé pas de disparité dans l'accès aux soins de santé

- **Ethique**

- Elaborer un cadre éthique solide pour guider l'utilisation de l'IA dans la détection précoce des tumeurs cérébrales en mettant l'accent sur la transparence, la responsabilité et le respect des droits des patients
- S'assurer que les données médicales utilisées sont gérées de manier éthique et conforme à la réglementation en matière de protection des données.

IV.7. Limites et Perspectives

IV.7.1. Limites

- **Disponibilité des données de formation** : L'une des principales contraintes est le manque de données de formation adéquates dans un contexte Camerounais. La création de bases de données annotées peut être coûteuse et prendre du temps.
- **Interprétation clinique** : Si l'IA peut identifier des problèmes, elle n'est pas toujours capable de fournir une interprétation clinique approfondie et complète.

- Les modèles d'IA peuvent être sensibles aux différences dans les données d'apprentissage et ne pas se généraliser correctement à divers groupes de patients ou à des formes de tumeurs moins fréquentes. Ceci est également due à la présence d'une base donnée limitée
- **Coûts** : Les systèmes d'IA peuvent être coûteux à créer, à installer et à entretenir, ce qui peut constituer un obstacle à leur adoption générale.

IV.7.2. Perspectives

- **Améliorer la qualité des données** : Les progrès réalisés dans la collecte et l'annotation de données de haute qualité peuvent aider à surmonter les restrictions en matière de données de formation.
- **Détection multimodale** : La combinaison de données provenant de plusieurs modalités, telles que l'imagerie par résonance magnétique (IRM) et la tomodensitométrie (TDM), peut améliorer la précision de la détection des tumeurs.
- **Prévision de la croissance tumorale** : de la réponse au traitement et des résultats cliniques grâce à l'IA : l'IA peut également être utilisée pour prédire la croissance tumorale, la réponse au traitement et les résultats cliniques, ouvrant ainsi la voie à une médecine personnalisée.

Conclusion

Les réseaux neuronaux convolutifs, associés à des algorithmes avancés d'identification d'objets, constituent une stratégie potentielle de détection précoce des cancers du cerveau. Les critères d'évaluation, tels que la précision, la sensibilité et la spécificité, permettent d'évaluer objectivement l'efficacité de la solution.

Toutefois, il est essentiel de se rappeler que l'intelligence artificielle en médecine ne se limite pas à la technologie elle-même. La capacité d'interpréter les données et de collaborer avec les professionnels de la santé est essentielle pour garantir la confiance et la fiabilité des conclusions diagnostiques.

Dans ce chapitre, nous avons fait une analyse de la situation afin de relayer les problèmes que pose la méthode traditionnelle pour la détection précoce des tumeurs cérébrales. Puis après nous avons donné les objectifs de notre intervention en les justifiant et enfin nous avons présenté la procédure d'implémentation de notre solution en entraînant nos données sur deux algorithmes afin de sélectionner le meilleur en termes de précision. En outre dans ce chapitre, nous avons montré comment l'intersection de la science, de la technologie et de la médecine peut ouvrir des voies pour le bien-être des patients. Les progrès de l'intelligence artificielle permettent une détection précoce plus précise, ce qui peut contribuer à sauver des vies et à améliorer la qualité de vie des patients.

CONCLUSION GENERALE

Ce mémoire aborde le problème de détection précoce des tumeurs cérébrales à partir d'image radiologique par apprentissage profond. Il était donc question pour nous d'employer une méthode scientifique afin de résoudre et d'améliorer la situation grâce aux techniques d'intelligence artificielle.

En ce qui concerne les questions sous-jacentes à notre étude, nous avons d'abord abordé, dans notre premier chapitre, la réalisation d'une étude de la littérature afin d'identifier et de définir la plupart des idées théoriques et technologiques nécessaires à une compréhension approfondie du sujet. C'est ainsi que nous avons défini l'apprentissage automatique et profond ainsi que les différentes approches d'apprentissage. Dans le même ordre d'idée, nous avons abordé les tumeurs cérébrales, leurs types et les solutions de Deep Learning existantes en ce qui concerne la segmentation des tumeurs cérébrales. Dans le deuxième chapitre, nous avons justifié la nature expérimentale de notre recherche puis présenté les différentes variables ainsi que les outils qui nous ont permis d'accomplir notre quête.

Dans la suite de ce mémoire nous avons présenté le site de notre recherche ainsi que la source des données collectées. Afin de rendre les données prêtes à utilisation pour notre modèle, nous avons effectué un processus de prétraitement qui consiste à normaliser, redimensionner et séparer en données de test et d'entraînement dans un pourcentage de 25% et 75% respectivement. Puis après, nous avons souligné le problème que pose la méthode traditionnelle pour la détection des tumeurs cérébrales dans le chapitre 4 suivi de la proposition de notre intervention. Dans la stratégie d'action, nous avons appliqué les différentes méthodes et algorithmes aux données d'images radiologique ce qui nous a permis de ressortir la précision, le rappel, le score F1 et la matrice de confusion. Le meilleur des deux modèles entraînés en termes de précision est sélectionné (modèle entraîné avec EfficientNet) avec une précision de 0,99 soit 99% de précision pour être déployer sur hugging face. A la suite de cela, une interface utilisateur est développée avec ReactJS et est connectée à notre modèle afin de faciliter son adoption et son utilisation.

WEBOGRAPHIE ET BIBLIOGRAPHIE

Webographie

anaconda.com. s.d. <https://www.anaconda.com/products/distribution> (consulté le 20 Aout, 2023 à 15:45)

coe.int s.d. <https://www.coe.int/fr/web/artificial-intelligence/history-of-ai> (consulté le 15 Aout, 2023 à 16:50)

lebigdata.com s.d. <https://www.lebigdata.fr/confusion-matrix-definition#:~:text=Confusion%20Matrix%20%3A%20définition,comparés%20avec%20les%20valeur> (consulté le 5 Aout, 2023 à 15:01)

nodejs.org s.d. <https://nodejs.org/en/download> (consulté le 5 Aout, 2023 à 15:00)

saagie.com s.d. <https://www.saagie.com/fr/blog/l-histoire-du-deep-learning/> (consulté le 5 Aout, 2023 à 18:00)

researchgate.net s.d. https://www.researchgate.net/figure/Pooling-layer-operation-oproaches-1-Pooling-layers-For-the-function-of-decreasing-the_fig4_340812216 (consulté le 5 Juillet, 2023 à 17:50)

v7labs.com s.d. <https://www.v7labs.com/blog/overfitting> (consulté le 5 Juillet, 2023 à 15:30)

python.developpez.com. s.d. <https://python.developpez.com/actu/315154/Lescreateurs-de-Python-devoient-leurs-plans-d-acceleration-pour-Python-quipromettent-de-le-rendre-2-a-5-fois-plus-rapide-sans-casser-aucun-codeexistant/> (consulté le 22 Juillet, 2023 à 14:00)

https://fr.wikipedia.org/wiki/Imagerie_par_r%C3%A9sonance_magn%C3%A9tique (consulté le 22 Juillet, 2023 à 14:05)

https://www.openclassroom.com/deep_learning/les%_neurones (consulté le 19 Juillet, 2023 à 13:05)

Bibliographie

Ali-Osman, Francis. 2002. « Brain Tumors ». P. 167-84 in *Human Cell Culture*. Vol. 2, *Human Cell Culture*, édité par J. R. W. Masters et B. Palsson. Dordrecht: Kluwer Academic Publishers. (Consulté le 02 Juin, 2023 à 14:00)

Azencott, Chloé-Agathe. s. d. « Introduction au Machine Learning ». (Consulté le 02 Juin, 2023 à 17:30)

Jul, Himadri Sankar Chatterjee. s. d. « A Basic Introduction to Convolutional Neural Network ». (Consulté le 20 Juin, 2023 à 12:25)

Mathew, Amitha, P. Amudha, et S. Sivakumari. 2021. « Deep Learning Techniques: An Overview ». P. 599-608 in *Advanced Machine Learning Technologies and Applications*. Vol. 1141, *Advances in Intelligent Systems and Computing*, édité par A. E. Hassanien, R. Bhatnagar, et A. Darwish. Singapore: Springer Singapore. (Consulté le 22 Juin, 2023 à 10 : 25)

Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in neural information processing systems*, pages 2672{2680, 2014. (Consulté le 01 Septembre, 2023 à 12:25)

Wasimuddin, Muhammad and Elleithy, Khaled and Abuzneid, Abdel-Shakour and Faezipour, Miad and Abuzagheh, Omar. «Stages-based ecg signal analysis from traditional signal processing to machine learning approaches: A survey. » *IEEE Access*, 2020. (Consulté le 03 Septembre, 2023 à 13 :30)

Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. *arXiv preprint arXiv:1502.03167*, 2015. (Consulté le 03 Septembre, 2023 à 22:25)

Dumitru Erhan, Yoshua Bengio, Aaron Courville, Pierre-Antoine Manzagol, Pascal Vincent, and Samy Bengio. Why does unsupervised pre-training help deep learning? *Journal of Machine Learning Research*, 11(Feb):625{660, 2010. (Consulté le 25 Aout, 2023 à 10 :30)

Ranzato, M., Mnih, V., and Hinton, G. (2010b). Generating more realistic images using gated MRFs. In *NIPS'2010*. (Consulté le 25 Aout, 2023 à 11:00)

Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C., and Fei-Fei, L. (2014a). ImageNet Large Scale Visual Recognition Challenge. (Consulté le 17 Aout, 2023 à 17:17)

Salakhutdinov, R. and Hinton, G. E. (2007a). Learning a nonlinear embedding by preserving class neighbourhood structure. In *Proceedings of the Eleventh International Conference on Artificial Intelligence and Statistics (AISTATS'07)*, San Juan, Porto Rico. Omnipress. (Consulté le 18 Aout, 2023 à 15:25)

Schmidhuber, J. (1992). Learning complex, extended sequences using the principle of history compression. *Neural Computation*, (Consulté le 29 Juillet, 2023 à 7:30)

Sutton, R. S., Mcallester, D., Singh, S., and Mansour, Y. (2000). Policy gradient methods for reinforcement learning with function approximation. In *NIPS'1999*, pages 1057—1063. MIT Press. (Consulté le 27 Juillet, 2023 à 13:27)

Mathew et al. - 2021 - Deep Learning Techniques An Overview.pdf (Consulté le 28 Aout, 2023 à 13:29)

Hestenes, M. et Stiefel, E. (1952). Methods of conjugate gradients for solving linear systems. *Journal of Research of the National Bureau of Standards*, 19(6). (Consulté le 13 Aout, 2023 à 8:29)

Kuhn, H. W. et Tucker, A. W. (1951). Nonlinear programming. In Neyman, J., editor, *Proceedings of the Second Berkeley Symposium on Mathematical Statistics and Probability*, pages 481–492. University of California Press. (Consulté le 27 Aout, 2023 à 20:47)

Luenberger, D. G. (1969). *Optimization by Vector Space Methods*. John Wiley & Sons. (Consulté le 1er Septembre, 2023 à 4:04)

ANNEXES

Formulaire de Recueil

* Indicates required question

1. Age

2. Sexe *

Mark only one oval.

- ☐ Masculin
☐ Feminin
☐ Autre

3. Avez-vous déjà entendu parler d'une tumeur cérébrale ? *

Mark only one oval.

- ☐ Oui
☐ Non

4. Connaissez-vous des personnes ou vous même avoir déjà été diagnostiqué avec une tumeur cérébrale par le passé ? *

Mark only one oval.

- ☐ Oui. J'ai été diagnostiqué avec une tumeur cérébrale dans le passé
☐ Oui. Je connais des proches ou connaissance qui ont été diagnostiqué avec une tumeur cérébrale
☐ Non désolé pas du tout

<https://docs.google.com/forms/d/1MBmxGx-GjNoc6Cs16kTdJENngDF0yv31E3m3Xm6DbC0/edit?pli=1>

1/4

11/09/2023 15:42

Formulaire de Recueil

5. Si oui pour la question precedente, un professionnel de la santé a t'il été contacté en raison de ces symptômes ?

Mark only one oval.

- ☐ Oui
☐ Non
☐ Aucune idée

6. Quel type de diagnostic avait été reçu ?

Mark only one oval.

- ☐ IRM
☐ Tomodensitométrie
☐ Biopsie
☐ Autre

7. À quel stade a été diagnostiquée la tumeur cérébrale ?

Mark only one oval.

- ☐ 0
☐ 1
☐ 2
☐ 3
☐ 4

8. Quelle a été la durée entre l'apparition des symptômes et le diagnostic ?

9. Quel traitement avait été suivi pour la tumeur cérébrale ?

Mark only one oval.

- ☐ Chirurgie
- ☐ Radiothérapie
- ☐ Chimiothérapie
- ☐ Thérapie par protons ou ions lourds
- ☐ Thérapie ciblée
- ☐ Aucun

10. Quel a été la réaction la reaction au traitement

Mark only one oval.

- ☐ Bien
- ☐ Mal
- ☐ Bien. Mais avec beaucoup de difficulté
- ☐ Aucun effet

11. Pensez-vous que l'information sur les symptômes des tumeurs cérébrales devrait être davantage diffusée ?

Mark only one oval.

- ☐ Oui
- ☐ Non
- ☐ Je ne sais pas

9. Quel traitement avait été suivi pour la tumeur cérébrale ?

Mark only one oval.

- ☐ Chirurgie
- ☐ Radiothérapie
- ☐ Chimiothérapie
- ☐ Thérapie par protons ou ions lourds
- ☐ Thérapie ciblée
- ☐ Aucun

10. Quel a été la réaction la reaction au traitement

Mark only one oval.

- ☐ Bien
- ☐ Mal
- ☐ Bien. Mais avec beaucoup de difficulté
- ☐ Aucun effet

11. Pensez-vous que l'information sur les symptômes des tumeurs cérébrales devrait être davantage diffusée ?

Mark only one oval.

- ☐ Oui
- ☐ Non
- ☐ Je ne sais pas

TABLE DES MATIERES

DEDICACE	I
REMERCIEMENTS	II
RESUME	III
ABSTRACT	IV
SOMMAIRE	V
LISTE DES FIGURES	VI
LISTE DES TABLEAUX	IX
LISTE DES ABREVIATIONS	X
INTRODUCTION GENERALE	1
CHAPITRE I : CADRE THEORIQUE ET CONCEPTUEL	11
Introduction.....	12
I.1. Histoire de l'IA	13
I.2. Définition.....	19
<i>I.2.1. Qu'est-ce qu'une Intelligence Artificielle ?</i>	<i>19</i>
<i>I.2.2. Apprentissage automatique (Machine Learning (ML)) (Azencott s. d.).....</i>	<i>21</i>
<i>I.2.3. Présentation des algorithmes de classification, avantage et inconvénient en Machine Learning (Azencott s. d.)</i>	<i>25</i>
<i>I.2.4. Apprentissage profond (Deep Learning (DL)) (Mathew, Amudha, et Sivakumari 2021) ¹</i>	<i>29</i>
<i>I.2.5. Présentation des algorithmes de classification en deep learning, avantage et inconvénient (Azencott s. d.) ²</i>	<i>31</i>
<i>I.2.6. Types d'algorithme du réseau de neurone convolutif (Convolutional Neural network (CNN))</i>	<i>32</i>
<i>I.2.7. Composante du réseau de neurone convolutif (Convolutional Neural network (CNN)) (Jul s. d.) ³</i>	<i>33</i>
<i>I.2.8. Méthode d'optimisation et mesure de performance</i>	<i>37</i>
I.3. Généralité sur les tumeurs cérébrales (Ali-Osman 2002) ⁴	40
I.3.1. Définition.....	40
I.3.2. Classification des tumeurs cérébrales (Ali-Osman 2002)	41
I.3.3. Types de tumeur cérébrale	42
I.3.4. Diagnostic (Ali-Osman 2002)	43
I.4. Etat de l'art.....	45
Conclusion	49
CHAPITRE II : METHODOLOGIE DE RECHERCHE	51

Introduction.....	52
II.1. Nature de la recherche	53
II.2. Variable de recherche	54
II.2.1. Définition Conceptuelle	54
II.2.1. Limites et difficultés	55
II.3. Outils de recherche	55
Conclusion	57
CHAPITRE III : PRESENTATION DE LA SITUATION.....	58
Introduction.....	59
III.1. Présentation du site de recherche	60
III.1.1. Historique et mission	60
III.1.2. Organisation	60
III.1.3. Organigramme de la structure.....	61
III.1.4. Localisation	61
III.1.5. Ressource Matérielles.....	62
III.2. Présentation des données et analyse	63
Conclusion	67
CHAPITRE IV : ANALYSE DE LA SITUATION ET PROPOSITION D'INTERVENTION.....	68
Introduction.....	69
IV.1. Présentation et analyse de la situation.....	70
IV.2. Intervention proposée et justification	71
IV.3. Objectifs de l'intervention	72
IV.3.1. Objectif générale	72
IV.3.2. Objectif spécifique	72
IV.4. Composantes de l'intervention envisagée	72
IV.5. Stratégies d'action	80
IV.5.1. Architecture de la solution.....	80
IV.5.2. Présentation du Jeu de données sur les tumeurs cérébrales	82
IV.5.3. Procédure d'implémentation	85
IV.6. Faisabilité	97
IV.6.1. Economique.....	98
IV.6.2. Sociale.....	100
IV.7. Limites et Perspectives.....	100
IV.7.1. Limites.....	100
IV.7.2. Perspectives	101
Conclusion	101

CONCLUSION GENERALE	103
WEBOGRAPHIE ET BIBLIOGRAPHIE	XI
<i>Webographie</i>	XI
<i>Bibliographie</i>	XII
ANNEXES	XIV
TABLE DES MATIERES	XVI